

Inteligencia Artificial

Introducción al Análisis de Datos

Ing. González H. Alexis



Tabla de Contenidos

01

Active Recall

Repaso del tema anterior

02

Main Content

Flujo de trabajo típico.
Uso de librerías para análisis de
datos.
Introducción al EDA.


03

Live Coding Pair Programming

Ejercitación & Feedback

01

Active Recall



Active Recall

A partir de estos datos:

Nro. Pasajeros	Desayuno	Precio
3	Sí	\$350
2	Sí	\$250
5	No	\$500
3	No	\$300

¿Podrían predecir el precio para estos nuevos datos? $Precio = (Pasajeros * 100) + (50 \text{ si Desayuno es Sí})$

Nro. Pasajeros	Desayuno	Precio
1	Sí	?
4	No	?

¿Qué tipo de aprendizaje máquina sería?

Aprendizaje supervisado

$$\text{Precio} = (\text{Pasajeros} * 100) + (50 \text{ si Desayuno es Sí})$$

Datos de entrenamiento:

Nro. Pasajeros	Desayuno	Precio
3	Sí	\$350
2	Sí	\$250
5	No	\$500
3	No	\$300

Target
(etiqueta, label)

Entrenar un modelo

Mostrar datos etiquetados para que aprenda la relación o el mecanismo que conecta los datos de entrada con la etiqueta

Pasajero: \$100

Desayuno: \$50

Datos de prueba (test):

Nro. Pasajeros	Desayuno	Precio
1	Sí	\$150
4	No	\$400

Predecir

El modelo calcula la incógnita en base a lo que aprendió

Aprendizaje supervisado

Problema de REGRESIÓN
La etiqueta es una cantidad

Nro. Pasajeros	Desayuno	Precio
3	Sí	\$350
2	Sí	\$250
5	No	\$500
3	No	\$300

Problema de CLASIFICACIÓN
La etiqueta es una categoría

Nro. Pasajeros	Desayuno	Precio
3	Sí	BARATO
2	Sí	BARATO
5	No	MUY CARO
3	No	CARO

Target

Es la respuesta correcta que le damos a la máquina para que aprenda a hacer su trabajo

Aprendizaje supervisado

Problema de REGRESIÓN

La etiqueta es una cantidad

Nro. Pasajeros	Desayuno	Precio
3	Sí	\$350
2	Sí	\$250
5	No	\$500
3	No	\$300

¿Cuánto? ¿Qué Cantidad?

Predecir una cantidad

- Predecir el sueldo de una persona en base a sus años de experiencia.
- Estimar la temperatura de mañana.
- Calcular cuántas unidades de un producto se van a vender el próximo mes. Etc.

Problema de CLASIFICACIÓN

La etiqueta es una categoría

Nro. Pasajeros	Desayuno	Precio
3	Sí	BARATO
2	Sí	BARATO
5	No	MUY CARO
3	No	CARO

¿De qué tipo es? ¿A qué grupo pertenece?

Predecir una categoría

- Un filtro de correo electrónico (spam vs. no spam)
- Aprobar o rechazar un crédito bancario.
- Usar computer vision para detectar si en una imagen hay un perro o un gato. Etc.

Esta es una decisión que se toma en la etapa de diseño, antes de escribir una sola línea de código.

Active Recall

¿Podrían agrupar estos perfiles de lector en dos grupos? ¿y en tres?



No hay Target
(etiqueta, label)

Libros terminados	% de subrayado	Sesiones de lectura por semana	Minutos por sesión	Grupo
15	40%	7	15	?
16	5%	2	20	?
42	45%	7	45	?
14	38%	2	65	?
40	8%	3	60	?
18	42%	6	20	?
38	44%	2	15	?

Aprendizaje no supervisado

El modelo encuentra
estos grupos



Libros terminados	% de subrayado	Sesiones de lectura por semana	Minutos por sesión	Grupo
15	40%	7	15	1
16	5%	2	20	2
42	45%	7	45	1
14	38%	2	65	3
40	8%	3	60	2
18	42%	6	20	1
38	44%	2	15	3

Entrenar un modelo

Dar los datos **SIN ETIQUETAR** y dejar que el modelo descubra patrones, relaciones o agrupamientos por sí mismo

Aprendizaje no supervisado

La etiqueta la ponemos nosotros



Libros terminados	% de subrayado	Sesiones de lectura por semana	Minutos por sesión	Grupo	Etiqueta
15	40%	7	15	1	CONSTANTE
16	5%	2	20	2	HOBBY
42	45%	7	45	1	CONSTANTE
14	38%	2	65	3	MIX
40	8%	3	60	2	HOBBY
18	42%	6	20	1	CONSTANTE
38	44%	2	15	3	MIX

En el Aprendizaje No Supervisado, la **etiqueta** es el toque final (lo usamos para bautizar lo que descubrimos).



02

Main Content { }

¿Qué es el análisis de datos?

Definición y Proceso

Es el proceso de explorar, limpiar y modelar datos para extraer información útil y tomar decisiones.

Rol en la IA

Es clave para garantizar que los modelos de IA trabajen con datos confiables y adecuados para el problema.




Exploramos

Limpiamos

Modelamos

Roles en datos y Machine Learning



Flujo de trabajo del análisis de datos para IA


01

Identificar el problema



02

Recopilar los datos



03

EDA y limpieza básica




04

Análisis estadístico y preparación



05

Entrenar modelos



Proceso Iterativo

Ej. Sistema de visión artificial

01

Identificar el problema

Queremos que una cámara detecte automáticamente si un producto en la cinta transportadora está roto.

02

Recopilar los datos

Ponemos a grabar la cámara y juntamos 10.000 fotos del producto pasando por la cinta.

03

EDA y limpieza básica

Descartamos las fotos que salieron borrosas, oscuras o donde la lente estaba tapada.

04

Análisis estadístico y preparación

Analizamos estadísticamente "sanos" y "rotos" para no sesgar a la máquina, y normalizamos todas las imágenes a un tamaño de 256x256 píxeles.

05

Entrenar modelos

Le pasamos las imágenes a nuestra red neuronal para que aprenda a extraer las características visuales (bordes, contrastes) que definen a una pieza fallada.



Proceso Iterativo

Librerías Python

Recolección de datos

BeautifulSoup

SQLAlchemy

EDA, preprocesamiento, limpieza

pandas

NumPy

Visualización y análisis

matplotlib



seaborn

Análisis estadístico, reducción de dimensionalidad



SciPy



statsmodels

Otras (otros tipos de datos, automatización)



Sweetviz

PYCARET




librosa



YData



Terminología básica pandas





Google Colab

Ejemplos prácticos

02_carga_y_exploracion_datos\01_carga_y_exploracion_datos.ipynb



¿Qué es el análisis exploratorio de datos (EDA)?



¿Qué es el análisis exploratorio de datos (EDA)?



Comprensión

Resumir, visualizar y entender en profundidad la naturaleza de los datos.



Tratamiento

Tomar decisiones fundamentales sobre outliers y datos faltantes.



Preparación

Identificar transformaciones necesarias antes del entrenamiento de ML.



Patrones

Facilitar el descubrimiento de relaciones y la relevancia de variables.



Variables aleatorias y datasets



Mapeo Numérico

Una variable aleatoria (v.a.) es una forma de mapear los resultados de algún fenómeno aleatorio a números.



1



2



3




Modelado y Análisis

Constituyen una herramienta fundamental para modelar y analizar fenómenos que involucran incertidumbre o aleatoriedad.



Muestras en Datasets

Las columnas de un dataset pueden considerarse como un conjunto de observaciones de una variable aleatoria tomada de una población.



El dataset del Titanic

Introducción al Aprendizaje de IA

Es un dataset sumamente famoso y fundamental para dar los primeros pasos en Ciencia de Datos. Lo utilizaremos a lo largo del curso para ilustrar y aplicar conceptos esenciales de Machine Learning.

Información de los Pasajeros

El set de datos recopila características detalladas del pasaje:

- **Demografía y Viaje:** Edad, género, tarifa pagada y clase social en la que viajaban.
- **Relaciones:** Cantidad de familiares (padres, hijos, cónyuges, hermanos) a bordo.
- **Variable Objetivo:** El estado de supervivencia final de cada persona (sobrevivió o no).



Ejemplos de v. aleatorias en el dataset del Titanic



SURVIVED
(¿Sobrevivió?)

Varía aleatoriamente según factores como:

- Ubicación en el barco,
- Acceso a botes salvavidas,
- Clase social,
- Decisiones personales durante el naufragio.



SEX

Varía aleatoriamente según la composición de quienes decidieron o pudieron viajar.

Influenciada por factores sociales como:

- Roles de género,
- Motivos del viaje.



AGE



Variable en función de la población que decidió o pudo viajar en el Titanic.
Condicionada por:

- Año de nacimiento,
- Circunstancias que los llevaron a ese viaje.



SibSp (cantidad de hermanos o esposo/a)

Influenciada por:

- Decisiones familiares (ej., viajar juntos),
(Cherbourg, Queenstown juntos)
- Tamaño de la familia,
- Factores sociales de la época.



FARE
(tarifa)



Variable según factores como:

- La clase (primera, segunda, tercera),
(Queenstown, Southampton)
- El puerto de embarque,
- Decisiones individuales de compra.




EMBARKED
(puerto de embarque)

Influenciada por:

- Lugar de origen,
- Itinerario personal,
- Disponibilidad de pasajes desde cada puerto.

Tipos de variables



Algunas consideraciones interesantes

Variables Categóricas

- **Representación:** Se pueden representar con números que actúan como un encoding o codificación.
- **Casos Binarios:** Las variables binarias (Sí/No, 1/0, True/False) son un tipo particular de las nominales.

El Caso de la Edad

- **Teoría vs. Práctica:** Generalmente se considera una variable continua por su naturaleza.
- **Medición:** Se suele medir y reportar como discreta (ej. en años), ilustrando la diferencia entre el dato real y cómo se refleja.

Doble Naturaleza: Fechas

- **Numérica:** Es útil cuando interesa cuantificar el tiempo transcurrido o analizar tendencias temporales.
- **Categórica:** Permite agrupar eventos en periodos específicos (ej. ventas por día de la semana).

¿Y qué pasa con las coordenadas geográficas? Reflexión para el análisis del dataset.



Google Colab

Ejercicio

02_carga_y_exploracion_datos\ejercicios\01_ejercicio_exploracion_dataset.ipynb



Actividad individual opcional

Objetivo

Identificar y seleccionar un dataset real. Familiarizarse con las bases de datos y repositorios abiertos, las interfaces de descarga, los distintos tipos de archivos y metadatos.

Consigna

Buscar un dataset de acceso libre que despierte tu curiosidad o que esté relacionado con tu área de interés. Puede provenir de portales de datos abiertos como Kaggle, datos.gob.ar, data.gov, UCI Machine Learning Repository, etc.

El dataset debe cumplir con las siguientes condiciones:

- Entre 200 y 2000 filas
- Al menos 5 variables (columnas)
- Mínimo 2 variables numéricas y 2 variables categóricas
- De acceso público y gratuito

Importante:


Hay MUCHOS datasets disponibles. **No elegir el dataset Titanic!**



Entrega	Estado	Puntos
No	-	0
Si	No cumple con la consigna	0
Si	Si cumple con la consigna	1

¡Gracias!

¿Consultas?



Ing. González H. Alexis