

Inteligencia Artificial

Análisis exploratorio de datos

Ing. González H. Alexis



Tabla de Contenidos

01

Active Recall

Repaso del tema anterior

02

Main Content

Estadísticas descriptivas.
Estadística robusta.
Relaciones entre variables.
Visualización de variables
numéricas y categóricas


03

Live Coding Pair Programming


Ejercitación & Feedback

01

Active Recall



Tipos de variables






© gonzalezhalexis@gmail.com ©

Tipos de análisis estadístico

Análisis Univariado

Análisis Bivariado

Análisis Multivariado




Tipos de análisis estadístico

Análisis Univariado

Estudia una sola variable a la vez con el objetivo de describir sus características principales, como por ejemplo su distribución.




Series		Series		DataFrame	
apples		oranges		apples	oranges
0	3	0	0	0	3
1	2	3	3	1	2
2	0	7	7	2	0
3	1	2	2	3	1



Tipos de análisis estadístico

Series		Series		DataFrame	
apples		oranges		apples	oranges
0	3	0	0	0	3
1	2	1	3	1	2
2	0	2	7	2	0
3	1	3	2	3	1



Análisis Bivariado

Estudia la relación entre dos variables para identificar si existe dependencia o correlación entre ellas.



Tipos de análisis estadístico

Series 1

Mango

0	4
1	5
2	6
3	3
4	1

+

Series 2

Apple

0	5
1	4
2	3
3	0
4	2

+

Series 3

Banana

0	2
1	3
2	5
3	2
4	7

=


DataFrame

Mango	Apple	Banana	
0	4	5	2
1	5	4	3
2	6	3	5
3	3	0	2
4	1	2	7

Análisis Multivariado

Analiza tres o más variables simultáneamente para comprender interacciones y efectos conjuntos.

Tasa de Supervivencia en el Titanic por Clase y Sexo




Tipos de análisis estadístico

Análisis Univariado

Estudia una sola variable a la vez con el objetivo de describir sus características principales, como por ejemplo su distribución.


Series		Series		DataFrame																																			
<table><tr><th></th><th>apples</th></tr><tr><td>0</td><td>3</td></tr><tr><td>1</td><td>2</td></tr><tr><td>2</td><td>0</td></tr><tr><td>3</td><td>1</td></tr></table>		apples	0	3	1	2	2	0	3	1	+	<table><tr><th></th><th>oranges</th></tr><tr><td>0</td><td>0</td></tr><tr><td>1</td><td>3</td></tr><tr><td>2</td><td>7</td></tr><tr><td>3</td><td>2</td></tr></table>		oranges	0	0	1	3	2	7	3	2	=	<table><tr><th></th><th>apples</th><th>oranges</th></tr><tr><td>0</td><td>3</td><td>0</td></tr><tr><td>1</td><td>2</td><td>3</td></tr><tr><td>2</td><td>0</td><td>7</td></tr><tr><td>3</td><td>1</td><td>2</td></tr></table>		apples	oranges	0	3	0	1	2	3	2	0	7	3	1	2
	apples																																						
0	3																																						
1	2																																						
2	0																																						
3	1																																						
	oranges																																						
0	0																																						
1	3																																						
2	7																																						
3	2																																						
	apples	oranges																																					
0	3	0																																					
1	2	3																																					
2	0	7																																					
3	1	2																																					



Análisis Bivariado

Estudia la relación entre dos variables para identificar si existe dependencia o correlación entre ellas.

Series		Series		DataFrame																																
<table><tr><th>apples</th></tr><tr><td>0</td><td>3</td></tr><tr><td>1</td><td>2</td></tr><tr><td>2</td><td>0</td></tr><tr><td>3</td><td>1</td></tr></table>	apples	0	3	1	2	2	0	3	1	+	<table><tr><th>oranges</th></tr><tr><td>0</td><td>0</td></tr><tr><td>1</td><td>3</td></tr><tr><td>2</td><td>7</td></tr><tr><td>3</td><td>2</td></tr></table>	oranges	0	0	1	3	2	7	3	2	=	<table><tr><th>apples</th><th>oranges</th></tr><tr><td>0</td><td>3</td><td>0</td></tr><tr><td>1</td><td>2</td><td>3</td></tr><tr><td>2</td><td>0</td><td>7</td></tr><tr><td>3</td><td>1</td><td>2</td></tr></table>	apples	oranges	0	3	0	1	2	3	2	0	7	3	1	2
apples																																				
0	3																																			
1	2																																			
2	0																																			
3	1																																			
oranges																																				
0	0																																			
1	3																																			
2	7																																			
3	2																																			
apples	oranges																																			
0	3	0																																		
1	2	3																																		
2	0	7																																		
3	1	2																																		



Análisis Multivariado

Analiza tres o más variables simultáneamente para comprender interacciones y efectos conjuntos.

Diagram illustrating the addition of three Series (Series 1, Series 2, Series 3) to form a DataFrame.

Series 1 (Mango):

	Mango
0	4
1	5
2	6
3	3
4	1

Series 2 (Apple):

	Apple
0	5
1	4
2	3
3	0
4	2


Series 3 (Banana):

	Banana
0	2
1	3
2	5
3	2
4	7

DataFrame:

	Mango	Apple	Banana
0	4	5	2
1	5	4	3
2	6	3	5
3	3	0	2
4	1	2	7

The diagram shows the addition of Series 1, Series 2, and Series 3 to form the DataFrame. The result is a DataFrame with columns Mango, Apple, and Banana, and rows 0 to 4.



Variables numéricas

Las variables numéricas se pueden caracterizar en términos de:

Tendencia central

**TENDENCIA
CENTRAL**



Variabilidad



VARIABILIDAD

Forma





FORMA

Variables numéricas

Las variables numéricas se pueden caracterizar en términos de:

Tendencia central

Resume en un solo valor al centro de la distribución de los datos (ej. media, mediana y moda).





El problema de la **tendencia central** es que nos puede ocultar la realidad.

Variables numéricas

Las variables numéricas se pueden caracterizar en términos de:


Variabilidad

Mide qué tan dispersos o alejados se encuentran los datos del centro (ej. desviación estándar, varianza y rango).



Curso A: Distribución Uniforme

Todos y cada uno de los alumnos se sacaron exactamente un 7.




Promedio = 7
Dispersión = Cero

(Todas pegadas en el 7).



Curso B: Distribución Dispersa

La mitad de la clase sacó un 10 excelente, y la otra mitad sacó un 4 de milagro.



Promedio = 7
Dispersión = Altísima

(Saltan de extremo a extremo). ➡

¿Qué significa?





El promedio es 7 en ambos, pero la realidad del aula es totalmente distinta. La dispersión nos mide justamente eso: qué tan 'desparramadas', apretadas o alejadas del centro están las notas.

Variables numéricas

Las variables numéricas se pueden caracterizar en términos de:

Forma

Describe el aspecto de la distribución, analizando su simetría y su nivel de apuntamiento (ej. asimetría y kurtosis).



FORMA: Mirar visualmente hacia dónde tira el 'peso' de los datos.

Variables numéricas

Las variables numéricas se pueden caracterizar en términos de:

Tendencia central

Resume en un solo valor al centro de la distribución de los datos (ej. media, mediana y moda).

Variabilidad

Mide qué tan dispersos o alejados se encuentran los datos del centro (ej. desviación estándar, varianza y rango).

Forma

Describe el aspecto de la distribución, analizando su simetría y su nivel de apuntamiento (ej. asimetría y curtosis).



Cuando analizamos una variable numérica, nuestro objetivo es contar la historia de dónde está su centro, qué tan estirados están los números y qué dibujo forman

Momentos

Son simplemente las **herramientas matemáticas** que usamos para calcular exactamente esas tres cosas (Tendencia Central, la Dispersión y la Forma)

Momento de orden k

Calculado respecto al origen.

$$\mu'_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$


Momento central de orden k

Calculado respecto a la media.


$$\mu_k = \frac{1}{n} \sum_{i=1}^n \left(x_i - \bar{x} \right)^k$$

Momentos

Los momentos son medidas que capturan diferentes aspectos de una distribución de datos numéricos.



Momentos



$$\frac{1}{N} \sum_{i=1}^N (x_i)^k$$

1. MOMENTO RESPECTO AL ORIGEN ($E[X^k]$)
(Medida desde el Cero Absoluto - Número Crudo)

k = 1: PROMEDIO (Media Cruda)

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

k = 2: Segundo Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^2$$

k = 3: Tercer Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^3$$

k = 4: Cuarto Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^4$$

$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^k$$

2. MOMENTO CENTRAL ($E[(X - \bar{x})^k]$)
(Medida en Centro)

k = 1: CENTRO DE GRAVEDAD (Siempre 0)

$$0 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})$$

k = 2: VARIANZA (Dispersión)

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

k = 3: Tercer Momento Central (Asimetría)

$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^3$$

k = 4: Cuarto Momento Central (Curtosis)


$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^4$$

Tendencia central: media, mediana y moda

Son distintas formas de medir el “centro” en un conjunto numérico de datos.

Media

El famoso promedio.




Mediana

Fifty fifty



Moda

El número que más se repite.



Tendencia central: media, mediana y moda



MÉTRICAS DE TENDENCIA CENTRAL: LA ANALOGÍA DE LOS SUELDOS

CÓMO EL CENTRO DE DATOS DIFIERE CON EXTREMOS


1. LA MODA: El Pico de Frecuencia



Moda = \$1,000


Sueldo más repetido.
Ignora extremos.

2. LA MEDIANA: El Corte Justo



50% gana \$1,000 o menos.
No distorsionado.

3. LA MEDIA: El Punto de Equilibrio



Media = \$2,900

\$29k Total / 10 Personas = \$2,900.
Arrastrada por extremos.

Medidas de dispersión: varianza y desviación estándar

Varianza


Sirven para medir qué tan “dispersos” están los datos alrededor de la media.

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

Desviación Estándar

La desviación estándar suele ser más fácil de interpretar.

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2}$$




$\frac{1}{N} \sum_{i=1}^N (x_i)^k$	$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^k$
1. MOMENTO RESPECTO AL ORIGEN ($E[X^k]$) (Medida desde el Cero Absoluto - Número Crudo)	2. MOMENTO CENTRAL ($E[(X - \bar{x})^k]$) (Medida en Centro)
k = 1: PROMEDIO (Media Cruda) $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$	k = 1: CENTRO DE GRAVEDAD (Siempre 0) $0 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})$
k = 2: Segundo Momento Crudo $\frac{1}{N} \sum_{i=1}^N x_i^2$	k = 2: VARIANZA (Dispersión) $\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$
k = 3: Tercer Momento Crudo $\frac{1}{N} \sum_{i=1}^N x_i^3$	k = 3: Tercer Momento Central (Asimetría) $\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^3$
k = 4: Cuarto Momento Crudo $\frac{1}{N} \sum_{i=1}^N x_i^4$	k = 4: Cuarto Momento Central (Curtosis) $\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^4$

Medidas de dispersión: varianza y desviación estándar

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2}$$




Medidas de dispersión: varianza y desviación estándar

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2}$$

¿CUÁL ES MÁS "SEGURA" PARA UN BUEN SUELDO?



EMPRESA A

Promedio: \$2.000.000

Caos (D. Est.): \$50.000


PREDECIBILIDAD ALTA

CASI TODOS COBRAN
CERCA DEL PROMEDIO

¡POCO RIESGO!



Poco
Rango



EMPRESA B

Promedio: \$2.000.000

Caos (D. Est.): \$1.500.000

INCIERTO

MUCHOS GANAN
MUCHO MÁS, OTROS
MUCHO MENOS

¡ALTO RIESGO!




Gran Rango

➔ SENTIRÁS MÁS SEGURIDAD EN "A"
PORQUÉ: En A, sabes tu sueldo. En B, es una LOTERÍA.



Medidas de forma: asimetría



$$\frac{1}{N} \sum_{i=1}^N (x_i)^k$$

1. MOMENTO RESPECTO AL ORIGEN ($E[X^k]$)
(Medida desde el Cero Absoluto - Número Crudo)

k = 1: PROMEDIO (Media Cruda)

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

k = 2: Segundo Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^2$$

k = 3: Tercer Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^3$$

k = 4: Cuarto Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^4$$

$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^k$$

2. MOMENTO CENTRAL ($E[(X - \bar{x})^k]$)
(Mesarrel en Centro)

k = 1: CENTRO DE GRAVEDAD (Siempre 0)

$$0 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})$$

k = 2: VARIANZA (Dispersión)

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

k = 3: Tercer Momento Central (Asimetría)

$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^3$$

k = 4: Cuarto Momento Central (Curtosis)


$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^4$$

Medidas de forma: asimetría

LA ANALOGÍA DE LA MASA




LA VISUALIZACIÓN DE DATOS



¡ALARMA! DATOS SESGADOS



Medidas de forma: asimetría



Asimetría (Skewness)

ANÁLISIS E INTERPRETACIÓN



altamente
asimétrica

moderadamente
asimétrica


aproximadamente
simétrica

moderadamente
asimétrica


altamente
asimétrica



$\text{media} < \text{mediana} < \text{moda}$



$\text{media} = \text{mediana} = \text{moda}$



$\text{moda} < \text{mediana} < \text{media}$

EJEMPLOS


Asimetría Negativa

- edad de jubilación
- peso al nacer
- notas de exámenes sencillos

Asimetría Positiva

- salarios
- tiempos de espera
- precios de departamentos

Medidas de forma: curtosis



$$\frac{1}{N} \sum_{i=1}^N (x_i)^k$$

1. MOMENTO RESPECTO AL ORIGEN ($E[X^k]$)
(Medida desde el Cero Absoluto - Número Crudo)

k = 1: PROMEDIO (Media Cruda)

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

k = 2: Segundo Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^2$$

k = 3: Tercer Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^3$$

k = 4: Cuarto Momento Crudo

$$\frac{1}{N} \sum_{i=1}^N x_i^4$$

$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^k$$

2. MOMENTO CENTRAL ($E[(X - \bar{x})^k]$)
(Mesarrel en Centro)

k = 1: CENTRO DE GRAVEDAD (Siempre 0)

$$0 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})$$

k = 2: VARIANZA (Dispersión)

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

k = 3: Tercer Momento Central (Asimetría)

$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^3$$

k = 4: Cuarto Momento Central (Curtosis)

$$\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^4$$

Medidas de forma: curtosis



LA ANALOGÍA DE LA MASA



Masa Perfecta
(Referencia Normal)

CHATURA Y ANCHURA
(Colas Ligeras, Pico Bajo)



APLASTAMIENTO
DESDE ARRIBA

MASA CHATA
Y ANCHA

COLAS LIGERAS
(Leve peso)



ESTIRAMIENTO
HA LA ARRIBA



ESTIRAMIENTO
HACIA ARRIBA


ALTURA Y FINURA
(Colas Pesadas, Pico Alto)

MASA FINA Y
PUNTIAGUDA


COLAS PESADAS
(Gran peso)



LA VISUALIZACIÓN DE DATOS



¡MICROSCÓPIO DE COLAS! DATOS Y RIESGO



Curtosis



PESO DE LAS COLAS.

Medida de cuántos datos hay hacia los extremos de la distribución.

(Adapted from original)

$$Curtosis = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^4}{\sigma^4}$$

RANGO DE CURTOSIS: $[1, +\infty)$



AVISO DE CONFIANZA.

Indica el peligro de basarse solo en métricas centrales si hay colas pesadas.

(Adapted from original)

LOS TRES TIPOS DE CURTOSIS CON VALORES CLAVE


LEPTOCÚRTICA

(Puntiaguda)



MESOCÚRTICA

(Normal)



PLATICÚRTICA

(Plana)



Curtosis exceso

Curtosis Exceso = Curtosis - 3.



Para una distribución Normal, la **Curtosis Exceso** es 0.
(Adapted from original).

Mide cuánto más pesadas o ligeras son las colas de comparadas con la normal.

RANGO DE CURTOSIS EXCESO:
 $[-2, +\infty)$

Curtosis exceso



INTERPRETACIÓN Y ANÁLISIS VISUAL

PLATICÚRTICA
(Colas Menos Pesadas)


MESOCÚRTICA
(Considerada Normal)

LEPTOCÚRTICA
(Colas Pesadas)

-2 -1 0 1 2 3



Exceso de Curtosis = 0



Exceso de Curtosis > 0

EJEMPLOS PRÁCTICOS



Edades en un Jardín de Infantes
Temperatura en un Quirófano



Temperatura en
en un Quirófano



Likes / Views
en Videos

Likes / Views en Videos
Magnitudes de Sismos



Curtosis exceso





INTERPRETACIÓN

platicúrtica
(colas menos pesadas)

mesocúrtica
(se considera Normal)

leptocúrtica
(colas pesadas)



En este ejemplo:


- Distribución de Laplace con $\mu = \frac{1}{\sqrt{2}}$
- Normal estándar $\mu = 0, \sigma^2 = 1$
- Uniforme entre $\pm\sqrt{3}$

Estadística robusta

La **estadística robusta** es un enfoque de la estadística que busca ser resistente a problemas comunes en los datos reales:

- valores atípicos (outliers)
- datos que no cumplen los supuestos clásicos (como normalidad).

Las medidas robustas capturan la información sin verse afectadas por valores extremos.



Cuantiles

Los cuantiles son valores que dividen un conjunto de datos ordenados en partes iguales.

Tipos de cuantiles más comunes:

Percentiles

Dividen los datos en 100 partes iguales.

100

Deciles

Dividen los datos en 10 partes iguales.

10

Cuartiles

Dividen los datos en 4 partes iguales.

4

Cuartiles



Q1 o primer cuartil o cuartil inferior.
El 25% de los datos son menores o iguales a él.



Q2 o segundo cuartil (La Mediana).
Divide al conjunto en dos mitades iguales.




Q3 o tercer cuartil o cuartil superior.
El 75% de los datos son menores o iguales a él.

Q1
(percentile 25)

Q2
(percentile 50)

Q3
(percentile 75)

18
19
19
20
21
21
21
21
24
24
25
26
26
26
27
29
30
32
34
34



Estadística robusta: tendencia central

Medidas robustas de tendencia central:

Mediana

Valor central de los datos.


- Es el Q2.

	18
	19
	19
	20
Q1 (percentile 25)	21
	21
	21
	21
Q2 (percentile 50)	24
	25
	26
	26
	26
Q3 (percentile 75)	27
	29
	30
	32
	34
	34

Media recortada (trimmed mean)

La media recortada de nivel α se obtiene promediando los datos situados entre los percentiles α y $100-\alpha$.

OLIMPIADAS: SISTEMA DE Puntuación DE CLAVADOS




Estadística robusta: dispersión

Medidas robustas de dispersión:


IQR (Rango Intercuartil)

Diferencia entre Q1 y el Q3



MAD (Median Absolute Deviation)

$$MAD = \text{mediana} (|x_i - \text{mediana}(x)|)$$



¿Cómo decidimos cuál usar?

Rango intercuartil (IQR)

	18
	19
	19
	20
Q1 (percentile 25)	21
	21
	21
	21
Q2 (percentile 50)	24
	24
	25
	26
	26
	26
Q3 (percentile 75)	27
	29
	30
	32
	34
	34

IQR
(Q3 - Q1)

IQR o rango intercuartil
contiene al 50 % central
de los datos

Ejemplo:


Q1 = 21
Q2 = 24,5
Q3 = 28
IQR = 28 - 21 = 7
rango total = 34 - 18 = 16

¿Y ese 7 es mucho o poco? ¿Nuestros datos están bien o no?

Rango intercuartil (IQR)

El tamaño del IQR indica si los datos están concentrados o dispersos.





El IQR se considera pequeño si es menor al 20% del rango total (máx - mín).



Relación entre variables numéricas: covarianza

La covarianza mide cómo dos variables numéricas cambian juntas.

Solo indica dirección, no intensidad, por eso es difícil de interpretar directamente




$$\text{Cov}(X, Y) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n}$$

rango

$(-\infty, +\infty)$

Relación entre variables numéricas: covarianza

Interpretación:



Relación entre var. numéricas: correlación de Pearson

La correlación de Pearson es una medida de la relación **lineal** entre dos **variables numéricas**. Da una idea de la fuerza y la dirección de esa relación.

La **correlación es la covarianza “escalada”**, lo que hace que sea comparable entre distintos datasets.


Coefficiente de correlación de Pearson para n muestras

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

rango


$[-1, +1]$

Correlación Negativa
Perfecta




$r_{xy} = -1$

Correlación Negativa
Fuerte




$r_{xy} = -0,9$

Correlación Negativa
Débil




$r_{xy} = -0,2$

Correlación Nula




$r_{xy} = 0$

Correlación Positiva
Débil




$r_{xy} = 0,2$

Correlación Positiva
Fuerte



$r_{xy} = 0,9$

Correlación Positiva
Perfecta



$r_{xy} = 1$

Relación entre var. numéricas: correlación de Pearson



⚠ IMPORTANTE!

- La correlación no distingue cuál es la variable dependiente y cuál la independiente.
- La correlación de la muestra no indica nada acerca de su validez para la población de los datos.

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

¿Cuál es el problema con este método?

Relación entre var. numéricas: corr. de Spearman

La correlación de Spearman detecta la relación **monótona** (no necesariamente lineal) entre dos variables numéricas.

Se basa en rangos, no en valores directos.
Da una idea de la fuerza y la dirección de la relación monótona entre variables.



Coeficiente de correlación de Spearman para n muestras.

- “ d_i ” son las diferencias entre rankings

Fórmula clásica
$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

Fórmula general
(cuando hay empates)
$$r_s = \text{corr}(R_x, R_y)$$

rango

$$[-1, +1]$$

Ejemplo: correlación de Spearman

Medimos el tiempo de reacción de 8 jugadores (de videojuegos) y les preguntamos su edad.



	
12	14
15	25
17	20
18	35
20	45
21	30
22	60
26	95

d es la **diferencia de rangos** entre las dos variables.

$$r_s = 1 - \frac{6 \cdot \sum d_i^2}{n \cdot (n^2 - 1)}$$

n es el **número de casos**

Valor r_s	Fuerza de la correlación
0,0 – 0,1	no hay correlación
0,1 – 0,3	correlación baja
0,3 – 0,5	correlación media
0,5 – 0,7	correlación alta
0,7 – 1,0	correlación muy alta

		d	d^2
12	14	1-1 = 0	0
15	25	2-3 = -1	1
17	20	3-2 = 1	1
18	35	4-5 = -1	1
20	45	5-6 = -1	1
21	30	7-4 = 2	4
22	60	7-7 = 0	0
26	95	8-8 = 0	0
			$\Sigma 8$

$$r_s = 1 - \frac{6 \cdot \sum d_i^2}{n \cdot (n^2 - 1)}$$

$$r_s = 1 - \frac{6 \cdot \sum d_i^2}{n \cdot (n^2 - 1)} = 1 - \frac{48}{504} = 0.90$$

¿Qué sucede si tenemos empate? Varias personas con el mismo tiempo o edad

Ejemplo: correlación de Spearman

Medimos el tiempo de reacción de 8 jugadores (de videojuegos) y les preguntamos su edad. Tenemos un empate para las edades de 20 años.

~~Fórmula clásica~~ ~~$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$~~

Sólo para números enteros

Fórmula general
(cuando hay empates)

$$r_s = \text{corr}(R_x, R_y)$$

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

							
	12	1	14	1	$= \frac{2 + 3}{2} = 2,5$	14	1
	15	2	20	3		20	2,5
	17	3	20	2		20	2,5
	18	4	35	5		35	5
	20	5	45	6		45	6
	21	6	30	4		30	4
	22	7	60	7		60	7
	26	8	95	8		95	8

Los puestos 2 y 3 "desaparecen"

Utilizamos la fórmula de Pearson con los valores de ranking

Relación entre var. numéricas: correlación de Kendall

La correlación de Kendall **compara pares de observaciones** y mira si el orden relativo entre ellos se mantiene.

Da una idea de qué proporción de pares está bien ordenada.

Se basa en rangos, no en valores directos.



Jugador A: "Yo soy mayor que vos, ¿también tardo más tiempo en reaccionar?"

Jugador B: "Sí, yo soy más joven y reaccioné más rápido"

Jugador B: "No, yo soy más joven pero reaccioné más lento que vos"

Coeficiente de correlación de Kendall para n muestras

Fórmula clásica $\tau = \frac{C-D}{\frac{n(n-1)}{2}}$

Fórmula general (cuando hay empates) $\tau_b = \frac{C-D}{\sqrt{(C+D+T_x)(C+D+T_y)}}$

- C = # de pares concordantes
- T_x : empates en X
- D = # de pares discordantes
- T_y : empates en Y

rango

$$[-1, +1]$$

Ejemplo: correlación de Kendall

⤴	⌚
1	1
2	3
3	2
4	4

Pares Concordantes (C): 5

Pares Discordantes (D): 1

Total de parejas posibles

$$\frac{n(n-1)}{2} = \frac{4 \times 3}{2} = 6 \text{ pares}$$

Aplicamos Kendall

rango

$[-1, +1]$

$$\tau = \frac{C - D}{\text{Total de pares}} \quad \tau = \frac{5 - 1}{6} = \frac{4}{6} \approx 0.67$$

$$\tau = 0.67$$


Indica una fuerte correlación **positiva**

Ejemplo: correlación de Kendall con empate

Kendall resuelve los empates con una lógica brillante y simple: la **anulación**.

Si dos valores empatan, no hay ni acuerdo ni desacuerdo. Ese cruce se declara nulo (empate), no suma puntos ni para C ni para D, y solo se anota en un contador aparte para ajustar el puntaje final

Personas	Edad	Tiempo
1	1	1
2	3	3
3	3	3
4	4	4



Total de parejas posibles

$$\frac{n(n-1)}{2} = \frac{4 \times 3}{2} = 6 \text{ pares}$$

Pares Concordantes (C): 5

Pares Discordantes (D): 0

Empate en Edad (Tx): 0

Empate en Tiempo (Ty): 1

Aplicamos Kendall

rango
[-1, +1]


$$\tau_b = \frac{C - D}{\sqrt{(C + D + T_x)(C + D + T_y)}}$$

$$\tau_b = \frac{5 - 0}{\sqrt{(5 + 0 + 0)(5 + 0 + 1)}}$$

$$\tau_b = \frac{5}{\sqrt{5 \times 6}} = \frac{5}{\sqrt{30}} \approx 0.91$$

Relación entre variables numéricas: comparación de métodos de correlación




CARACTERÍSTICA	PEARSON	SPEARMAN	KENDALL
Asume distribución normal	✓ Sí	✗ No	✗ No
Robusto a outliers	✗ No	✓ Sí	✓ Sí
Útil cuando ...	 La relación es lineal.	 La relación es monótona (creciente o decreciente).	 Hay pocos datos. Las variables tienen valores repetidos (empates).



Ayuda Memoria

¿Qué es Monótona? Una relación que siempre va en la misma dirección (sube o baja).

¿Por qué Pearson falla en Outliers? Porque las distancias se elevan al cuadrado, dando un peso excesivo a los valores extremos.





Relación entre var. numéricas: matriz de correlación

Es una matriz cuadrada que contiene los coeficientes de correlación entre todas las parejas de **variables numéricas** de un conjunto de datos.

Resume las relaciones lineales (o monotónicas, según el método) entre pares de variables.

Propiedades:

- Es simétrica.
- Sus valores están en el rango $[-1, 1]$.
- La diagonal es siempre 1 (cada variable consigo misma).





Google Colab



Ejemplo en Python

03_analisis_exploratorio_datos_edat01_correlacion.ipynb



Variables categóricas

Las variables categóricas se pueden describir a partir de cantidades, proporciones y porcentajes de los distintos valores o categorías.




Medidas de concentración de categorías

Moda: valor más frecuente

Proporción de la moda: qué proporción del total está representado por la moda.

Multimodalidad: permite detectar si la distribución está dominada por una sola categoría.




Medidas de distribución y frecuencia

Frecuencia absoluta: número de veces que aparece cada categoría.

Frecuencia relativa: proporción de cada categoría respecto al total de observaciones.


Rango de frecuencias: diferencia entre la categoría más frecuente y la menos frecuente.



Entropía de Shannon

La **incertidumbre de Shannon** o entropía de Shannon mide la incertidumbre asociada a una fuente de información.

En el caso de variables categóricas, refleja el grado de uniformidad en la distribución de frecuencias relativas.



Entropía de Shannon

- p_i : proporción de la categoría i (frecuencia relativa de la categoría).
- n : número de categorías (cardinalidad)

$$H(X) = - \sum_{i=1}^n p_i \log_2(p_i)$$




rango

$$[0, \log_2(n)]$$


Entropía de Shannon: Variables Categóricas

En variables categóricas, la entropía mide cuán dispersa o uniforme es la distribución de frecuencias.


- **Mayor entropía:** más incertidumbre sobre a qué categoría pertenece una observación elegida al azar. Las categorías están equilibradas o bien distribuidas.
- **Menor entropía:** hay poca incertidumbre. Una o pocas categorías dominan al resto.
- **Entropía máxima:** se da cuando todas las categorías son igualmente probables.



Low Entropy



High Entropy



Visualización: Distribución de una variable numérica

Distribución de una variable


- Datos numéricos
- Datos categóricos

Relación entre dos variables


- Numérica-numérica
- Numérica-categórica
- Categórica-categórica

Relaciones multivariadas


1. DISTRIBUCIÓN DE FRECUENCIA (HISTOGRAMA)




2. ESTIMACIÓN DE DENSIDAD DE KERNEL (KDE)




3. DIAGRAMA DE CAJA (BOXPLOT)



4. DIAGRAMA DE VIOLÍN (VIOLIN PLOT)



5. DIAGRAMA DE ENJAMBRE (SWARMPLOT)



Visualización: Distribución de una variable categórica

Para complementar las métricas, es recomendable usar diferentes visualizaciones

ANÁLISIS DE FECUNDIDAD Y ACTIVIDAD SOCIOECONÓMICA EN MUJERES (14-49 AÑOS)

Censo Nacional de Población, Hogares y Viviendas 2022. Resultados **Definitivos**.

VISUALIZACIÓN DE FRECUENCIA



GRÁFICOS DE BARRAS O COUNTPLOTS:

Muestran la frecuencia de cada categoría.

Mujeres con hijos/as que asisten a educación
(por cada mil), según nivel educativo



Gráfico 15. Fuente: INDEC, Censo 2022

VISUALIZACIÓN DE PROPORCIONES



GRÁFICOS DE TORTA: Explican las proporciones relativas y la composición.

Condición de actividad según maternidad (porcentajes)




Gráfico 17. Fuente: INDEC, Censo 2022

Fuente: INDEC, Censo Nacional de Población, Hogares y Viviendas 2022. Resultados Definitivos. | [Fuente: Fecundidad - Censo Nacional](#)


Relación entre dos variables numéricas

Scatterplot




Relación entre una variable numérica y una categórica

Boxplots del largo de la aleta para cada especie



Relación entre una variable numérica y una categórica

Violin plot del largo de la aleta de los pingüinos para cada especie



Otros:

- Gráficos de barra
- Strip / swarm plots

Relación entre dos variables categóricas

Tabla de contingencia o Cross-tab

Cuadro 2.5. Provincia del Chubut. Población en viviendas particulares por sexo, según departamento. Año 2022

Departamento	Total ⁽¹⁾	Sexo		
		Mujer / Femenino	Varón / Masculino	X / Ninguna de las anteriores
Total	599.612	305.364	294.169	79
Biedma	106.092	53.706	52.333	53
Cushamen	28.067	14.196	13.870	1
Escalante	218.520	111.060	107.441	19
Florentino Ameghino	1.792	858	934	-
Futaleufú	50.403	26.247	24.155	1
Gaiman	12.594	6.342	6.252	-
Gastre	1.313	567	745	1
Languiñeo	2.905	1.394	1.510	1
Mártires	746	316	430	-
Paso de Indios	1.877	869	1.008	-
Rawson	146.620	75.848	70.770	2
Río Senguer	6.466	3.097	3.368	1
Sarmiento	14.575	7.203	7.372	-
Tehuelches	5.976	2.889	3.087	-
Telsen	1.666	772	894	-


⁽¹⁾ Incluye la población en situación de calle censada en la vía pública.

Fuente: INDEC, Censo Nacional de Población, Hogares y Viviendas 2022. Resultados provisionales.

Relación entre dos variables categóricas

Matriz de contingencia con Heatmap o mapa de calor

Número de pingüinos de cada especie en función de la isla donde habitan



Penguins in Palmer Archipelago

Recorded penguins in 2009 and their nesting islands




Otros:

- Gráficos de barra agrupadas (comparación)
- Gráficos de barra apiladas (proporciones)

Relaciones multivariadas

Scatterplot dos variables numéricas y una categórica (hue)




Otros:


- **Scatterplot con tamaño:** tercera variable numérica
- **Pairplot:** scatterplot de numéricas + categórica (hue)
- **Heatmap:** tercera variable numérica (ej: correlación)

Diagramas comparativos

Ejemplo: pirámides poblacionales



Pirámide poblacional de personas nacidas en Venezuela que residen en Argentina con DNI con proceso digital. Total país. Agosto 2022.



Pirámide poblacional de personas nacidas en Italia que residen en Argentina con DNI con proceso digital. Total país. Agosto 2022

Resumen

Variables numéricas

Tendencia central

Media: valor promedio.

Mediana: en un conjunto ordenado de números, es el valor que se encuentra en el medio.

Moda: valor más frecuente.

Dispersión

Varianza: dispersión de los datos con respecto a la media. Promedia diferencias al cuadrado.

Desviación estándar: dispersión con respecto a la media pero en las mismas unidades que los datos.

Cuartiles y rango intercuartil (IQR): otra forma de cuantificar dispersión de los datos.

Forma

Asimetría (skewness): forma de los datos; qué tan simétrica es la distribución respecto a su media.

Curtosis: concentración de datos extremos (presencia de colas más pronunciadas o aplanadas).

Resumen

Medidas basadas en momentos

orden	medida	fórmula	qué información captura
1	media	$\mu = \frac{1}{n} \sum_{i=1}^n x_i$	Centro Es el punto de equilibrio de los datos.
2	varianza	$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$	Dispersión Mide qué tan lejos están los datos de la media.
3	asimetría	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^3}{\sigma^3}$	Sesgo Mide si la distribución está sesgada hacia la izquierda o derecha.
4	curtosis	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^4}{\sigma^4}$	Extremos Mide la "pesadez" de las colas de la distribución.

Resumen

Relación entre variables

medida	fórmula	qué información captura
correlación de Pearson	$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$	Fuerza y dirección de la relación lineal entre dos variables (basada en valores).
correlación de Spearman	$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$	Fuerza y dirección de la relación monótona entre dos variables (basada en rankings).
correlación de Kendall	$\tau_b = \frac{C - D}{\sqrt{(C + D + T_x)(C + D + T_y)}}$	Grado de consistencia en el orden entre pares de observaciones (basada en rankings).

Resumen

Variables categoricas

Concentración de categorías

Moda: Valor más frecuente.

Proporción de la moda: Qué proporción del total está representado por la moda.

Multimodalidad. Permite detectar si la distribución está dominada por una sola categoría.

Distribución y frecuencia

Frecuencia absoluta: Número de veces que aparece cada categoría.

Frecuencia relativa: Proporción de cada categoría respecto al total de observaciones.

Rango de frecuencias: Diferencia entre la categoría más frecuente y la menos frecuente.

Diversidad o variabilidad

Cardinalidad: número de categorías únicas.

Entropía de Shannon: medida de incertidumbre o diversidad de la distribución.



Google Colab

Ejemplo en Python

02_analisis_exploratorio_datos\03_edatitanic.ipynb



Actividad individual opcional

Objetivo

Seleccionar uno de los sets de datos disponibles [aquí](#).

Consigna

Realizar un EDA básico del dataset seleccionado:

- estadística descriptiva
- tipos de variables
- relaciones entre variables
- incluir al menos 3 gráficos

Guardarlo en un repositorio de acceso público o en una notebook de Google Colab. Lo importante es que el código esté ejecutado (que muestre la salida).

En algunos casos, los datasets tienen más de 2000 filas. Pueden trabajar con todo el dataset o extraer una muestra.


Se pueden apoyar en las notebooks dadas en clase, o pueden crear su propio código.



Entrega	Estado	Puntos
No	-	0
Si	No cumple con la consigna	0
Si	Si cumple con la consigna	1

¡Gracias!

¿Consultas?



Ing. González H. Alexis