

Inteligencia Artificial

EDA - Causas e Identificación de faltantes

Ing. González H. Alexis



Tabla de Contenidos

01

Active Recall

Repaso del tema anterior

02

Main Content

Test estadísticos y medidas de asociación.
Causas de valores faltantes.
Identificación de faltantes y outliers


03

Live Coding Pair Programming

Ejercitación & Feedback

01

Active Recall



Resumen

Variables numéricas

Tendencia central

Media: valor promedio.

Mediana: en un conjunto ordenado de números, es el valor que se encuentra en el medio.

Moda: valor más frecuente.

Dispersión

Varianza: dispersión de los datos con respecto a la media. Promedia diferencias al cuadrado.

Desviación estándar: dispersión con respecto a la media pero en las mismas unidades que los datos.

Cuartiles y rango intercuartil (IQR): otra forma de cuantificar dispersión de los datos.

Forma

Asimetría (skewness): forma de los datos; qué tan simétrica es la distribución respecto a su media.

Curtosis: concentración de datos extremos (presencia de colas más pronunciadas o aplanadas).

Resumen

Medidas basadas en momentos

orden	medida	fórmula	qué información captura
1	media	$\mu = \frac{1}{n} \sum_{i=1}^n x_i$	Centro Es el punto de equilibrio de los datos.
2	varianza	$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$	Dispersión Mide qué tan lejos están los datos de la media.
3	asimetría	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^3}{\sigma^3}$	Sesgo Mide si la distribución está sesgada hacia la izquierda o derecha.
4	curtosis	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^4}{\sigma^4}$	Extremos Mide la "pesadez" de las colas de la distribución.

Resumen

Relación entre variables

medida	fórmula	qué información captura
correlación de Pearson	$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$	Fuerza y dirección de la relación lineal entre dos variables (basada en valores).
correlación de Spearman	$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$	Fuerza y dirección de la relación monótona entre dos variables (basada en rankings).
correlación de Kendall	$\tau_b = \frac{C - D}{\sqrt{(C + D + T_x)(C + D + T_y)}}$	Grado de consistencia en el orden entre pares de observaciones (basada en rankings).

Resumen

Variables categoricas

Concentración de categorías

Moda: Valor más frecuente.

Proporción de la moda: Qué proporción del total está representado por la moda.

Multimodalidad. Permite detectar si la distribución está dominada por una sola categoría.

Distribución y frecuencia

Frecuencia absoluta: Número de veces que aparece cada categoría.

Frecuencia relativa: Proporción de cada categoría respecto al total de observaciones.

Rango de frecuencias: Diferencia entre la categoría más frecuente y la menos frecuente.

Diversidad o variabilidad

Cardinalidad: número de categorías únicas.

Entropía de Shannon: medida de incertidumbre o diversidad de la distribución.



© gonzalezhalexis@gmail.com ©

Test de hipótesis

¿Qué es un test de hipótesis?

Es una manera formal de elegir entre dos hipótesis, diseñado para evaluar si un efecto observado en los datos es real o es simplemente producto del azar.

Ejemplo cotidiano: Un juicio

En el sistema judicial, al igual que en la estadística, nos enfrentamos a la toma de una decisión bajo incertidumbre con dos hipótesis posibles:

- **Supuesto de inocencia:** La persona es inocente hasta que se demuestre lo contrario.
- **Hipótesis alternativa:** La persona es culpable.

El objetivo del juicio no es "probar la inocencia", sino recolectar evidencias suficientes para rechazarla.



El veredicto de los datos

Siempre existe la posibilidad de que aparezca una prueba extraña por pura casualidad o azar.

Sin embargo, si las evidencias acumuladas son abrumadoras, la explicación de "todo es azar" deja de ser creíble.

Resultado: Se rechaza la inocencia y se declara la culpabilidad.

Test de hipótesis

¿Qué es un test de hipótesis?

Es una manera formal de elegir entre dos hipótesis, diseñado para evaluar si un efecto observado en los datos es real o es simplemente producto del azar.

Ejemplo cotidiano: Un juicio

el test

En el sistema judicial, al igual que en la estadística, nos enfrentamos a la toma de una decisión bajo incertidumbre con dos hipótesis posibles:

- **Supuesto de inocencia:** La persona es inocente hasta que se demuestre lo contrario. **hipótesis nula**
- **Hipótesis alternativa:** La persona es culpable.

hipótesis alternativa

El objetivo del juicio no es "probar la inocencia", sino recolectar evidencias suficientes para rechazarla.

↑
datos



El veredicto de los datos

Siempre existe la posibilidad de que aparezca una prueba extraña por pura casualidad o azar.

Sin embargo, si las evidencias acumuladas son abrumadoras, la explicación de "todo es azar" deja de ser creíble.

Resultado: Se rechaza la inocencia y se declara la culpabilidad.

Test de hipótesis ¿Cuáles son los pasos?

1. Planteamiento

Traducimos la pregunta de investigación en dos hipótesis contrarias:

H_0 (Nula): Afirmación que se pone a prueba de forma conservadora.

H_1 (Alternativa): Lo que se desea demostrar si hay evidencia suficiente.

2. Evidencia

Recolectamos una muestra representativa de datos para analizar.

Resumimos esta información mediante una función matemática llamada **estadístico de prueba**.

3. El p-valor

Asumiendo que la hipótesis nula (H_0) es cierta, calculamos la probabilidad de obtener un resultado tan o más extremo.

Esta métrica evalúa la **compatibilidad** de los datos con H_0 .

4. Decisión

Comparamos el p-valor contra un nivel de significancia prefijado:

Si es menor: Rechazamos la hipótesis nula a favor de la alternativa.

Si no: No la rechazamos, atribuyendo el efecto al azar.

Test de hipótesis. Ejemplo

Paso 1: Planteamiento del test de hipótesis

a) Hipótesis del Test

H_0 (Hipótesis Nula)

El peso promedio de los bebés es igual a 3 kg.

$$H_0 : \mu = 3 \text{ kg}$$

H_1 (Hipótesis Alternativa)

El peso promedio de los bebés es diferente de 3 kg.

$$H_1 : \mu \neq 3 \text{ kg}$$

b) Nivel de Significancia

Definimos el límite de tolerancia para el error de tipo I (probabilidad de rechazar H_0 siendo esta verdadera).

Significancia (α)

$$\alpha = 0.05$$

Equivale a un nivel de confianza del 95% para la toma de decisiones.

Test de hipótesis. Ejemplo

Paso 1: Planteamiento del test de hipótesis → Paso 2: Calculamos el estadístico



Antes de calcular el estadístico, tenemos que recolectar evidencia y decidir cuál es el estadístico de test que vamos a utilizar.

a) Recolectamos evidencia

Datos:

Ejemplo 1

ID	1	2	3	4
PESO	3,8	3,7	3,9	2,8

Ejemplo 2

ID	1	2	3	4
PESO	2,9	3,1	3,1	4,9

Ejemplo 3

ID	1	2	3	4
PESO	1,9	3,1	3,1	4

Test de hipótesis. Ejemplo



Paso 1: Planteamiento del test de hipótesis → Paso 2: Calculamos el estadístico

b) Selección del Estadístico

El estadístico de prueba depende directamente del test de hipótesis utilizado.

Este se elige cuidadosamente en función de:

- El problema particular planteado.
- Características de los datos (normalidad, independencia, tamaño de la muestra, varianza conocida o desconocida, etc.).

I. El problema:

Evaluar si la media poblacional es igual a 3.

II. Características de los datos:

Muestra aleatoria, observaciones independientes, población normal, desviación estándar desconocida y tamaño muestral pequeño.

III. Tipo de test:

Al ser la desviación estándar poblacional desconocida y la muestra pequeña, se utiliza un **test t de Student** para una media.

En el test t de Student se utiliza el estadístico t.

$$t = \frac{\bar{x} - \mu}{s/\sqrt{n}}$$

Test de hipótesis. Ejemplo

Paso 2: Calculamos el estadístico

Ya tenemos la evidencia (datos)
y ya definimos el estadístico (t)

$$t = \frac{\overline{x} - \mu}{s/\sqrt{n}} = \frac{\overline{x} - 3}{s/\sqrt{n}}$$

$$H_0 : \mu = 3$$

$$H_1 : \mu \neq 3$$

Muestras de Datos:

 Ejemplo 1

ID	1	2	3	4
PESO	3,8	3,7	3,9	2,8

 Ejemplo 2

ID	1	2	3	4
PESO	2,9	3,1	3,1	4,9

 Ejemplo 3

ID	1	2	3	4
PESO	1,9	3,1	3,1	4

❓ ¿Hay suficiente evidencia para rechazar la hipótesis nula?

Test de hipótesis. Ejemplo

Paso 2: Calculamos el estadístico

$$t = \frac{\bar{x} - \mu}{s/\sqrt{n}} = \frac{\bar{x} - 3}{s/\sqrt{n}} \quad \begin{matrix} H_0 : \mu = 3 \\ H_1 : \mu \neq 3 \end{matrix}$$

Ejemplo 1

ID	1	2	3	4
PESO	3,8	3,7	3,9	2,8

La mayoría de los valores están lejos de 3 kg.

$$t = \frac{3,55 - 3}{0,5/2} \approx 2,2$$

Ejemplo 2

ID	1	2	3	4
PESO	2,9	3,1	3,1	4,9

La diferencia depende de una sola observación, que podría deberse al azar.

$$t = \frac{3,5 - 3}{0,93/2} \approx 1,08$$

Ejemplo 3

ID	1	2	3	4
PESO	1,9	3,1	3,1	4

Los datos son muy variables.

$$t = \frac{3,025 - 3}{0,86/2} \approx 0,06$$

Test de hipótesis. Ejemplo



Paso 3: Calculamos el p-valor

¿Cuál es la probabilidad de observar t suponiendo H_0 verdadera?

El p-valor puede calcularse con Python o aproximarse usando tablas de la distribución t de Student.

$$H_0 : \mu = 3$$

$$H_1 : \mu \neq 3$$

Ejemplo 1

ID	1	2	3	4
PESO	3,8	3,7	3,9	2,8

La mayoría de los valores están lejos de 3 kg.

$$t \approx 2,2$$

t está relativamente lejos de 0. Hay evidencia contra H_0 , **pero no es suficiente**

$$p - \text{valor} \approx 0,115$$

Ejemplo 2

ID	1	2	3	4
PESO	2,9	3,1	3,1	4,9

La diferencia depende de una sola observación, que podría deberse al azar.

$$t \approx 1,08$$

t no es tan extremo porque, aunque la media supera a 3, la variabilidad es grande.

$$p - \text{valor} \approx 0,359$$

Ejemplo 3

ID	1	2	3	4
PESO	1,9	3,1	3,1	4

Los datos son muy variables.

$$t \approx 0,06$$

t es casi cero y los datos son compatibles con la hipótesis nula.

$$p - \text{valor} \approx 0,956$$

Test de hipótesis. Ejemplo

Paso 4: Tomamos una decisión

En los tres casos p -valor $> 0,05$.

Por lo tanto, **no se rechaza la hipótesis nula H_0** . No hay evidencia suficiente para concluir que la media poblacional sea distinta de 3.

$$H_0 : \mu = 3$$

$$H_1 : \mu \neq 3$$

Ejemplo 1

ID	1	2	3	4
PESO	3,8	3,7	3,9	2,8

La mayoría de los valores están lejos de 3 kg.

$$t \approx 2,2$$

t está relativamente lejos de 0. Hay evidencia contra H_0 , **pero no es suficiente**

$$p - \text{valor} \approx 0,115$$

Ejemplo 2

ID	1	2	3	4
PESO	2,9	3,1	3,1	4,9

La diferencia depende de una sola observación, que podría deberse al azar.

$$t \approx 1,08$$

t no es tan extremo porque, aunque la media supera a 3, la variabilidad es grande.

$$p - \text{valor} \approx 0,359$$

Ejemplo 3

ID	1	2	3	4
PESO	1,9	3,1	3,1	4

Los datos son muy variables.

$$t \approx 0,06$$

t es casi cero y los datos son compatibles con la hipótesis nula.

$$p - \text{valor} \approx 0,956$$

Test de hipótesis – La lógica del procedimiento

1. Planteamiento

Traducimos la pregunta de investigación en dos hipótesis contrarias:

H_0 (Nula): Afirmación que se pone a prueba de forma conservadora.

H_1 (Alternativa): Lo que se desea demostrar si hay evidencia suficiente.

H_0 hipótesis nula
 H_1 hipótesis alternativa

2. Evidencia

Recolectamos una muestra representativa de datos para analizar.

Resumimos esta información mediante una función matemática llamada **estadístico de prueba**.

El estadístico está diseñado de manera que cuanto más alejado de 0, más fuerte es la evidencia contra H_0 .

3. El p-valor


¿Cuál es la probabilidad de observar una evidencia al menos tan extrema como la obtenida, suponiendo $H_0 = V$? (**p-valor**)

El p-valor se calcula a partir del valor del estadístico y su distribución. Cada estadístico sigue una distribución conocida cuando H_0 es verdadera.

$P(\text{estadístico} \mid \text{hipótesis nula})$


4. Decisión

La **significancia** es un umbral que define el máximo riesgo que estamos dispuestos a aceptar de equivocarnos (es decir, de rechazar H_0 cuando en realidad es verdadera).



No rechazar H_0 no es lo mismo que aceptar H_0

Test de chi-cuadrado de independencia



¿Qué es?

El test de chi-cuadrado de independencia es un test de hipótesis para determinar si hay una relación entre dos **variables categóricas nominales**.

Ejemplo Práctico

Para saber si existe una asociación significativa entre el **nivel educativo** y el **medio de transporte** preferido, realizamos este análisis.

Test de chi-cuadrado de independencia


Supuestos Básicos

- Las observaciones son **independientes**.
- Las categorías son **mutuamente excluyentes**.


Regla de Cochran (Validez)

- Al menos el **80%** de las frecuencias esperadas deben ser ≥ 5 .
- **Ninguna** frecuencia esperada debe ser **menor a 1**.

Datos observados




Datos esperados



Test de chi-cuadrado de independencia

Ejemplo Práctico: Queremos determinar si existe una asociación significativa entre el nivel educativo y el medio de transporte preferido.



Paso 1: Test de Hipótesis

H₀ (Nula): No hay relación entre el nivel educativo y el medio de transporte.

H₁ (Alternativa): Hay relación entre el nivel educativo y el medio de transporte.

Nivel de significancia: $\alpha = 0,01$

El Estadístico

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$



O_i: Frecuencias observadas

E_i: Frecuencias esperadas

Test de chi-cuadrado de independencia

Paso 2: Calculamos el estadístico

El estadístico chi-cuadrado mide qué tan diferentes son los datos observados respecto a los esperados, si las variables fueran independientes.

Datos observados:



Nivel educativo	Auto propio	Transporte público	Bicicleta / Caminando	Total
Secundario	45	80	25	150
Universitario	70	40	30	140
Total	115	120	55	290

Datos esperados:

$$E = \frac{TotalFila \times TotalCol}{Total}$$



Nivel educativo	Auto propio	Transporte público	Bicicleta / Caminando	Total
Secundario	59	62	28	150
Universitario	56	58	27	140
Total	115	120	55	290

Residuos

Nivel educativo	Auto propio	Transporte público	Bicicleta / Caminando
Secundario	3,32	5,22	0,32
Universitario	3,50	5,59	0,33

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i} = 18,28$$

- **H₀:** No hay relación entre las variables.
- **H₁:** Hay relación entre las variables.

Test de chi-cuadrado de independencia

Paso 3: Calculamos el p-valor

El p-valor puede calcularse con Python o aproximarse usando tablas de la distribución chi-cuadrado.

$$p - valor = P(\chi^2 = 18,28 | H_0)$$

En este ejemplo:

- El p-valor obtenido es $\approx 0,00011$.
- Es muy improbable observar esta evidencia (chi-cuadrado = 18,28) si asumimos que la hipótesis nula es cierta.

Paso 4: Interpretación y decisión


Decisión Estadística

Como p-valor ($0,00011$) $< 0,01$ (nivel de significancia), se rechaza la hipótesis nula (H_0).

Conclusión Práctica

Existe una relación significativa entre el nivel educativo y el medio de transporte que las personas eligen.

Test Anova




¿Qué es ANOVA?

El **Análisis de Varianza** es una técnica estadística que permite evaluar si una variable numérica difiere significativamente según los valores de una variable categórica.

Ejemplo Práctico

Por ejemplo, si queremos ver si el **peso corporal promedio** difiere significativamente entre las tres especies de la gráfica, realizamos un ANOVA.


Test Anova



Supuestos del ANOVA

- **Independencia**
Los valores observados deben ser independientes entre sí.
- **Normalidad**
Los datos de cada grupo deben seguir una distribución normal.
- **Homogeneidad**
Las varianzas entre las distintas clases deben ser iguales.

Test Anova



Planteamos el test de hipótesis

Hipótesis nula (H_0): el peso corporal promedio de todas las especies es igual: $\mu_1 = \mu_2 = \dots = \mu_k$

Hipótesis alternativa (H_1): al menos una especie tiene peso promedio diferente.

Nivel de significancia: $\alpha=0,05$


El estadístico de prueba (F)

$$F = \frac{\text{variabilidad entre grupos}}{\text{variabilidad intra grupos}} = \frac{\frac{\sum n_i (\bar{x}_i - \bar{x})^2}{k-1}}{\frac{\sum \sum (x_{ij} - \bar{x}_i)^2}{N-k}}$$

Test Anova

Visualización de los Datos

Cada círculo representa un pingüino. Los colores indican la especie a la que pertenecen, permitiendo comparar visualmente sus pesos (kg).



Formulación de Hipótesis

Hipótesis Nula (H_0): $\mu_1 = \mu_2 = \dots = \mu_k$
(El peso promedio es igual en todas las especies)


Hipótesis Alternativa (H_1): Al menos una especie tiene un peso promedio diferente.

Estadístico de Prueba (F)

F mide qué tan diferentes son las medias de los grupos respecto a lo esperado si todas fueran iguales.

$$F = ???$$

Test Anova



Formulación de Hipótesis

Hipótesis Nula (H_0): $\mu_1 = \mu_2 = \dots = \mu_k$

(El peso promedio es igual en todas las especies)


Hipótesis Alternativa (H_1): Al menos una especie tiene un peso promedio diferente.

Variabilidad entre grupos

$$\frac{\sum n_i (\bar{x}_i - \bar{x})^2}{k - 1}$$

k: número de grupos

Test Anova



Formulación de Hipótesis

Hipótesis Nula (H_0): $\mu_1 = \mu_2 = \dots = \mu_k$

(El peso promedio es igual en todas las especies)

Hipótesis Alternativa (H_1): Al menos una especie tiene un peso promedio diferente.

Variabilidad intra grupos

$$\frac{\sum \sum (x_{ij} - \bar{x}_i)^2}{N - k}$$


N: total de observaciones

k: número de grupos

Test Anova

Visualización de los Datos

Cada círculo representa un pingüino. Los colores indican la especie a la que pertenecen, permitiendo comparar visualmente la distribución de sus pesos (kg) a lo largo del eje.



Formulación de Hipótesis

Hipótesis Nula (H_0): $\mu_1 = \mu_2 = \dots = \mu_k$

(El peso promedio es igual en todas las especies)

Hipótesis Alternativa (H_1): Al menos una especie tiene un peso promedio diferente.

Estadístico de prueba (F)

$$F = \frac{\text{variabilidad entre grupos}}{\text{variabilidad intra grupos}} = \frac{\frac{\sum n_i (\bar{x}_i - \bar{x})^2}{k - 1}}{\frac{\sum \sum (x_{ij} - \bar{x}_i)^2}{N - k}}$$

Interpretación:

F $\approx$ 1: No hay diferencias significativas entre grupos.

F grande: Existen diferencias significativas.



Test de hipótesis. Ejemplos



TEST	PROPÓSITO	EJEMPLO	ESTADÍSTICO
Z-test	Comparar una media con un valor conocido (n grande)	¿El promedio de peso de los bebés nacidos en el hospital es 3,2 kg? ¿El promedio de vida útil de las lamparitas es de 800 horas?	Z
t de Student	Comparar 1 o 2 medias	1 media: ¿El peso promedio de los paquetes es de 500 gramos como dice el paquete? 2 medias: ¿Los autos de marca A consumen menos combustible en promedio que los de marca B?	t
Chi-Cuadrado	Ver si dos variables categóricas son independientes	¿Existe relación entre el nivel educativo y el nivel de ingresos? ¿Hay relación entre el género musical que se escucha y el nivel de estrés?	χ^2
ANOVA	Comparar 3 o más medias	¿Influye el tipo de fertilizante (A, B, C o D) en el rendimiento de la cosecha? ¿Hay diferencias en el nivel de satisfacción de clientes entre 4 sucursales de un banco?	F

Medidas de asociación entre variables

Repaso: ¿Cómo miramos la relación entre variables?

TIPO DE VARIABLE	NUMÉRICA	CATEGÓRICA
NUMÉRICA		
CATEGÓRICA		

Medidas de asociación entre variables

Repaso: ¿Cómo medimos la relación entre variables?

TIPO DE VARIABLE	NUMÉRICA	CATEGÓRICA
NUMÉRICA	Pearson (lineal) Spearman (monótona) Kendall (monótona)	?
CATEGÓRICA		?

Medidas de asociación para variables categóricas

01

Coeficiente Phi

Medida de asociación para tablas de contingencia 2x2.

02

Correlación punto-biserial

Relación entre una variable dicotómica y una continua.

03

Cramér's V

(fuerza de asociación)

Apta para tablas de contingencia de cualquier tamaño.

04

Kendall Tau-b

(para categóricas)

Ideal para variables ordinales con empates.

05

Eta cuadrado

Mide la proporción de varianza explicada en variables categóricas.

Coeficiente Phi

¿Qué es?

El Coeficiente Phi (ϕ) es una medida estadística que cuantifica la relación de asociación entre variables.

- **Asociación Binaria:** Diseñado específicamente para evaluar la relación entre dos variables dicotómicas.
- **Base Chi-Cuadrado:** Su cálculo se fundamenta directamente en el estadístico matemático Chi-cuadrado (χ^2).
- **Fuerza y Dirección:** Permite conocer tanto la presencia de una relación como la intensidad de la misma.

¿Cómo se calcula?

Fórmula basada en Chi-cuadrado $\phi = \sqrt{\frac{\chi^2}{n}}$

Desde la tabla 2x2
$$\phi = \frac{ad - bc}{\sqrt{(a+b)(c+d)(a+c)(b+d)}}$$

Nomenclatura

χ^2 = Estadístico Chi-cuadrado

n = Tamaño de la muestra

Rango de Interpretación

Valores posibles: [-1, +1]

Coeficiente Phi

Interpretación



Ejemplo práctico

CURSO	APRO-BADO	DESA-PROBADO	TOTAL
ONLINE	38	62	100
PRESENCIAL	72	28	100
TOTAL	110	90	200

$$\phi = \sqrt{\frac{X^2}{n}} = \sqrt{\frac{22,727}{200}} \approx 0,337$$

$$\phi = \frac{38 \times 28 - 62 \times 72}{\sqrt{(38 + 62)(72 + 28)(38 + 72)(62 + 28)}} = \frac{-3400}{9949,87} \approx -0,342$$

Correlación punto-biserial

¿Qué es?

- La **correlación punto-biserial** mide la relación y la fuerza de la asociación entre una **variable numérica continua** (altura, nota, salario, etc.) y una **variable binaria** (1/0, Sí/No, aprobado/reprobado, etc.).
- Es un caso especial del **coeficiente de correlación de Pearson**, optimizado específicamente para cuando una de las variables es categórica dicotómica.

¿Cómo se calcula?

Fórmula para n muestras:

$$r_{pb} = \frac{x_1 - x_0}{s} \sqrt{\frac{n_1 n_0}{n^2}}$$

x_1, x_0 = medias de cada grupo

s = desviación estándar total

n_1, n_0 = tamaños de cada grupo; n = total

Rango de Interpretación

Valores posibles: **[-1, +1]**

Correlación punto-biserial

Interpretación



Ejemplo práctico

tomó cafeína	NO	NO	SÍ	SÍ	NO	SÍ	SÍ	NO	SÍ	NO
reacción (seg)	320	340	245	230	305	260	255	290	240	315

$$r_{pb} = \frac{x_1 - x_0}{s} \sqrt{\frac{n_1 n_0}{n^2}} = \frac{246 - 314}{38,73} \sqrt{\frac{5 \times 5}{10 \times 10}} \approx -0,878$$

Cramér's V (fuerza de asociación)

¿Qué es?

- Cramer's V es una medida de asociación entre dos variables categóricas nominales.
- Está basada en el estadístico chi-cuadrado.
- Indica si hay relación entre las variables y la intensidad de esa relación.

¿Cómo se calcula?

Fórmula para n muestras:

$$V = \sqrt{\frac{X^2}{n(k-1)}}$$

χ^2 = estadístico chi-cuadrado

n = tamaño de muestra


k = menor número de filas o columnas

Rango de Interpretación

Valores posibles: **[0, +1]**

Cramér's V (fuerza de asociación)

Interpretación



Ejemplo práctico

Retomamos el ejemplo de la relación entre el nivel educativo y el medio de transporte:

$$V = \sqrt{\frac{X^2}{n(k-1)}} = \sqrt{\frac{18,28}{290(2-1)}} = \sqrt{0,063} \approx 0,251$$

chi² reveló una relación significativa, sin embargo con Cramer's V vemos que la magnitud de esta relación es casi moderada

Kendall Tau-b para categóricas ordinales

¿Qué es?

- Es una medida de asociación que evalúa la fuerza y la dirección monotónica entre dos variables.
- Ya habíamos visto el caso numérica-numérica. Kendall Tau-b se usa también para comparar variables numéricas con variables categóricas ordinales, o dos variables categóricas ordinales entre sí.
- En el caso de las variables categóricas, en lugar de rankings se usa el orden de las categorías.

¿Cómo se calcula?

Fórmula para n muestras:

$$\tau_b = \frac{C - D}{\sqrt{(C + D + T_x)(C + D + T_y)}}$$

C = Cantidad de pares **concordantes**

D = Cantidad de pares **discordantes**

T_x = empates en X


T_y = empates en Y

Rango de Interpretación

Valores posibles: **[-1, +1]**

Kendall Tau-b para categóricas ordinales

Interpretación



Ejemplo práctico

Nivel de estrés: Bajo (1) < Medio (2) < Alto (3)

Calidad de sueño: Mala (1) < Regular (2) < Buena (3)

NIVEL DE ESTRÉS	Bajo	Bajo	Medio	Medio	Alto	Alto
CALIDAD DE SUEÑO	Buena	Regular	Regular	Mala	Mala	Regular

NIVEL DE ESTRÉS	1	1	2	2	3	3
CALIDAD DE SUEÑO	3	2	2	1	1	2

$$\tau_b = \frac{C - D}{\sqrt{(C + D + T_x)(C + D + T_y)}} = \frac{1 - 7}{\sqrt{(1 + 7 + 3)(1 + 7 + 4)}} \approx -0,522$$

Eta cuadrado

¿Qué es?

- Eta cuadrado es una medida de asociación (o tamaño del efecto) que dice qué porcentaje de la variabilidad de una variable numérica se explica por una variable categórica.
- Está basada en el test ANOVA.
- Indica la intensidad pero no dice si la relación es positiva o negativa (dirección).

¿Cómo se calcula?

Fórmula para n muestras:

$$\eta^2 = \frac{\sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2}{\sum_{i=1}^N (x_i - \bar{x})^2}$$


Suma de cuadrados entre grupos, dividido en la suma de cuadrados total

Rango de Interpretación

Valores posibles: **[0, +1]**

Eta cuadrado

Interpretación



Ejemplo práctico

¿Cuánta relación hay entre el color del botón de "Comprar ahora" y la cantidad de dinero que gastan los clientes?

cliente	botón	\$
c1	verde	15
c2	verde	35
c3	rojo	25
c4	rojo	45

$$\eta^2 = \frac{\sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2}{\sum_{i=1}^N (x_i - \bar{x})^2} = \frac{2 \times (25 - 30)^2 + 2 \times (35 - 30)^2}{(15 - 30)^2 + (35 - 30)^2 + (25 - 30)^2 + (45 - 30)^2} = \frac{100}{500} = 0,2$$



Google Colab

Ejemplo en Python

04_datos_faltantes_outliers\01_datos_faltantes_outliers.ipynb



Medidas de asociación

TIPO DE VARIABLE	NUMÉRICA (edad, salario)	CATEGÓRICA NOMINAL (*) (estado civil, provincia)	CATEGÓRICA BINARIA (trabaja S/N, estudia S/N)	CATEGÓRICA ORDINAL (nivel de estudio, nivel de ingresos)
NUMÉRICA (edad, salario)	- Pearson (lineal) - Spearman (monót.) - Kendall (monót.)	Eta cuadrado	Correlación punto-biserial	Kendall Tau
CATEGÓRICA NOMINAL (*) (estado civil, provincia)		Cramér's V	Cramér's V	Kendall Tau o Cramér's V
CATEGÓRICA BINARIA (trabaja S/N, estudia S/N)			Coeficiente Phi	Kendall Tau
CATEGÓRICA ORDINAL (nivel de estudio, nivel de ingresos)				Kendall Tau

(*) 3 o más categorías

Outliers (datos anómalos)


Los **outliers** son puntos que difieren significativamente de otras observaciones en un dataset.

¿Por qué es crucial identificarlos?

- **Errores y anomalías:** Indican fallas en la recolección o problemas en los datos.
- **Hallazgos valiosos:** Permiten resaltar comportamientos inusuales pero altamente significativos.
- **Modelado preciso:** Evitan distorsiones en los modelos estadísticos o predictivos de machine learning.

⚠ Riesgo de sesgo: Si no se manejan adecuadamente, pueden sesgar por completo el análisis y conducir a conclusiones estratégicas erradas.

Ejemplo de Visualización



Un único dato diferente (resaltado) altera la distribución típica del grupo.


Técnicas para detectar outliers

Análisis visual




Boxplots

Representan la distribución mediante cuartiles, facilitando la identificación visual de valores atípicos.




Histogramas

Muestran la frecuencia de los datos; las barras aisladas en los extremos revelan anomalías.



Swarmplots

Grafican cada punto individual evitando la superposición, ideal para ver la dispersión real de outliers.



Técnicas para detectar outliers

Métodos estadísticos robustos

Regla del IQR


Establece límites estadísticos para clasificar valores atípicos:

Límite Inferior:

$$Q1 - 1.5 \times IQR$$

Límite Superior:

$$Q3 + 1.5 \times IQR$$



Técnicas para detectar outliers

Métodos estadísticos clásicos

Regla de las 3 Sigmas ($\pm 3\sigma$)


Establece límites estadísticos basados en la desviación estándar:

Límite Inferior:

Media - 3 × STD

Límite Superior:

Media + 3 × STD



(asumo distribución normal!)

Datos faltantes

¿Qué son?

Son observaciones incompletas o valores no registrados en el dataset (**NaN**, **null**).

¿Por qué importan?

Pueden distorsionar el análisis y los modelos si no se tratan correctamente, introduciendo **sesgo (bias)** y afectando la confiabilidad de los resultados.



Tipos de causas de datos faltantes: MCAR

¿Qué es MCAR?

El valor falta por una causa al azar y su falta es independiente de los datos.

A esta causa la llamamos **MCAR** (Missing Completely at Random) o Muestra Con Ausencia Random.

Es un mecanismo que no introduce sesgo.

Nota: “Muestra Con Ausencia Random” es un nombre “inventado” como regla mnemotécnica,

Ejemplo Práctico

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas. El formulario falla al azar y no se registran algunas respuestas.

Participante	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	53	Profesor	430.000
3	21	Null	1.350.000
4	34	Analista de marketing	1.000.000
5	Null	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	770.000
.....			

Tipos de causas de datos faltantes: MAR

¿Qué es MAR?

La falta del valor se relaciona con los datos de otras columnas (hay un patrón).

A esta causa la llamamos **MAR (Missing at Random)** o **Muestra Ausente por Relación**.

Nota: “*Muestra Ausente por Relación*” es un nombre “inventado” como regla mnemotécnica,

Ejemplo Práctico

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas.

Los entrevistados mayores de 40 son menos propensos a divulgar su salario.

Participante	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	37	Profesor/a	430.000
3	53	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	23	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	Null
.....			

Tipos de causas de datos faltantes: MNAR

¿Qué es MNAR?

La falta del valor depende del dato no observado y se debe a una causa específica que debe ser investigada.

A esta causa la llamamos **MNAR (Missing not at Random)** o **Muestra No Aparece** debido a su **Resultado**.

Nota: “*Muestra No Aparece debido a su Resultado*” es un nombre “inventado” como regla mnemotécnica,

Ejemplo Práctico

Ejemplo: estamos investigando salarios en Argentina y enviamos una encuesta a 100 personas. Las personas con salarios más altos tienden a evitar contestar la pregunta.

Participante	Edad	Rubro	Salario
1	45	Abogado/a	Null
2	52	Profesor/a	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	Null
5	23	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	770.000
.....			

Tipos de causas de datos faltantes: **Estructural**

¿Qué es faltante estructural?

La falta del valor se debe a que el dato no existe.

Tiene sentido que no esté. A esta causa la llamamos **estructural** o por **diseño**.

Ejemplo Práctico

Investigamos salarios en Argentina y enviamos una encuesta a 100 personas.

Para los encuestados que no se han graduado, el año de graduación queda en blanco (**Null**).

Participante	Edad	Año de graduación	Rubro	Salario
1	45	2006	Abogado/a	1.500.000
2	52	1998	Profesor/a	430.000
3	21	Null	Analista de datos	1.350.000
4	34	Null	Analista de marketing	1.000.000
5	23	2024	A. financiero/a	600.000
5	31	2020	Asesor/a del congreso	700.000
6	48	Null	Recepcionista	770.000
.....				

Algunas formas de analizar causas de faltantes

Fáciles de identificar

MAR: Métodos gráficos y bibliotecas especiales para analizar si hay o no patrones.

MCAR: Filtrado o agrupamiento (por ej. si el % de faltantes es similar al agrupar de distintas formas) y tests estadísticos.

Estructural: Consultar la documentación de recolección de los datos.

Difícil de detectar

MNAR (Missing Not at Random)

Se deja como **última opción** si no hay evidencia clara de ninguna de las otras causas.

Su detección e interpretación **requiere investigación** exhaustiva y un sólido conocimiento del dominio.



Google Colab

Ejemplo en Python

04_asociacion_faltantes_outliers\02_datos_faltantes_outliers.ipynb






Resumen



Estadísticas descriptivas

Variables numéricas

Tendencia central






Forma



Dispersión

varianza y desvío estándar



asimetría

Variables categóricas

Concentración


- Moda
- Proporción de la moda
- Multimodalidad

Distribución y frecuencia

- Frecuencia absoluta
- Frecuencia relativa
- Rango de frecuencias

Diversidad o variabilidad

- Cardinalidad
- Entropía de Shannon



Resumen


Datos faltantes

Definición: Son observaciones incompletas o valores no registrados en el dataset (NaN, null).

Tipos de faltantes

- **MCAR**
Missing Completely at Random
Muestra Con Ausencia Random
- **MAR**
Missing at Random
Muestra Ausente por Relación
- **MNAR**
Missing Not at Random
Muestra No Aparece debido a su Resultado
- **Estructural**
Mecanismo por diseño

Análisis visual



Otros métodos

EDA (relaciones)

Análisis exploratorio para identificar patrones de asociación.

Filtrado y agrupación

Es MCAR si el % de faltantes es similar al agrupar de distintas formas.

Tests estadísticos

Pruebas formales para validar el tipo de mecanismo de pérdida.


Resumen

Outliers


Definición: Son puntos que difieren significativamente de otras observaciones en un dataset.

Análisis visual

Permite identificar la presencia de valores atípicos de forma rápida y gráfica mediante la distribución de los datos.



Boxplots




Histogramas

Métodos estadísticos

Robustos (modernos)

Filtrado por **Rango Intercuartílico (IQR)**. Identifica datos fuera del rango:


$$\begin{aligned} &< Q1 - 1.5 * IQR \\ &> Q3 + 1.5 * IQR \end{aligned}$$



Clásicos

Filtrado por **Desviación Estándar (STD)**. Identifica datos fuera de:

$$\begin{aligned} &< media - 3 * STD \\ &> media + 3 * STD \end{aligned}$$



Repaso práctico

Estadísticas climáticas



Análisis Exploratorio de Datos (EDA)

Vamos a realizar el EDA y visualizaciones con datos abiertos del Servicio Meteorológico Nacional Argentino para el período 1991-2020.



Estaciones meteorológicas

Corresponden a los sitios donde se miden y registran las condiciones del tiempo atmosférico de manera sistemática y continua.

Estadísticas climáticas normales

Se le llama así a los valores promedio y extremos de diferentes variables meteorológicas, calculados sobre un período estándar de 30 años. Sirven como referencia climatológica.

Repaso práctico

El dataset



Estadísticas climáticas normales calculadas sobre el período 1991-2020 para todas las estaciones meteorológicas del país



Variables registradas

- **Temperatura:** media, máxima y mínima
- **Humedad:** relativa
- **Viento:** velocidad (km/h)
- **Nubosidad:** total
- **Precipitación:** cantidad total
- **Frecuencia:** días con precipitación superior a 0,1 mm



Google Colab

Repaso práctico

04_asociacion_faltantes_outliers\03_eda_ejemplo_smn.ipynb



Actividad individual opcional

Objetivo

Seleccionar uno de los sets de datos disponibles [aquí](#).
(Preferentemente el mismo que la actividad anterior, o alguno otro de interés.)

Consigna

Realizar EDA completo (Actividad anterior)
Identificar características generales (por ej. tamaño, tipo de información, curiosidades, desafíos a priori, etc.) del dataset seleccionado.
Outliers, técnicas que considere aplicar si corresponde, etc.

Resumir esta información en 3 diapositivas.

1. Caratula
2. Contenido
3. Contenido

En la siguiente clase se sorteará 2 o 3 alumnos quienes presentaran en 10min sus diapositivas.




Click Me 

Entrega	Estado	Puntos
No	-	0
Si	No cumple con la consigna	0
Si	Si cumple con la consigna	1

¡Gracias!

¿Consultas?



Ing. González H. Alexis