

Inteligencia Artificial

Procesamiento y limpieza de datos

Ing. González H. Alexis



Tabla de Contenidos

01

Active Recall

Repaso del tema anterior

02

Main Content

Flujo de preparación de datos.
Data cleaning y data wrangling.
Split del dataset.
Tratamiento de datos faltantes
y outliers.
Cardinalidad.
Codificación.


03

Live Coding Pair Programming

Ejercitación & Feedback

01

Active Recall



Repaso

Aprendizaje supervisado

1. Entrenamiento

Entrenamos un modelo con datos de entrenamiento.

Nro. Pasajeros	Desayuno	Precio
3	Si	\$350
2	Si	\$250
5	No	\$500
3	No	\$300

2. Predicción

Luego predecimos con datos de test.

Nro. Pasajeros	Desayuno	Precio
1	Si	?
4	No	?

A la variable a predecir (precio en este caso) la llamamos **target, etiqueta o label**.

En el caso de un problema de clasificación, a las etiquetas les llamamos **clases**.

Regresión

Cuando la etiqueta representa una **cantidad**, estamos ante un problema de regresión.

Nro. Pasajeros	Desayuno	Precio
3	Si	\$350
2	Si	\$250
5	No	\$500
3	No	\$300

Clasificación

Cuando la etiqueta representa una **categoría**, estamos ante un problema de clasificación.

Nro. Pasajeros	Desayuno	Precio
3	Si	BARATO
2	Si	BARATO
5	No	MUY CARO
3	No	CARO



© gonzalezhalexis@gmail.com ©

Desbalance

El desbalance es una característica de los problemas de clasificación.

Se produce cuando las clases (o etiquetas) que el modelo debe predecir no están representadas de manera proporcional en el dataset.

¿Por qué ocurre?

- **Sesgo de selección:** Los datos se recolectan de forma que guardan una proporción distorsionada desde el origen.
- **Naturaleza del problema:** Ciertas clases son intrínsecamente raras en el dominio real (**causa más frecuente**).


⚠ ¿Por qué es un problema?

Los modelos de ML tienden a:

- Aprender a clasificar con mayor precisión las **clases mayoritarias** (más frecuentes).
- Tener un **peor desempeño** global al intentar predecir las clases menos frecuentes.

|| Ejemplo de Dataset

Visualización de una distribución desbalanceada de clases (A, B, C, D).




Desbalance. Técnicas para detectarlo

■ Análisis Visual

Evaluación gráfica del volumen por clase mediante gráficos de barra o de torta.

Proporciones de clase:


- Cálculo de frecuencias relativas.
- Evaluación del rango de frecuencias.



Matriz de Confusión

El análisis de los errores sistemáticos permite identificar sesgos de clasificación críticos.

Si los errores se concentran críticamente en las **clases minoritarias**, es un fuerte indicador de un desbalance no resuelto.



Σ Análisis de Índices

Entropía de Shannon

A mayor entropía, mayor incertidumbre y mejor balance global de los datos.

$$H(X) = - \sum_{i=1}^n p_i \log_2(p_i)$$

Índice de Gini


Mide la pureza de los datos. Un valor cercano a ~0.5 indica un dataset balanceado.

$$G = 1 - \sum_{i=1}^n p_i^2$$

Split del dataset

Dataset Original

features			...	target



features			target

TRAIN

Datos de entrenamiento para ajustar los parámetros del modelo.

features			target

TEST

Datos de prueba para evaluar la generalización.

Split del dataset. Buenas prácticas

Proporciones

Es usual particionar el conjunto de datos en entrenamiento y prueba para evaluar correctamente el modelo.


- 70% (train) / 30% (test)
- Alternativa común: 80% / 20%



Clasificación

Garantiza que las clases del target queden representadas de manera equitativa y proporcional en ambos subconjuntos.

- Stratified Split
- Esencial para datasets desbalanceados



Series Temporales

Evita la fuga de datos separando estrictamente por fechas, impidiendo mezclar pasado y futuro.

	features	target
Train	01/2025	
	...	
	...	
	04/2025	
	...	
	09/2025	
	features	target
Test	10/2025	
	...	
	12/2025	

Flujo de trabajo del análisis de datos para IA


01

Identificar el problema



02

Recopilar los datos



03

EDA y limpieza básica




04

Análisis estadístico y preparación



05

Entrenar modelos



 **Proceso Iterativo**

Limpieza y preparación de datos



Data Wrangling

Preparación de Datos

Preparar datos para responder preguntas de análisis de forma eficaz.

- Transformamos y agrupamos para resumir la información clave.
- Reorganizamos y combinamos fuentes de datos diversas.
- Enriquecemos los datos agregando valor para el modelado.

Ejemplo de Reorganización (Tidy Data)

Mes	Producto	Ventas
Ene	A	10
Ene	B	20
Feb	A	15
Feb	B	18



Mes	A	B
Ene	10	20
Feb	15	18

Data cleaning



Problema	Cómo se resuelve	con Pandas
Tipos de datos y formato incorrecto	Conversión	<code>astype()</code> <code>pd.to_datetime()</code>
Duplicados	Eliminación	<code>drop_duplicates()</code>
Errores tipográficos, inconsistencias y categorías inconsistentes	Estandarizar: unificar mayúsculas/minúsculas, corregir abreviaturas, eliminar tildes, definir nomenclaturas únicas.	<code>str.lower()</code> <code>str.upper()</code> <code>str.title()</code> <code>str.strip()</code> <code>str.replace()</code> <code>map()</code> <code>apply()</code>

Data wrangling



A nivel del dataset (estructura)	Cómo se resuelve	con Pandas
Fuentes de datos diversas	Integración de múltiples fuentes: unir, fusionar, concatenar	<code>pd.concat()</code> <code>pd.merge()</code>
Dataset en formato no apropiado	Dar formato según las necesidades	<code>pivot()</code> , <code>melt()</code> , <code>reset_index()</code>
Datos muy detallados	Agrupar por categorías	<code>groupby()</code> , <code>agg()</code>

A nivel de columnas (contenido)	Cómo se resuelve	con Pandas
Tipos de datos incorrectos	Convertir texto, números y fechas	<code>astype()</code> , <code>to_numeric()</code> , <code>to_datetime()</code>
Información embebida en texto	Extraer o combinar información contenida en strings	<code>split()</code> , <code>extract()</code> , <code>get()</code> , <code>join()</code>
Datos no explícitos	Crear nuevas variables a partir de datos existentes	<code>assign()</code> , <code>apply()</code> , <code>transform()</code> , <code>.dt.year</code> , <code>.dt.month</code> , <code>.dt.day_name()</code>

Flujo de preparación de datos para IA

Recolección de datos

Fase inicial de obtención y almacenamiento de las fuentes de información necesarias para el proyecto.



Paso 03

EDA y limpieza básica 03

Exploración y entendimiento de datos.

Data cleaning y wrangling.

Identificación de transformaciones y tratamiento necesario



Split del dataset

Buena práctica:
Paso sumamente necesario antes de hacer la preparación final de los datos.



Paso 04

Preparación final 04

Análisis estadístico.
Codificación.
Nulos y outliers.
Escalamiento.
Reducción de dim.
Otras técnicas.

Repaso – Datos faltantes y outliers

¿Qué son los datos faltantes?

Son observaciones incompletas o valores no registrados en el dataset (NaN, null).



¿Qué son los outliers?

Son puntos que difieren significativamente de otras observaciones en un dataset.



Importante:

Si no se manejan adecuadamente, los datos faltantes y los outliers pueden distorsionar el análisis, introducir sesgo en los modelos y conducir a conclusiones erradas.

Estrategias para manejo de datos faltantes


Eliminación

- Borrar filas (observaciones).
- Borrar columnas (variables).

Imputación (colocar un valor)

Métodos univariados:

- Por media, mediana, moda.
- Valor de adelante o de atrás.
- Crear nueva categoría.
- Series temporales (hacia adelante/atrás e interpolación lineal o polinómica).





Ejemplo: imputación por la mediana

columna original

Imputación
Mediana de la
edad = 28

sex	fare	class	deck	embark_town	alive	alone	age	age_2
male	26.5500	First	E	Southampton	yes	True	51.00	51.00
female	21.0750	Third	NaN	Southampton	no	False	3.00	3.00
female	19.2583	Third	NaN	Cherbourg	yes	False	0.75	0.75
male	7.2292	Third	NaN	Cherbourg	no	True	NaN	28.00
male	8.0500	Third	NaN	Southampton	no	True	34.00	34.00
female	23.0000	Second	NaN	Southampton	yes	False	18.00	18.00
female	27.7208	First	B	Cherbourg	yes	True	44.00	44.00
male	14.5000	Third	NaN	Southampton	no	True	NaN	28.00
male	9.5000	Third	NaN	Southampton	no	True	NaN	28.00
female	9.5875	Third	NaN	Southampton	no	True	37.00	37.00
male	11.5000	Second	NaN	Southampton	no	False	21.00	21.00
male	78.8500	First	C	Southampton	no	False	36.00	36.00

Histograma de la edad antes y después de la imputación




Ejemplo: imputación hacia adelante/atrás

columna original

Imputación

	date	passengers	pass_ffill	pass_bfill
0	1949-01-01	NaN	NaN	118.0
1	1949-02-01	118.0	118.0	118.0
2	1949-03-01	132.0	132.0	132.0
3	1949-04-01	129.0	129.0	129.0
4	1949-05-01	NaN	129.0	135.0
5	1949-06-01	135.0	135.0	135.0
6	1949-07-01	148.0	148.0	148.0
7	1949-08-01	148.0	148.0	148.0
8	1949-09-01	136.0	136.0	136.0
9	1949-10-01	119.0	119.0	119.0
10	1949-11-01	NaN	119.0	126.0
11	1949-12-01	NaN	119.0	126.0
12	1950-01-01	NaN	119.0	126.0
13	1950-02-01	126.0	126.0	126.0

Número de pasajeros antes y después de la imputación



¿Cómo elegir la estrategia para el tratamiento de faltantes?

MCAR (Aleatorio)

Muy baja (<10%)

Eliminar filas

Baja (10-30%)

Imputación simple

Media (40-60%)


Técnicas avanzadas
(Próximamente)

Alta (70%+)

Eliminar columna completa

Ejemplo: Imputación por la mediana

```
# En Pandas
df.fillna({'age_2':
df['age'].median()}, inplace=True)
```



¿Cómo elegir la estrategia para el tratamiento de faltantes?

MAR (patrón)

Muy baja (<10%)

Imputación simple
(considerando el patrón)

Baja (10-30%)

Imputación simple
(considerando el patrón)

Media (40-60%)

Técnicas avanzadas
(Próximamente)

Alta (70%+)

Eliminar columna completa

Ejemplo: Imputación por la media



```
# En Pandas  
titanic_df['age'] =  
titanic_df.groupby('class')['age'] \  
.transform(lambda x:  
x.fillna(x.mean()))
```

1

Detectamos que los faltantes en edad cambian según la clase

2

Calculamos la media de edad por clase

3

Imputamos la edad según la media calculada para cada clase.

clase	faltantes
First	13,89 %
Second	5, 98 %
Third	27,70 %

clase	mean(age)
First	38
Second	30
Third	25

¿Cómo elegir la estrategia para el tratamiento de faltantes?

Estructural (no existe el dato)

Muy baja (<10%)

Imputar con 0, crear nueva categoría, etc.

Baja (10-30%)

Imputar con 0, crear nueva categoría, etc.

Media (40-60%)

Redefinir la variable

Alta (70%+)

Redefinir la variable

Ejemplo: Creamos una columna

```
# En Pandas
titanic_df['deck_sn'] =
titanic_df['deck'].notna().map({True
: 'S', False: 'N'})
```

1

Descubrimos que el faltante en deck se debe a que no todos los pasajeros tenían deck asignado (en particular los de tercera clase)

2

Creamos una columna para indicar si el pasajero tiene o no tiene deck asignado

clase	faltantes
First	18,98 %
Second	91,30 %
Third	97,56 %

¿Cómo elegir la estrategia para el tratamiento de faltantes?

Patrón de Faltantes	Muy baja cantidad <10%	Baja cantidad 10-30%	Media cantidad 40-60%	Alta cantidad 70%+
MCAR (aleatorio)	Eliminar filas	• Imputar con media si dist. aprox. Normal • Imputación por mediana • Imputar con moda o nueva cat. para categóricas	Técnicas avanzadas (proximamente)	Eliminar columna completa
MAR (patrón)	• Imputar con media si distribución aprox. Normal (*) • Imputación por mediana (*) • Imputar con la moda o nueva categoría para las categóricas (*)			
MNAR (falta el dato por su valor)	Modelado especial (custom)			
Estructural (no existe el dato)	• Imputar con 0 si corresponde (por ej, "salario del cónyuge" = 0 si no tiene) • Crear una nueva categoría (por ej, "no_aplica")		Redefinir la variable	

(*) considerando el patrón

Estrategias para manejo de outliers

Eliminación de filas

Si no son representativos o se los considera errores.

Imputación

Reemplazar por un valor acorde como la media o la mediana.


Aplicar winsorización (o capping en inglés): reemplazar por un valor máximo o mínimo definido, generalmente basado en un percentil.

Transformación

Aplicar logaritmo o raíz cuadrada para minimizar el impacto.

Segmentación

Agrupar los outliers en una categoría separada (categóricas).



¡Analizar si se trata de errores o son valores legítimos!



Google Colab

Ejemplo en Python

05_procesamiento_y_limpieza_de_datos\02_tratamiento_datos_faltantes.ipynb
05_procesamiento_y_limpieza_de_datos\03_tratamiento_outliers.ipynb



Cardinalidad (v. categóricas)

Es el número de valores únicos que puede tomar una variable en un conjunto de datos.

Baja

La mayoría de los valores se repiten en el conjunto de datos.

Ejemplos

- Estado civil
- Día de la semana

Alta

Existe una gran cantidad de valores únicos y diferentes.

Ejemplos

- Nombres de clientes
- Correos electrónicos

Extrema

Cada valor es prácticamente único para cada registro.

Ejemplos

- Números de serie
- Códigos de transacción

Codificación

¿Qué es?

Consiste en transformar variables categóricas en números para que puedan ser utilizadas por algoritmos de ML.

¿Cómo elegir la estrategia?

La elección de la estrategia de codificación depende del tipo de variable y de la cardinalidad de los datos.



Color			
Amarillo	1	0	0
Verde	0	1	0
Rojo	0	0	1
Amarillo	1	0	0

Amarillo	Verde	Rojo
1	0	0
0	1	0
0	0	1
1	0	0

One-hot encoding (o Dummy Encoding)

Transformación One-Hot Encoding

...	COLOR	...	...
...	AZUL	...	...
...	ROJO	...	...
...	VERDE	...	...
...	AZUL	...	...
...	VERDE	...	...
...	VERDE	...	...

Feature Original

Variable categórica nominal (color) que queremos codificar.



AZUL	ROJO	VERDE
1	0	0
0	1	0
0	0	1
1	0	0
0	0	1
0	0	1

Columnas Codificadas

Se crea una nueva columna binaria (0 o 1) por cada categoría.

Categóricas (cualitativas)



Variables Binarias (Caso Especial)

Cuando una variable categórica solo posee dos categorías posibles (ej. Sí / No):

Recomendación: Codificar con una única columna (valores 0 y 1) en lugar de utilizar One-hot con dos columnas redundantes.

Hashing encoding

Transformación Hashing encoding

...	COLOR	...	...
...	AZUL	...	...
...	ROJO	...	...
...	VERDE	...	...
...	NARANJA	...	...
...	GRIS	...	...
...	VERDE	...	...



H1	H2
0	1
1	0
1	1
0	0
1	0
1	1

Feature Original

Variable categórica nominal (color) que queremos codificar.

Columnas Codificadas

Permite codificar variables categóricas de alta cardinalidad mapeándolas a un espacio de dimensión fija.

Categóricas (cualitativas)



Evita la explosión de columnas que genera One-Hot encoding tradicional.

Hashing encoding – Consideraciones

Alta Cardinalidad

Es la solución preferida cuando se tienen variables categóricas con **cardinalidad muy alta** y se trabaja con pipelines simples y modelos de ML tradicional.

Enfoques Híbridos

Los enfoques híbridos con **embeddings* pre-entrenados** son una alternativa, pero implican mayor complejidad. Se usan para capturar semejanzas semánticas entre categorías.

Ejemplo de Mapeo (Hashing)

ID_EMPL	TITULO	SUELDO
E00001	MACHINE LEARNING ENGINEER	...
E00002	SENIOR SOFTWARE DEVELOPER	...
E00003	ANALISTA DE RECURSOS HUMANOS	...
...	...	...

(*) Embeddings lo retomaremos en la parte de aprendizaje profundo.

Frequency encoding

Transformación Frequency encoding

...	COLOR	...	...
...	AZUL	...	...
...	ROJO	...	...
...	VERDE	...	...
...	AZUL	...	...
...	VERDE	...	...
...	VERDE	...	...



COLOR_F
0.333
0.166
0.5
0.333
0.5
0.5

Feature Original

Variable categórica nominal (color) que queremos codificar.

Frequency encoding

Codificación basada en la frecuencia de aparición de cada categoría.

Categóricas (cualitativas)



Cálculo de Frecuencias

Total de registros (N) = 6

Azul: $2/6 = 0.333$

Rojo: $1/6 = 0.166$

Verde: $3/6 = 0.500$

Frequency encoding – Caso de Uso


Alta Frecuencia (Optimización)

Un sitio con alta frecuencia de ventas suele tener procesos logísticos optimizados, almacenes grandes y contratos con empresas de envío.

Baja Frecuencia (Riesgo de Demora)

Una tienda con baja frecuencia puede ser un vendedor ocasional o un particular que podría tardar más en despachar y entregar el producto.

Distribución del Dataset (Ejemplo)



La frecuencia de esta variable en el dataset tiene cierta relación con lo que estamos queriendo predecir (envíos a tiempo). Entonces la podemos codificar eficientemente utilizando **Frequency Encoding**.

Target encoding

Transformación Target encoding

...	COLOR	...	PRECIO
...	AZUL	...	8
...	ROJO	...	10
...	VERDE	...	5
...	AZUL	...	16
...	VERDE	...	7
...	VERDE	...	3

target

Feature Original

Variable categórica nominal (color) que queremos codificar.



COLOR_T
12
10
5
12
5
5

Feature codificada

Target encoding

Categorías (cualitativas)



Cálculo de Medias (Target)

Azul: $(8 + 16) / 2 = 12$

Rojo: $(10) / 1 = 10$

Verde: $(5 + 7 + 3) / 3 = 5$

Target encoding

Transformación Target encoding

...	COLOR	...	PRECIO
...	AZUL	...	8
...	ROJO	...	10
...	VERDE	...	5
...	AZUL	...	16
...	VERDE	...	7
...	VERDE	...	3

target

Feature Original

Variable categórica nominal (color) que queremos codificar.



COLOR_T
12
10
5
12
5
5

Feature codificada

Target encoding

Categóricas (cualitativas)



Importante:

Existen variantes para mejorar el rendimiento de los modelos:

- k-fold target encoding
- leave-one-out target encoding



Ordinal encoding

Transformación Ordinal encoding

...	CALIDAD	...	...
...	BUENA	...	...
...	REGULAR	...	...
...	MUY BUENA	...	...
...	BUENA	...	...
...	MUY BUENA	...	...
...	MUY BUENA	...	...

target



CALIDAD_O
1
0
2
1
2
2

Feature codificada

Categorías (cualitativas)

Nominales

Ordinales

Asociación de Orden

Regular: 0

Buena: 1

Muy Buena: 2

Establece una relación numérica que preserve el sentido u orden físico de las categorías.

Cyclic encoding para variables con comportamiento cíclico

Transformación Cyclic Encoding

date	month	month_num	month_sin	month_cos
1949-01-01	Jan	1	0.5000	0.8660
1949-02-01	Feb	2	0.8660	0.5000
1949-03-01	Mar	3	1.0000	0.0000
1949-04-01	Apr	4	0.8660	-0.5000
1949-05-01	May	5	0.5000	-0.8660
1949-06-01	Jun	6	0.0000	-1.0000
1949-07-01	Jul	7	-0.5000	-0.8660
1949-08-01	Aug	8	-0.8660	-0.5000
1949-09-01	Sep	9	-1.0000	-0.0000
1949-10-01	Oct	10	-0.8660	0.5000
1949-11-01	Nov	11	-0.5000	0.8660
1949-12-01	Dec	12	-0.0000	1.0000
1950-01-01	Jan	1	0.5000	0.8660
1950-02-01	Feb	2	0.8660	0.5000
1950-03-01	Mar	3	1.0000	0.0000




Feature Original

Meses expresados numéricamente (1-12) sin continuidad circular.

Feature Codificada

Mapeo a coordenadas seno y coseno que preservan la naturaleza cíclica.

Comportamiento Cíclico



¿Por qué es necesario?

Evita saltos artificiales entre diciembre (12) y enero (1). Al proyectar en un círculo trigonométrico, la distancia temporal se mantiene matemáticamente consistente para el modelo.

Label encoding para codificar la variable TARGET

Variable Target (Categórica)

...	...	...	TIPO_INCIDENCIA
...	...	...	problemas técnicos
...	...	...	consulta
...	...	...	consulta
...	...	...	reclamo factura
...	...	...	problemas técnicos
...	...	...	cambio de plan

Regla del Modelo

En un problema de **CLASIFICACIÓN** la variable target debe ser de tipo numérica discreta.

¿Qué pasa si no lo es?

¡Tenemos que codificarla mediante técnicas como **Label Encoding**!

Label encoding para codificar la variable TARGET

Variable Target (Categórica)

...	...	...	TIPO_INCIDENCIA
...	...	...	problemas técnicos
...	...	...	consulta
...	...	...	consulta
...	...	...	reclamo factura
...	...	...	problemas técnicos
...	...	...	cambio de plan



Target codificada

INCID_L
0
1
1
2
0
3

Mapeo de Categorías:

- **0** problemas técnicos
- **1** consulta
- **2** reclamo factura
- **3** cambio de plan



Google Colab

Ejemplo en Python

05_procesamiento_y_limpieza_de_datos\04_codificacion.ipynb



Resumen: Estrategias de codificación

Técnica	Consiste en ...	Ideal para...
One-Hot Encoding	crear una columna binaria (0/1) para cada categoría.	Baja cardinalidad. Multi-label (multi-hot encoding)
Ordinal Encoding	asignar un número entero secuencial a cada categoría.	Variables con un orden lógico
Hashing Encoding	aplicar una función hash para mapear categorías en un número fijo de dimensiones.	Cardinalidad muy alta
Frequency Encoding	sustituir cada categoría por su frecuencia de aparición.	Muchas categorías frecuentes (si hay categorías poco frecuentes, agrupar). La frecuencia aporta información sobre la variable target. (ej. fraude)
Target Encoding	reemplazar cada categoría con la media (u otra estadística) de la variable objetivo.	Alta cardinalidad. Problemas supervisados
Cyclic Encoding	transformar variables cíclicas en coordenadas en un círculo mediante funciones seno y coseno.	Variables con patrón cíclico
Label Encoding	asignar un número entero arbitrario a cada categoría	Codificar la variable target

Resumen: Estrategias de codificación

Técnica	Ventajas	Desventajas
One-Hot Encoding	Simple y efectiva	Escala mal con alta cardinalidad
Ordinal Encoding	Conserva el orden natural	Crea relaciones numéricas artificiales, (lineal, igualmente espaciada, por ej: low=1, medium=2, high=3) y puede confundir a los modelos lineales o basados en distancia
Hashing Encoding	Escalable y eficiente	Puede provocar colisiones (no es reversible) No conserva relaciones semánticas, orden ni jerarquía
Frequency Encoding	Útil para reducir categorías raras	Puede perder información
Target Encoding	Compacto y efectivo	Riesgo de sobreajuste
Cyclic Encoding	Conserva continuidad temporal	No se recomienda en datos sin periodicidad clara
Label encoding	Simple y efectiva	Pensado únicamente para la variable target (porque implica orden)

Actividad individual opcional



Objetivo

Aplicar los conocimientos adquiridos durante la cursada.

Consigna

Esta actividad comprende un total de 20 preguntas: 19 de opción múltiple y una de respuesta abierta. El cuestionario se divide en dos secciones:


- **Parte 1:** Preguntas de carácter conceptual.
- **Parte 2:** Consultas aplicadas al dataset del Servicio Meteorológico Nacional (SMN) analizado en clase.



Entrega	Preguntas correctas	Puntos
No	-	0
Si	Menor a 16	0
Si	Mayor o igual a 16	1

¡Gracias!

¿Consultas?



Ing. González H. Alexis