

Inteligencia Artificial

Procesamiento y nuevas features

Ing. González H. Alexis



Tabla de Contenidos

01

Active Recall

Repaso del tema anterior

02

Main Content

Discretización.
Normalización y
estandarización.
Técnicas avanzadas para el
tratamiento de datos faltantes
y outliers.
Desbalance.
Creación de nuevos features.


03

Live Coding Pair Programming

Ejercitación & Feedback

01

Active Recall



Repaso

Flujo de preparación de datos - Split.

Proceso de División

La separación de los datos es el paso fundamental para garantizar que el modelo aprenda patrones reales en lugar de simplemente memorizar la información.


TRAIN Dataset

Usualmente entre el 70% y 80% de los datos originales. Se utiliza exclusivamente para el entrenamiento y ajuste del modelo.

TEST Dataset

El porcentaje restante (20%-30%). Funciona como datos completamente "no vistos" para validar de forma objetiva la precisión final.

Flujo de Split del Dataset



Repaso


¿Por qué hacer el split antes de transformar los datos?

⚠ Contaminación de Datos

Si usáramos el dataset completo cuando hacemos una transformación, estaríamos contaminando el dataset de entrenamiento con “pistas” de los datos de test.

📈 Métricas Engañosas


Al evaluar el modelo con los datos de test, las métricas serían engañosas (demasiado optimistas).



Repaso

Flujo de preparación de datos

→ Split del dataset → Calcular y aplicar las transformaciones →





02

Main Content { }

Creación de nuevos features (Feature Engineering)

Concepto y Objetivo

Se trata de generar nuevas variables a partir de otras existentes con el fin de captar patrones o relaciones ocultas y mejorar la interpretación de los modelos.

Ejemplo: Métrica IMC

$$\text{IMC} = \text{peso} / (\text{altura})^2$$

Reemplazar las variables peso y altura por la métrica IMC, que aporta mayor valor y relación con la salud que las variables originales aisladas.



Técnicas para crear features



Matemáticas

Operaciones como A/B , $A*B$, $A-B$, etc.



Agregados

Métricas resumidas como promedios, sumas o totales.



Temporales

Extracción de día, hora, mes o año de un timestamp.



Texto

TF-IDF (importancia de palabras) y embeddings.



Ejemplos comunes



Fecha de ingreso → Antigüedad

Categoría (senior/semi-senior) o tiempo transcurrido.



Número de celular → Localización

Ubicación estimada a través del código de área.



Fecha de nacimiento → Edad

Cálculo directo para obtener la edad actual del usuario.



Sueldo/Provincia/Profesión → Relaciones

Salario promedio cruzado por zona y sector profesional.



Timestamp → Contexto Temporal

Hora del día, día hábil, feriado, clima o temporada.



Transacciones/Usuario → Frecuencia

Número acumulado de operaciones por cliente.



Factores de riesgo → Conteo / Riesgo

Índice ponderado o concurrencia de patologías.



Feedback de cliente → Sentiment Score

Conversión a escala numérica (positivo, neutral, negativo).



Valores faltantes → Indicadores de Omisión

Flag de ausencia o conteo de nulos por fila o dominio.



Descripción de producto → Palabras Clave

Extracción de términos clave (descuento, oferta, etc.).

Crterios para crear features



Crterios de Diseo

- **Relevancia:** Deben ser relevantes para el objetivo.
- **Relaciones importantes:** Capturar relaciones o transformaciones guiadas por conocimiento del dominio o anlisis.
- **Valor agregado:** Deben complementar o superar lo que aportan las variables originales.
- **Modelos de consumo:** Creados teniendo en cuenta los modelos que los consumirán.
- **Balance de recursos:** Equilibrio entre costo computacional e impacto en performance.



Casos de Uso Comunes

Ejemplos donde es clave crear features:

- **Datasets pequeos:** Muy til cuando el dataset cuenta con pocas filas.
- **Patrones no lineales:** Ayuda a los modelos a interpretar relaciones complejas.
- **Conocimiento de negocio:** El dominio lo requiere (ej. deuda/ingreso, nro. de items por compra, etc.).

Tip: conocer los modelos

Modelos Lineales

Estrategias para optimizar algoritmos lineales

- **Relaciones complejas:** Agregar features con relaciones complejas (ej., IMC) cuando se trabaja con modelos lineales.
- **Agregar ratios:** Considerar la creación de ratios, que son sumamente difíciles de aprender por cuenta propia para casi todos los modelos.

Modelos de Árbol

Técnicas eficaces para modelos basados en árboles

- **Combinaciones específicas:** Aunque los árboles aprenden combinaciones, conviene crearlas explícitamente si son de interés (especialmente con pocos datos).
- **Features de agregación:** Son muy útiles porque los árboles no tienen la capacidad natural de combinar información de muchos features a la vez.

Discretización




Conceptos Clave

- **Conversión de variables:** La discretización convierte variables continuas en variables discretas o categóricas.
- **Objetivo principal:** Se usa para mejorar la interpretación o el rendimiento de un modelo.
- **Metodologías:** Existen diversos métodos para discretizar, dependiendo del objetivo y de los datos.


Caso de Estudio

¿Cómo podríamos discretizar la longitud del pico de los pingüinos?




Métodos de discretización


Intervalos de igual rango de valores



Puntos de corte (cuantiles)



Rango fijo



¿Para qué discretizamos?



Menor Complejidad

Reduce la cantidad de datos y la complejidad computacional.



Menos Ruido

Disminuye fluctuaciones irrelevantes que contribuyen al overfitting.



Interpretación

Mejora el entendimiento al agrupar los datos en segmentos objetivos claros.



Control Outliers

Funciona como herramienta eficaz para contener el impacto de valores atípicos.

Discretización de la variable target – Ejemplo

Queremos clasificar, pero la variable target es numérica continua.

...	...	...	PUNTAJE	RATING
...	...	...	8,66	MUY BUENO
...	...	...	10	EXCELENTE
...	...	...	5,01	REGULAR
...	...	...	8,16	MUY BUENO
...	...	...	7,90	BUENO
...	...	...	3	MALO

↑
target
continua

↑
target
discretizada

PRECIO_L
3
4
1
3
2
0

↑
target
codificada



Google Colab

Ejemplo en Python

06_feature_engineering_avanzado\01_discretizacion.ipynb



Resumen de métodos de discretización

Intervalos iguales

Descripción

Rangos de igual amplitud.

Pros y contras

Simple. No sirve si los datos son asimétricos.

Por puntos de corte

Descripción

Basados en la distribución de los datos. Cada intervalo tiene el mismo número de observaciones.

Pros y contras

Funciona bien para datos asimétricos.

K-means

Descripción

Agrupar los datos en clusters con el algoritmo k-means.

Pros y contras

Captura agrupamientos naturales. Para datasets grandes requiere mucho cómputo.

Ancho fijo

Descripción

Definidos por el usuario basados en el conocimiento del dominio.

Pros y contras

Control total, pero requiere conocimiento de los datos y su distribución.

Normalización y estandarización

Son dos técnicas fundamentales para preparar las variables numéricas con el objetivo de mejorar el rendimiento y la velocidad de convergencia de los modelos de Machine Learning.

Normalización

CONCEPTO

Escala los valores numéricos para que queden contenidos estrictamente dentro de un rango determinado, usualmente $[0, 1]$.

CUÁNDO USAR

Útil cuando la distribución no es gaussiana y para algoritmos que dependen de distancias, como KNN o Redes Neuronales.

Estandarización

CONCEPTO

Transforma las variables para que tengan una media de 0 y una desviación estándar de 1 (escala Z-score).

CUÁNDO USAR

Ideal cuando los datos siguen una distribución normal o gaussiana, y para modelos lineales, máquinas de soporte vectorial (SVM) o PCA.

Normalización



Se escalan las variables numéricas para que sus valores estén dentro de un rango específico, generalmente entre 0 y 1. Útil cuando se usa un algoritmo que depende de la distancia (ej. KNN).

Ejemplo de Escalamiento

Original	Normalizado
13,1	0
16,2	0,369048
17	0,464286
18,3	0,619048
21,5	1

Fórmula matemática y Distribución resultante

$$X_{normalizado} = \frac{X - \min(X)}{\max(X) - \min(X)}$$



Estandarización (o Z-score)

Se transforman los datos de modo que tengan una media igual a 0 y una desviación estándar igual a 1. Adecuada cuando los datos ya tienen una distribución normal.



Útil para algoritmos que asumen distribución normal (Regresión lineal, SVM).

Ejemplo de Estandarización

Original	Estandarizado
13,1	-2,054446
16,2	-0,482361
17	-0,076662
18,3	0,5826
21,5	2,205397

Fórmula matemática y Distribución resultante

$$X_{\text{estandarizado}} = \frac{X - \mu}{\sigma}$$



Normalización y estandarización

Para tener en cuenta:

- Al normalizar y estandarizar cambian la **media**, la **varianza** y la **covarianza** de las variables.
- La **correlación de Pearson** permanece igual porque es invariante frente a transformaciones lineales de escala y centrado.

Normalización (Min-Max)

$$X_{normalizado} = \frac{X - \min(X)}{\max(X) - \min(X)}$$

Estandarización (Z-score)

$$X_{estandarizado} = \frac{X - \mu}{\sigma}$$



Google Colab

Ejemplo en Python

06_feature_engineering_avanzado\02_normalizacion_estandarizacion.ipynb



Escalamiento después de codificación

Ya vimos que hay que escalar las variables numéricas, pero ¿qué hacemos con las categóricas codificadas (que ahora también son números)?

	One-hot, binary, hashing... producen 0/1	Cyclic encoding	Frequency encoding	Target & Ordinal
Si normalizo las numéricas... ¿tengo que normalizar las codificadas?	NO no aporta nada	NO <i>¡para no romper el efecto cíclico!</i>	NO ya está entre 0 y 1	SÍ
Si estandarizo las numéricas... ¿tengo que estandarizar las codificadas?			SÍ	

Repaso: Desbalance

El Problema del Desbalance


Ocurre cuando las clases a predecir no están representadas de manera proporcional en el dataset de entrenamiento.

- **Clases mayoritarias:** El modelo tiende a sobreaprenderlas por su alta frecuencia.
- **Clases minoritarias:** Se obtiene un peor desempeño y dificultad de predicción.


¿Cómo lo detectamos?

Es fundamental identificar el desbalance antes del entrenamiento mediante técnicas diagnósticas:

- **Análisis visual:** Uso de gráficos de barras y diagramas de sectores (pie charts).
- **Proporciones de clase:** Frecuencias relativas y rangos de distribución.
- **Índices teóricos:** Evaluación mediante Entropía de Shannon o índice de Gini.



Ejemplo: desbalanceado
(levemente)



Ejemplo: balanceado

Técnicas para el tratamiento del desbalance

BALANCEAR Métodos de remuestreo

Oversampling (Sobremuestreo)

Duplicar o recrear sintéticamente muestras de la clase minoritaria (ej. **SMOTE** o IA generativa).

Undersampling (Submuestreo)

Remover muestras de la clase mayoritaria para equilibrar la distribución de los datos de entrenamiento.

MITIGAR Algoritmos y pesos

Weighted Random Sampler (Muestreador Aleatorio Ponderado)

Muestreo con reemplazo proporcional a pesos inversos de la clase. Simula balance sin alterar datos originales.

Técnicas de ensamble

Uso de algoritmos como **Balanced Random Forest** y **AdaBoost** que integran control del desbalance.



Recomendación: En desbalances extremos (1:1000), considerar la recolección de más datos.



Google Colab

Ejemplo en Python



06_feature_engineering_avanzado\03_desbalance.ipynb





Flujo de preparación de datos

Split del dataset

Calcular y aplicar las transformaciones





CALCULAR Y APLICAR




Flujo de preparación de datos

Split del dataset




Calcular y aplicar las transformaciones



CALCULAR Y APLICAR



APLICAR



Calcular y aplicar transformaciones

Transformación	Ejemplo	Calcular y aplicar en TRAIN	Aplicar en TEST
Tratar nulos	Imputar por la media	Calcular la media: 28 Imputar todos los nulos con 28.	Imputar todos los nulos con 28 .
Tratar outliers	Clipping	Determinar outliers: > 65 Imputar todos los outliers con 65.	Imputar con 65 todos los valores mayores a 65.
Crear features (el cálculo no depende de otras observaciones)	IMC	$IMC = peso / (altura)^2$	$IMC = peso / (altura)^2$
Crear features (el cálculo depende de otras observaciones)	Edad promedio por provincia	Calcular los valores de edad promedio por provincia. Ejemplo Neuquén: 45. A las observaciones de Neuquén se les asigna 45 .	Se asignan los valores según el cálculo hecho en entrenamiento. A las observaciones de Neuquén se les asigna 45.



Calcular y aplicar transformaciones

Transformación	Ejemplo	Calcular y aplicar en TRAIN	Aplicar en TEST
Discretizar	Igual rango de valores	Calcular rangos según distribución de la variable (mín 10, máx 30). Para dos grupos: • Categoría A (entre 10 y 20) • Categoría B (entre 21 y 30)	Asignar la categoría directa: • A (si valor está entre 10 y 20) • B (si valor está entre 21 y 30)
Codificar	One hot encoding	Detectar categorías: rojo, azul, verde. Crear columnas R, A, V. Codificar rojo como 1 0 0 , azul como 0 1 0 y verde como 0 0 1 .	Codificar rojo como 1 0 0 , azul como 0 1 0 y verde como 0 0 1 .
Escalar	Normalizar	Calcular mín y máx: 30 y 80. Calcular x' como $(x - 30) / 50$.	Calcular x' como $(x - 30) / 50$.
Balancear	Oversampling	Aplicar sobremuestreo a las clases minoritarias.	-


Flujo de preparación de datos

Split del dataset

Calcular y aplicar las transformaciones






CALCULAR Y APLICAR




APLICAR




Alerta DRIFT




! Data drift. Ejemplo 1: codificación



! Data drift. Ejemplo 1: codificación



Flujo de preparación de datos



Técnicas avanzadas para el tratamiento de datos faltantes

Métodos Simples

Estrategias tradicionales iniciales para mitigar la ausencia de información en los conjuntos de datos.



Eliminación Directa

Descarte completo de filas (observaciones) o columnas (variables) con datos nulos.



Imputación Univariada

Reemplazo de valores faltantes utilizando estimadores simples como la media aritmética.

Métodos Multivariados

Técnicas avanzadas que estiman los valores a partir del comportamiento de otras variables correlacionadas.



Algoritmos de Machine Learning

Modelos predictivos aplicados a la imputación (ej. Regresión, Árboles de decisión, KNN).



Modelos de Imputación Múltiple

Estimación iterativa y robusta basada en múltiples conjuntos simulados (ej. MICE).

Métodos multivariados - KNN


¿Cómo funciona?

El algoritmo KNN (K-Nearest Neighbors) busca las **k observaciones** (o vecinos) más similares a la fila del dato faltante.

El valor ausente se calcula e imputa directamente a partir de la información de esos vecinos cercanos.

⚠ ¡Atención!

Este método puede volverse altamente ineficiente y computacionalmente costoso al trabajar con datasets muy grandes.




Así funciona KNN para imputación

01

Dataset con nulos


Contamos con un conjunto de datos inicial donde la Feature C presenta valores faltantes.



02

Buscar Vecinos

Buscamos los k vecinos ($k=3$) de la observación que tiene los datos faltantes.



03

Calcular Imputación


Imputamos usando la media aritmética de los valores de la Feature C de sus vecinos.

A	B	C
4	3	2
7	2	4
2	1	3
5	1	4
3	2	3
2	6	7


Métodos multivariados – KNN

Se recomienda normalizar los datos antes de usar este algoritmo porque es sensible a la escala.

Datos sin normalizar



Datos normalizados



Si miramos solo la variable A, esta observación está **"lejos"** de la observación magenta.

Sin embargo, para el algoritmo esa distancia es **despreciable** por la diferencia de escala entre las variables A y B.

Métodos multivariados – MICE

Técnica Iterativa

MICE (Multiple Imputation by Chained Equations) es una técnica iterativa avanzada de imputación múltiple para procesar **muchas variables a la vez**.



2	3	9	8	7	5	1		6
4	5	6		9	2			7
	7	8	6	4				5
7	9	1	2	6	4	3	5	8
8	4	2	5	3	9	7	6	1
3	6	5	7	8	1	4	2	9
9	8	7	3	2	6	5	1	4
5	2	4	9	1	7	6	8	3
6	1	3	4	5	8	9	7	2

Patrones Complejos (MAR)

Es útil cuando se sospecha un mecanismo **MAR (Missing at Random)**, donde los datos faltantes muestran patrones complejos y dependen de múltiples variables del sistema.



influenced by
another
observed
variable

Así funciona MICE

Dataset con Nulos

Identificamos los valores faltantes (nulos) dentro de nuestro conjunto de datos original antes de iniciar el proceso.

	A	B	C
1			
2			
3			
4			

1. Imputación Simple

Se realiza una imputación rápida temporal para cada variable (por ejemplo, utilizando el promedio o la media) para poder iniciar el algoritmo.

A	B	C
		Media C
Media A		
	Media B	

2. Ciclo de Iteración (Variable por Variable)

a

Nos enfocamos en la variable A. Identificamos las filas donde había nulos.

Variable A	A	B	C
1			
2		B_i	C_i
3			
4			

b

Armamos un subset del dataset excluyendo las filas donde la variable A es nula

A	B	C
1		
3		
4		
2		

c

Entrenamos un modelo para predecir la variable A a partir del resto de las columnas (A=Target)

A (target)	B	C
1		
3		
4		
2		

d

Predecimos e imputamos los nulos de A usando el modelo entrenado.

A (target)	B	C
1		
3		
4		
2		

Así funciona MICE

e. Imputación de A

Se realiza la imputación del valor predicho para la variable bajo análisis.

e

Resultado luego de imputar los nulos de A:

A	B	C
		Media C
Pred A		
	Media B	

Otras variables

Repetimos a b c d e para cada una de las columnas donde había nulos.

Fin de Iteración 1

Al finalizar el ciclo para todas las columnas, se obtiene el dataset con la primera ronda completa de imputaciones.

A	B	C
		Pred C
Pred A		
	Pred B	

3. Repetimos el paso 2, N veces (tantas iteraciones como se hayan definido).

¿Cómo elegir la estrategia para el tratamiento de faltantes?

	Muy baja cantidad <10%	Baja cantidad 10-30%	Media cantidad 40-60%	Alta cantidad 70%+
MCAR (aleatorio)	Eliminar filas	- Imputar con media si distrib aprox. Normal - Imputación por mediana - Imputar con la moda o nueva categoría (ej, "FALTANTE") para las categóricas	- KNN (patrones claros) - MICE (patrones complejos) - Otros	Eliminar columna completa
MAR (patrón)	- Imputar con media si distrib aprox. Normal (*) - Imputación por mediana (*) - Imputar con la moda o nueva categoría (ej, "FALTANTE") para las categóricas (*)			
MNAR (autos sesgo)	Modelado especial (custom)			
Estructural (no existe el dato)	- Imputar con 0 si corresponde (ej, "salario del cónyuge" = 0 si no tiene) - Crear una nueva categoría (ej, "no_aplica")		Redefinir la variable	

(*) considerando el patrón

Técnicas avanzadas para el tratamiento de outliers

Métodos Simples

Técnicas univariadas y de transformación básicas:

- **Eliminación de filas:** Se descartan las observaciones con presencia de outliers.
- **Imputación univariada:** Reemplazo mediante estadísticos simples (media, mediana) o técnicas de capping.
- **Transformaciones:** Minimización del impacto de valores extremos mediante cambios de escala (ej. logaritmo).
- **Segmentación:** Separación de grupos para aislar comportamientos anómalos.

Métodos Multivariados

Imputación avanzada analizando múltiples variables en conjunto:

- **Relación entre columnas:** Estimación inteligente de valores faltantes o anómalos a partir del comportamiento de otras variables del dataset.
- **Algoritmos de Machine Learning:** Implementación de modelos de aprendizaje supervisado o no supervisado (por ejemplo, vecinos más cercanos o **KNN**) para una imputación de alta precisión.



Google Colab

Ejemplo en Python


06_feature_engineering_avanzado\04_tratamiento_datos_faltantes_avanzado.ipynb
06_feature_engineering_avanzado\05_tratamiento_outliers_avanzado.ipynb



Bibliotecas para automatizar EDA

ydata-profiling

Reportes automatizados y profundos:



- **Un solo comando:** Genera un análisis completo del dataframe en un archivo HTML interactivo de forma instantánea.
- **Análisis integral:** Detecta tipos de datos, correlaciones, valores faltantes, duplicados y estadísticas descriptivas detalladas.
- **Alertas automáticas:** Advierte sobre desbalances, alta cardinalidad y variables altamente correlacionadas.

sweetviz

Visualización comparativa rápida:



- **Comparación directa:** Diseñado específicamente para comparar datasets (ej. Entrenamiento vs. Testeo o subconjuntos de datos).
- **Interfaz estética:** Genera reportes con una UX extremadamente fluida, gráficos hermosos y limpios.
- **Asociaciones claras:** Visualiza correlaciones numéricas y categóricas de forma integrada y simple.



Google Colab

Ejemplo en Python

05_procesamiento_y_limpieza_de_datos\04_codificacion.ipynb



EDA y preprocesamiento para diferentes tipos de datos

Datos Tabulares

Análisis de variables numéricas y categóricas:


- **Métricas y visualización:** Uso de herramientas adaptadas a la naturaleza específica de cada tipo de dato.
- **Búsqueda activa:** Identificación de patrones, anomalías, tendencias, desbalances y problemas de calidad.

data														
id	area	area	area	area	area	area	area	area	area	area	area	area	area	area
1	id	area	area	area	area	area	area	area	area	area	area	area	area	area
2	id	area	area	area	area	area	area	area	area	area	area	area	area	area
3	id	area	area	area	area	area	area	area	area	area	area	area	area	area
4	id	area	area	area	area	area	area	area	area	area	area	area	area	area
5	id	area	area	area	area	area	area	area	area	area	area	area	area	area
6	id	area	area	area	area	area	area	area	area	area	area	area	area	area
7	id	area	area	area	area	area	area	area	area	area	area	area	area	area
8	id	area	area	area	area	area	area	area	area	area	area	area	area	area
9	id	area	area	area	area	area	area	area	area	area	area	area	area	area
10	id	area	area	area	area	area	area	area	area	area	area	area	area	area

Datos No Estructurados

Tratamiento de formatos de datos más complejos:

- **Elementos de análisis:** Procesamiento de palabras, píxeles y frecuencias.
- **Métodos aplicados:** Evaluación de medias, desvíos, histogramas y análisis de distribución.



EDA y preprocesamiento para Texto

Análisis de Texto

Aspectos clave a explorar:

- **Corpus:** volumen de documentos y palabras.
- **Longitud:** distribución de textos y oraciones.
- **Frecuencias:** conteo de palabras y tokens.
- **Clases:** balance de categorías.
- **N-gramas:** patrones de coocurrencia.
- **Métricas:** TF, DF y TF-IDF.

Preprocesamiento

Limpieza y preparación:

- **Filtros:** eliminación de stopwords, puntuación y errores ortográficos.
- **Normalización:** estandarizar abreviaturas y expresiones del texto.
- **Vectorización:** generación de embeddings y reducción dimensional con PCA.



EDA y preprocesamiento para Audio (o Señales)

Análisis de Audio

Aspectos clave a explorar:

- **Señales:** duración, amplitud y formas de onda.
- **Frecuencias:** espectrogramas y análisis de pitch.
- **Atributos:** entonación, melodía y variaciones acústicas.
- **Segmentación:** identificar voces, instrumentos y emociones.
- **Clases:** balance y distribución en clasificación.

Preprocesamiento

Limpieza y preparación:

- **Filtros:** eliminar archivos corruptos del dataset.
- **Reducción:** remover ruidos, silencios e interferencias.
- **Edición:** recortar fragmentos irrelevantes del audio.
- **Volumen:** normalizar la amplitud general de las señales.



EDA y preprocesamiento para Imágenes

Análisis y Visualización

Aspectos clave a explorar:

- **Inspección:** visualización de imágenes aleatorias.
- **Distribución:** histogramas de valores de píxeles.
- **Atributos:** colores, formas, texturas e iluminación.
- **Calidad:** enfoque, orientación y niveles de ruido.
- **Clases:** evaluación del balance de categorías.

Preprocesamiento

Limpieza y preparación:

- **Depuración:** eliminación de imágenes corruptas o dañadas.
- **Reducción:** aplicación de filtros de mediana y gaussianos.
- **Normalización:** estandarizar tamaños y resoluciones del set.





Google Colab

Ejemplo en Python

06_feature_engineering_avanzado\06_eda_automatico.ipynb
06_feature_engineering_avanzado\07_eda_texto.ipynb
06_feature_engineering_avanzado\08_eda_audio.ipynb
06_feature_engineering_avanzado\09_eda_imagenes.ipynb



Actividad individual opcional

Objetivo

Aplicar los conocimientos adquiridos durante la cursada.

Consigna

Esta actividad consiste en 9 preguntas multiple-choice.

La primera parte contiene preguntas conceptuales.

La segunda parte consiste en preguntas relacionadas con un dataset a elección entre los siguientes:


- Lionel Messi Club Goals (adaptado)
- 1980s Classic Hits



Entrega	Preguntas correctas	Puntos
No	-	0
Si	Menor a 6	0
Si	Mayor o igual a 6	1

¡Gracias!

¿Consultas?



Ing. González H. Alexis