

Inteligencia Artificial

Aprendizaje automático

Ing. González H. Alexis



Tabla de Contenidos

01

Active Recall

Repaso del tema anterior

02

Main Content

Definición de aprendizaje automático

Formas que las máquinas aprenden:

- Ap. Supervisado.
- Ap. No supervisado.
- Ap. Por refuerzo.


03

Live Coding Pair Programming

Ejercitación & Feedback

01

Active Recall



{ }

Datos


Lo más importante en Aprendizaje Automático son los datos

Nos permiten describir un objeto al que llamamos **entidad**. La forma en que se representan los datos afecta directamente los sistemas que se construyen y los problemas que pueden resolver.

Compra y venta

- Fabricante
- Modelo
- Año
- Color
- Precio

Entidad a representar: Auto



Seguimiento policial

- Fabricante
- Modelo
- Patente
- Dueño

Datos

Datos Estructurados

- **Formato estandarizado:** Datos tabulares organizados en filas y columnas.
- Permite acceso y procesamiento rápido y eficaz por software y personas.
- Información de carácter cuantitativo.

Datos No Estructurados

- **Sin modelo definido:** Información no ordenada de forma predefinida.
- **Ejemplos:** Archivos de texto, video, informes, e-mails e imágenes.

Estructura de Datos en Aprendizaje Automático

Uso de estructuras bidimensionales y notaciones vectoriales (arrays / tablas):

Filas (Muestras)

Cada fila del array representa una muestra, observación o dato puntual.

Columnas (Features)

Cada columna es una característica (feature o atributo) de la observación.

Objetivo (Label)

Columna especial (label o etiqueta) que contiene el valor que se pretende predecir.

Datos

Variables del Modelo

- **Variable dependiente (target) y:** (podemos conocer o no).
- **Predictores:** Conjunto $x_1, x_2, \dots, x_p$, descrito como vector $\mathbf{X} = (x_1, x_2, \dots, x_p)$.
- **Desafío:** Elegir las entradas correctas.

Población

Sub-set

Observaciones y Muestreo


- **Población:** El conjunto total de observaciones, el cual casi nunca podemos tener.
- **Subconjunto (Sub-set):** Las observaciones reales de las que disponemos para modelar.

Atributos / features

Objetivo

Position	Experience	Skill	Country	City	Salary (\$)
Developer	0	1	Argentina	Buenos Aires	103100
Data Scientist	2	2	Uruguay	Montevideo	104900
Developer	3	1	Argentina	Chivilcoy	106800
QA Eng	2	2	Colombia	Bogotá	108700
Product Manager	1	5	Perú	Lima	110400
Developer	7	5	Paraguay	Asunción	112300
Cloud Eng	5	2	Argentina	Buenos Aires	116100

Tipos de Variables





02

Main Content { }

Aprendizaje Automático

¿Qué es?

Una computadora observa datos, construye un modelo basado en ellos y lo utiliza como una hipótesis sobre el mundo y como una pieza de software capaz de resolver problemas.

¿Por qué queremos que una computadora aprenda?

Incertidumbre del Entorno

No se pueden anticipar todas las posibles situaciones futuras a las que se enfrentará el sistema.

Complejidad de Programación

No se tiene idea de cómo programar directamente una solución de forma explícita o manual.

Aprendizaje Automático — Ejemplos

CASO DE ESTUDIO: DETECCIÓN DE SPAM

Clasificación de Correos

Este problema se resuelve aplicando **Aprendizaje Automático**. Se analizan continuamente las palabras y los signos de puntuación de los correos entrantes.

Corresponde a un modelo de **aprendizaje supervisado**, cuyo resultado es una etiqueta o indicador binario (si el mensaje es SPAM o no).

Este tipo de tarea se conoce formalmente como un problema de clasificación.

Evaluación del Error

En este escenario, **no todos los errores de predicción tienen la misma gravedad**:

- **Filtrar correo legítimo:** Queremos evitarlo críticamente, ya que perder información importante genera un alto impacto negativo.
- **Dejar pasar SPAM:** Aunque resulta molesto e indeseable, sus consecuencias son considerablemente menos graves.

Aprendizaje Automático — Ejemplos

CASO DE ESTUDIO: PRECIO DE VENTA DE UNA CASA

Problema de Regresión

Se intenta predecir el precio de venta más apropiado de una casa dadas diferentes características, tales como tamaño, edad y ubicación.

Este es un problema de **aprendizaje supervisado**, conocido como **problema de regresión**.

Se considera regresión porque la medición del resultado es cuantitativa.



Aprendizaje Automático — Ejemplos


CASO DE ESTUDIO: SEGMENTACIÓN DE CLIENTES

Agrupamiento (Clustering)

Una famosa cadena de electrodomésticos quiere entender cómo se segmentan sus clientes según información demográfica y gustos, dados por su historial de compra.

Usando estos datos, se emplea un modelo que agrupa automáticamente a los usuarios en diferentes **grupos por similitud**.

Este problema es de aprendizaje no supervisado y particularmente de agrupamiento (clustering).



Aprendizaje Automático — Ejemplos

CASO DE ESTUDIO: SISTEMA DE RECOMENDACIÓN DE VIDEOS

Sistemas de Recomendación

Una empresa dedicada a compartir videos necesita mantener a los usuarios comprometidos en la plataforma.


Al finalizar un video, el sistema recomienda automáticamente el siguiente contenido a visualizar para prolongar la permanencia del usuario.

*Estos algoritmos se engloban en **aprendizaje supervisado**, **no supervisado** o **por refuerzo**.*



Formas de Aprendizaje

ESQUEMA GENERAL DE APRENDIZAJE AUTOMÁTICO



Formas de Aprendizaje

CLASIFICACIÓN SEGÚN EL TIPO DE DATOS Y REALIMENTACIÓN

Supervisado

Conocemos 'y' de antemano

- El modelo observa pares de **entradas-salidas** y aprende la relación entre ellos.
- Aprende de resultados conocidos realizando ajustes en sus **parámetros internos**.
- Permite realizar **predicciones adecuadas** ante nuevos datos de entrada.

No Supervisado

Sin respuesta objetivo ('y')

- El modelo descubre **patrones intrínsecos** directamente de la entrada.
- Funciona **sin ninguna retroalimentación** externa.
- No contamos con el valor objetivo y previamente etiquetado.

Por Refuerzo

Recompensas y Castigos

- El agente aprende interactuando mediante una **serie de refuerzos**.
- Evalúa cuál de las acciones anteriores fue la **más responsable** del resultado.
- Modifica sus decisiones para apuntar a **más recompensas** en el futuro.

Aprendizaje Supervisado

FORMALIZACIÓN MATEMÁTICA Y CONCEPTOS CLAVE

Definición Formal

Dado un conjunto de entrenamiento de N observaciones compuestas por pares de entradas y salidas: $(X_1, y_1), (X_2, y_2), \dots, (X_N, y_N)$

Función Objetiva

$$y = f(x)$$

Cada par de datos está generado por una **función desconocida** f que relaciona las entradas con la salida.

Modelo e Hipótesis

$$h(x) \approx f(x)$$

Se busca una **función** h que aproxime a la verdadera función f .

Esta función h es el modelo proveniente de un **espacio de hipótesis**.

Ground Truth

Salidas Conocidas ('y')

Llamamos a las **salidas** y como ground truth (valores reales observados).

Aprendizaje Supervisado

CRITERIOS Y METODOLOGÍA DE SELECCIÓN

Espacio de Hipótesis

¿Cómo elegir el espacio adecuado?

- **Conocimiento previo:** Aprovechar información existente sobre el proceso que generó los datos.
- **Análisis Exploratorio (EDA):** Examinar datos mediante pruebas estadísticas y visualizaciones.
- **Evaluación empírica:** Probar múltiples espacios de hipótesis y comparar cuál funciona mejor.

Selección del Modelo

¿Cómo elegir h dentro del espacio?

- **Hipótesis consistente:** Buscar una h tal que $h(x) = y$ para cada x de entrenamiento.
- **Valores continuos:** En salidas continuas es muy difícil obtener una coincidencia exacta.
- **Función de ajuste:** Se utiliza para medir qué tan cerca está $h(x_i)$ del valor real y_i .

Aprendizaje Supervisado

PROCESO DE ENTRENAMIENTO Y RIESGO EMPÍRICO

Flujo de Modelado

Población (Datos Totales)

Sub-set
(Datos de Entrenamiento)

Entrenamos

Modelo $h(x)$
Algoritmo / Hipótesis

Distribución de Datos Real

En la realidad, no podemos saber exactamente qué tan bien funcionará un modelo predictivo en la práctica porque **no conocemos la verdadera distribución** de los datos.

Estimación y Riesgo Empírico


Siempre trabajamos con subconjuntos para estimar y optimizar el rendimiento del modelo en un conjunto conocido de entrenamiento.

El rendimiento sobre este conjunto conocido se denomina **riesgo empírico**.

Aprendizaje Supervisado

GENERALIZACIÓN Y EVALUACIÓN DEL MODELO

Flujo de Evaluación




Generalización

¿Cómo medimos la eficacia real?

- **Medida real de desempeño:** La verdadera eficacia no se mide sobre el conjunto de entrenamiento, sino en qué tan bien procesa entradas nunca antes vistas.
- **Conjunto de prueba:** Se evalúa con un segundo set independiente de pares (X_i, y_i) reservado exclusivamente para validación.
- **Capacidad de generalización:** Se afirma que h generaliza correctamente si predice con alta precisión los resultados de este conjunto.

Aprendizaje Supervisado

FLUJO DEL APRENDIZAJE SUPERVISADO



Aprendizaje Supervisado

TIPOS DE APRENDIZAJE SUPERVISADO: CLASIFICACIÓN

Problemas de Clasificación

Se presentan cuando la variable *target* y es categórica o toma valores discretos.

Clasificación Binaria

Dos clases posibles (por ejemplo, es SPAM o no SPAM).

Clasificación Multi-clase


Múltiples clases (ej. nivel socioeconómico de una persona: alta, media y baja).

Alta Cardinalidad

Variante cuando se tienen muchísimas clases discretas.

Frontera de Decisión

Separación visual entre clases



Aprendizaje Supervisado

TIPOS DE APRENDIZAJE SUPERVISADO: REGRESIÓN

Problemas de Regresión

Si la variable target y es numérica, el problema es de regresión.

Variable Target (y)


Representa la variable continua o numérica que se desea predecir mediante el modelo.

Relación de Variables

Estudia las relaciones existentes entre la variable dependiente y una o más variables independientes (X).

Ajuste de Regresión

Línea de tendencia y estimación de parámetros



Aprendizaje Supervisado


REGRESIÓN VS. CLASIFICACIÓN

Regresión y clasificación son problemas muy similares entre sí. En ambos buscamos predecir una variable.

Clasificación

Predice una variable categórica


Separa los datos mediante una frontera de decisión entre clases distintas.



Regresión

Predice una variable numérica


Ajusta una línea o curva para estimar valores continuos.



Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

Supongamos que tenemos tres modelos en un problema de regresión. Tenemos una sola entrada x y una salida y que depende de x con una relación $f(x)$ que queremos modelar:




Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

Entrenamos con un set de entrenamiento y comparamos el ajuste de cada modelo:


Set de Entrenamiento

Muestra de datos de observaciones (x, y)



Modelos Entrenados

Comparación de las funciones $h(x)$, $g(x)$ y $v(x)$




Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

Midamos el error, para ello calculamos de la siguiente forma:

Gráfico de Ajuste



Fórmula MAE

$$MAE_p = \frac{1}{N} \sum_{i=1}^N |y - \hat{y}_p|$$

Resultados por Modelo

- Modelo 1: MAE1 = 0
- Modelo 2: MAE2 = 5
- Modelo 3: MAE3 = 1.25




Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

¿Pero realmente es el mejor? Evaluemos con el set de evaluación:

Gráfico de Evaluación



Fórmula MAE

$$MAE_p = \frac{1}{N} \sum_{i=1}^N |y - \hat{y}_p|$$

Resultados en Set de Evaluación

- Modelo 1: MAE1 = 90
- Modelo 2: MAE2 = 5.2
- Modelo 3: MAE3 = 1.75




Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

Análisis del comportamiento del Modelo 1 (Polinomio de alto grado):

Gráfico de Ajuste



Diagnóstico: Sobreajuste

- **Rendimiento:** Muy bueno en entrenamiento, pero deficiente en evaluación.
- **Causa:** El modelo aprende tanto que memoriza el ruido.
- **Complejidad:** Exceso de parámetros que impiden generalizar.

Criterio de Selección

Al elegir un modelo, se busca siempre que:


Parámetros $\ll$ Cantidad de obs. de entrenamiento

Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

Análisis del comportamiento del Modelo 2 (Subajuste) y Modelo 3 (Generalización):

Gráfico de Ajuste



Modelo 2: Subajuste

- **Rendimiento:** Pobre en entrenamiento y en evaluación.
- **Problema:** No logra capturar la estructura subyacente.
- **Diagnóstico:** Elevado sesgo (modelo demasiado simple).

Modelo 3: Generalización Óptima

- **Rendimiento:** Consistente entre entrenamiento y evaluación.
- **Atributo:** Capta la tendencia real ignorando el ruido.
- **Conclusión:** Excelente capacidad de generalización.

Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

El error que se comete con un modelo que sobreajusta y subajusta es diferente:

Error de Varianza

Asociado al Sobreajuste (Overfitting)

- **Origen:** Se presenta cuando el modelo es excesivamente complejo.
- **Efecto:** Memoriza el ruido de los datos de entrenamiento y pierde generalización.

Error de Sesgo

Asociado al Subajuste (Underfitting)

- **Origen:** Surge cuando el modelo es demasiado simple.
- **Efecto:** No logra capturar las relaciones ni la estructura real de los datos.

Error Total y Compromiso Sesgo-Varianza

- **Composición del Error:** Todo modelo tiene un error total compuesto de forma integrada por el error de sesgo y el de varianza.
- **Relación Inversa (Trade-off):** Estos errores son complementarios entre sí; al intentar reducir uno, el otro tiende a aumentar, exigiendo un punto de equilibrio óptimo.

Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

Estos errores los podemos ver si tomamos diferentes sets de entrenamiento y entrenamos el modelo con cada uno de ellos:




Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS


Si tenemos un modelo que **sobreajusta**, diferentes sets de entrenamiento nos darán modelos muy diferentes:

MUESTRA 01
Modelo 1




Ajuste extremo al conjunto 1, generando fluctuaciones drásticas.

MUESTRA 02
Modelo 2



Curva completamente diferente al cambiar los puntos de entrada.

MUESTRA 03
Modelo 3




Alta variabilidad de predicción: incapacidad de generalizar.

Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS


Si tenemos un modelo que **subajusta**, diferentes sets de entrenamiento nos darán modelos muy similares:

MUESTRA 01
Modelo 1




Línea rígida incapaz de capturar la tendencia subyacente de los datos.

MUESTRA 02
Modelo 2



Misma recta constante obtenida al cambiar el conjunto de entrenamiento.

MUESTRA 03
Modelo 3



Baja varianza entre estimaciones, pero con un elevado sesgo sistemático.

Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

MODELO SIMPLE

Alto Sesgo & Baja Varianza

Alto Sesgo Baja Varianza

El modelo más simple cometerá muchos errores en prácticamente cualquier conjunto de entrenamiento, lo que significa que tiene un **error alto de sesgo**.

Sin embargo, cuando evaluamos estos modelos con el conjunto de evaluación, el resultado siempre es similar. Entonces, decimos que tiene un **error de varianza bajo**.

MODELO COMPLEJO

Bajo Sesgo & Alta Varianza

Bajo Sesgo Alta Varianza

Por otro lado, el modelo complejo se adapta perfectamente a cada conjunto de entrenamiento. Tiene un **error de sesgo muy bajo**...


...pero un **error de varianza muy alto** (ya que dos conjuntos de entrenamiento cualesquiera probablemente darían lugar a modelos muy diferentes).

Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS


Si analizamos cada caso, observamos que el **modelo lineal** tiene un error pequeño, ya que presenta **poca varianza y poco sesgo**.

COMPLEJO (OVERFITTING) Alta Varianza




Se adapta excesivamente a los datos de entrenamiento, aumentando la varianza.

SIMPLE (UNDERFITTING) Alto Sesgo



Línea demasiado rígida e incapaz de capturar la tendencia real de los datos.

EQUILIBRADO (ÓPTIMO) Modelo Lineal



Poca varianza y poco sesgo. Logra el menor error de estimación general.

Sesgo y Varianza

CONCEPTOS FUNDAMENTALES: EVALUACIÓN DE MODELOS

REGLAS GENERALES DEL COMPROMISO

1. Relación Inversa

Cuanto más complejo es el modelo, la varianza aumentará y el sesgo disminuirá.


2. Reducción Inicial del Error

Al aumentar la complejidad, el sesgo tiende a disminuir más rápido de lo que la variabilidad aumenta, reduciendo el error total.

3. Punto de Inflexión (Sobreajuste)

Llega un punto en el que el efecto de la variabilidad es apreciable, aumentando el valor del error nuevamente.

CURVA DE ERROR vs. COMPLEJIDAD



Estrategias para disminuir el riesgo empírico

CONCEPTOS FUNDAMENTALES: TIPOS DE PARÁMETROS

Pensemos en los modelos como **cajas grises**: aún no sabemos exactamente cómo funcionan por dentro, pero entendemos que se componen de **dos tipos de parámetros**:

APRENDIZAJE DEL MODELO

Parámetros Entrenables

Definición: Son los parámetros que el modelo aprende automáticamente durante la fase de entrenamiento.

Consideración clave:

- Su cantidad total debe ser **mucho menor** que el volumen de datos de entrenamiento.
- Esto permite generalizar adecuadamente y **evitar el sobreajuste (overfitting)**.

CONFIGURACIÓN PREVIA

Hiperparámetros

Definición: Son parámetros de configuración interna que **no dependen** de los datos de entrenamiento.

Consideración clave:

- Deben ser **definidos previamente** antes de iniciar el proceso de entrenamiento.
- Controlan la estructura del modelo y el comportamiento del algoritmo de aprendizaje.

Estrategias

CONCEPTOS FUNDAMENTALES: SELECCIÓN DE HIPERPARÁMETROS

EL DESAFÍO

Dilema Inicial

Elegir los hiperparámetros adecuados es un reto fundamental: para conocer el mejor modelo deberíamos saberlos de antemano, pero para saberlos es indispensable entrenar primero.

LA ESTRATEGIA

Entrenamiento Múltiple

La práctica estándar consiste en entrenar múltiples modelos utilizando distintas combinaciones de hiperparámetros para evaluar y comparar cuál ofrece el mejor rendimiento.

EL RIESGO

Sobreajuste de Evaluación

¡Atención! Si se utiliza directamente el conjunto de evaluación para seleccionar la mejor opción, nos arriesgamos a optimizar solo para ese conjunto y perder generalización.

Estrategias

CONCEPTOS FUNDAMENTALES: SET DE VALIDACIÓN

USO Y PROPÓSITO

Set de Validación

Un tercer conjunto de datos sustraído del entrenamiento para evaluar el modelo objetivamente.

- **Hiperparámetros:** Permite evaluar y ajustar sus valores.
- **Monitoreo:** Detecta sobreajuste analizando la evolución en cada iteración (gradiente descendente en Deep Learning).
- **Integridad:** Evita usar el conjunto de evaluación final antes de tiempo ("hacer trampa").

LIMITACIONES Y SOLUCIÓN

Desafíos del Métodos

Desventajas principales:

- Es **muy sensible** a la partición o selección del conjunto de validación escogido.
- Resta datos valiosos que podrían haberse aprovechado para el entrenamiento.

Estrategia alternativa:

Validación Cruzada

Permite mitigar la pérdida de datos y reducir la sensibilidad de la muestra.

Estrategias

CONCEPTOS FUNDAMENTALES: VALIDACIÓN CRUZADA

TÉCNICA PRINCIPAL

Validación Cruzada K-Fold

Es el método estándar para evaluar modelos dividiendo el conjunto de datos en K particiones o folds.

- **Partición Equitativa:**
Los datos se dividen en K subconjuntos del mismo tamaño.
- **Entrenamiento Iterativo:**
En cada paso k, un fold sirve de validación y los K-1 restantes se usan para entrenar.
- **Métrica Global:**
Se promedian los resultados obtenidos en cada iteración para calcular el rendimiento final.

ESQUEMA VISUAL

Iteraciones en K-Fold (K=3)

Cada bloque rota la función de validación garantizando que todos los datos sean evaluados.

■ Validación (1 Fold)

■ Entrenamiento (K-1 Folds)



Estrategias

CONCEPTOS FUNDAMENTALES: VALIDACIÓN CRUZADA

PROCESO DE EVALUACIÓN

Flujo de Iteración


Esquema funcional paso a paso durante una ronda de validación cruzada:

- **Partición de Folds:**
Los datos se dividen en bloques ($k=1$, $k=2$ para entrenar y $k=3$ para evaluar).
- **Entrenamiento y Test:**
Se entrena el algoritmo con el set de entrenamiento y se evalúa el rendimiento.
- **Métrica de Error:**
Se calcula el error absoluto medio (MAE_1) producido por el modelo.

ESQUEMA VISUAL

Diagrama de Modelo y Métrica

Representación gráfica del flujo entre subconjuntos k , entrenamiento, evaluación y obtención de MAE .



Estrategias

CONCEPTOS FUNDAMENTALES: VALIDACIÓN CRUZADA

PROCESO DE EVALUACIÓN

Segunda Iteración ($k=2$)


Flujo paso a paso durante la segunda ronda de validación:

- **Partición de Folds:**
El bloque $k=2$ actúa como validación; $k=1$ y $k=3$ entrenan.
- **Entrenamiento y Test:**
Se entrena el modelo con los folds 1 y 3, evaluando en el fold 2.
- **Métrica de Error:**
Se obtiene el error absoluto medio (MAE_2) correspondiente.

ESQUEMA VISUAL

Diagrama de Modelo y Métrica

Representación gráfica del flujo con $k=2$ como validación y cálculo de MAE_2 .



Estrategias

CONCEPTOS FUNDAMENTALES: VALIDACIÓN CRUZADA

PROCESO DE EVALUACIÓN

Tercera Iteración ($k=3$)


Flujo paso a paso durante la tercera ronda de validación:

- **Partición de Folds:**
El bloque $k=3$ actúa como validación; $k=1$ y $k=2$ entrenan.
- **Entrenamiento y Test:**
Se entrena el modelo con los folds 1 y 2, evaluando en el fold 3.
- **Métrica de Error:**
Se obtiene el error absoluto medio (MAE_3) correspondiente.

ESQUEMA VISUAL

Diagrama de Modelo y Métrica

Representación gráfica del flujo con $k=3$ como validación y cálculo de MAE_3 .



Estrategias

CONCEPTOS FUNDAMENTALES: VALIDACIÓN CRUZADA

Iteración 1 (k=1)



Métrica: **MAE₁**

Iteración 2 (k=2)



Métrica: **MAE₂**

Iteración 3 (k=3)



Métrica: **MAE₃**



ESTIMACIÓN FINAL DE RENDIMIENTO

MAE Promedio Global

Promedio de los errores de cada iteración:

$$\text{MAE} = (\text{MAE}_1 + \text{MAE}_2 + \text{MAE}_3) / 3$$

Estrategias

CONCEPTOS FUNDAMENTALES: SELECCIÓN DE HIPERPARÁMETROS

Podemos repetir el procedimiento evaluando distintas familias de modelos o modificando hiperparámetros. Por ejemplo, variando el orden del polinomio:


Opción 1: Polinomio Grado 2



Modelo de menor complejidad

- Evaluación con polinomio de grado 2.
- Representado por el robot gris.
- Obtención del error **MAE** asociado.

Opción 2: Polinomio Grado 10



Modelo de mayor complejidad

- Evaluación con otro valor de hiperparámetro (Grado 10).
- Representado por el robot rojo.
- Obtención del error **MAE'** asociado.

DECISIÓN Y ENTRENAMIENTO FINAL

Comparación de Métricas (MAE)

Evaluamos y comparamos ambos MAE. Si el **robot gris** tuvo un menor error que el **robot rojo**, seleccionamos sus hiperparámetros (Grado 2). Con esto concluye la validación cruzada y se procede a entrenar el modelo final.

Estrategias

CONCEPTOS FUNDAMENTALES: VALIDACIÓN CRUZADA K-FOLD

Beneficios

- **Estrategia sistemática** para encontrar los hiperparámetros.
- Permite evaluar al menos una vez **cada punto de entrenamiento**.
- Facilita detectar y evaluar **problemas de sobreajuste**.
- Mantiene intacto el **conjunto de evaluación**.

Desventaja

- **Costo computacional alto:** Es un proceso muy lento.
- Cada modelo debe entrenarse **K veces**.

RECOMENDACIÓN PRÁCTICA

Alternativa para Grandes Volúmenes de Datos

En procesos lentos y con conjuntos de entrenamiento muy grandes, conviene usar un **conjunto de validación** único.

Estrategias

CONCEPTOS FUNDAMENTALES: REGULARIZACIÓN

Sin Regularizar

Error de Varianza Alto


Sobreajuste (Overfitting)



Con Regularización

Ajuste Equilibrado

Modelo Generalizable (Óptimo)



Mucha Regularización

Error de Sesgo Alto

Subajuste (Underfitting)





Google Colab


Ejemplo en Python

09_aprendizaje_automatico



¡Gracias!

¿Consultas?



Ing. González H. Alexis