Inteligencia Artificial

Regresión

Ing. González H. Alexis



© gonzalezhalexis@gmail.com ©

Tabla de Contenidos

01

Active Recall

Repaso del tema anterior

02

Main Content

Regresión Lineal
Tratamiento de variables
Métricas de evaluación

03

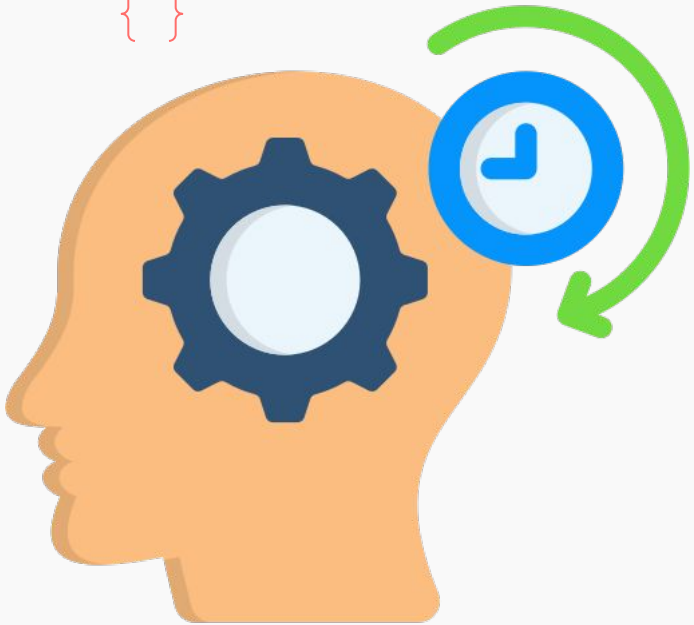
Live Coding
Pair Programming

Ejercitación & Feedback

© gonzalezhalexis@gmail.com ©

01

Active Recall



© gonzalezhalexis@gmail.com ©

Aprendizaje Supervisado

TIPOS DE APRENDIZAJE SUPERVISADO: REGRESIÓN

Problemas de Regresión

Si la variable target y es numérica, el problema es de regresión.

Variable Target (y)

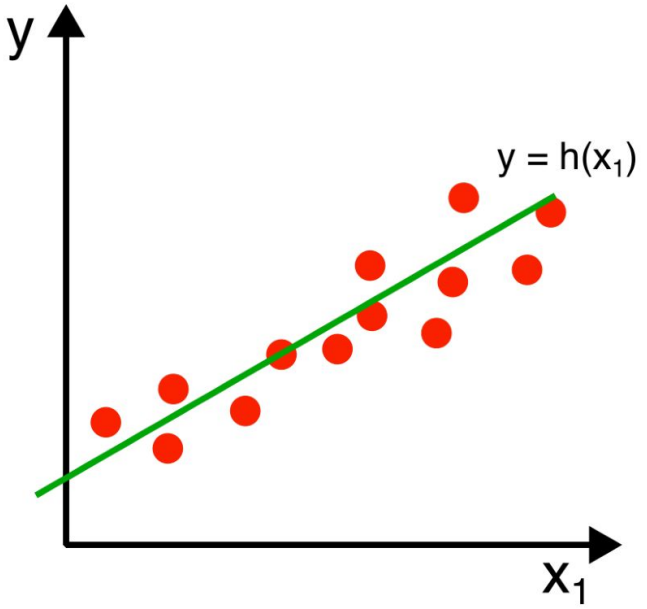
Representa la variable continua o numérica que se desea predecir mediante el modelo.

Relación de Variables

Estudia las relaciones existentes entre la variable dependiente y una o más variables independientes (X).

Ajuste de Regresión

Línea de tendencia y estimación de parámetros



© gonzalezhalexis@gmail.com ©



02

Main Content

© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

La regresión lineal es parte de una subárea del aprendizaje automático llamada **aprendizaje estadístico**, orientada al análisis formal de los datos:

Estudio & Análisis

Se enfoca en el estudio de modelos estadísticos y métodos para analizar y comprender los datos de manera rigurosa.

Inferencias & Decisiones

Utiliza herramientas y técnicas estadísticas clásicas para hacer inferencias y tomar decisiones basadas en los datos.

Objetivos Principales

Su enfoque principal puede ser la estimación de parámetros, la predicción o la inferencia sobre la relación entre variables.

© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

El modelo de regresión lineal es una combinación lineal de las variables de entrada:

$$\hat{y} = h(X) = b + w_0 x_0 + \cdots + w_d x_d$$

$$X = (x_0, x_1, \ldots, x_d)$$

Variables de Entrada

Son las características (features) de nuestras observaciones. Son todas variables numéricas.

$$b, w_0, \ldots, w_d$$

Coeficientes

Son los coeficientes del modelo. Son números reales. Cuanto más cerca de cero esté un coeficiente, menos depende la variable dependiente del feature que multiplica.

$$\hat{y}$$

Predicción

Es la predicción del modelo. Se compara con la etiqueta (label) de la observación.

© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

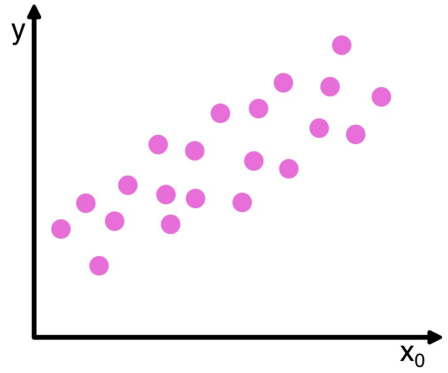
Combinación lineal de variables:

$$\hat{y} = h(X) = b + w_0 x_0 + \cdots + w_d x_d$$

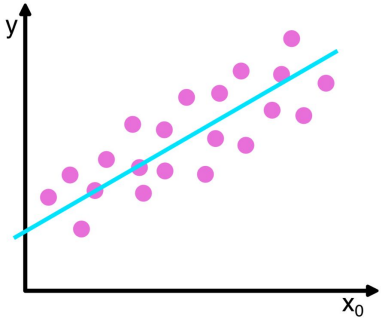
Notación matricial:

$$\hat{y} = h(X) = b + \boldsymbol{W}^T \boldsymbol{X}$$

Observaciones (X, y)

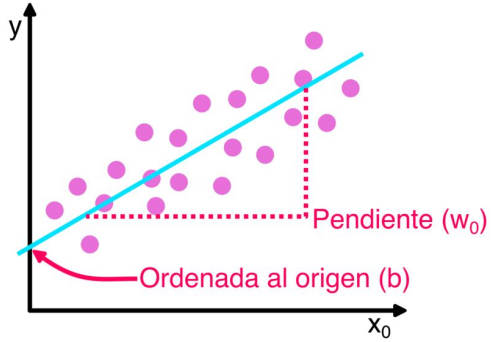


Recta de Ajuste



$$\hat{y} = h(X) = b + w_0 x_0$$

Parámetros del Modelo

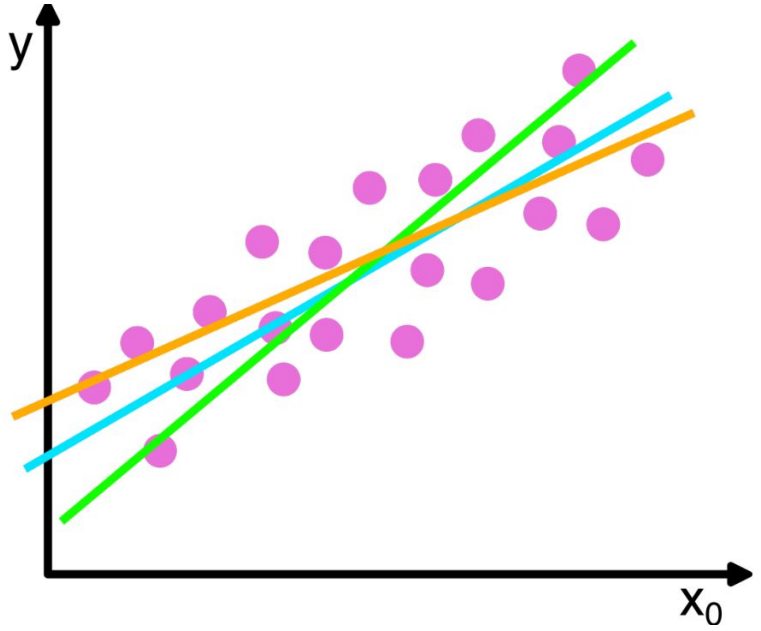


© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

¿Ahora cuál recta?



Criterio de Selección:

Se debe encontrar la línea recta que mejor se ajuste a nuestros datos, minimizando el error entre los valores reales y las predicciones del modelo.

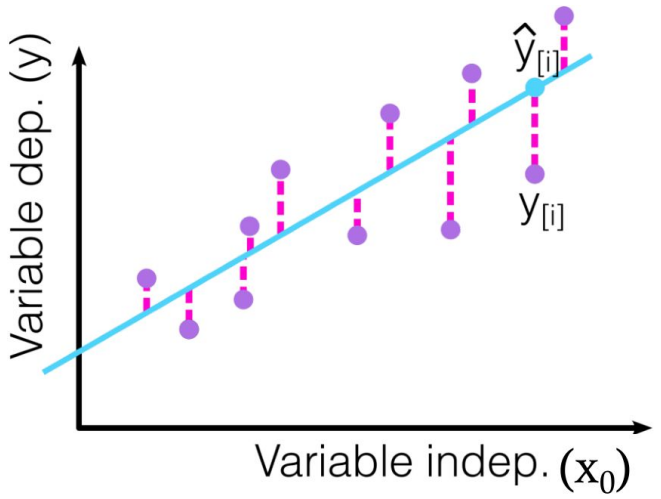
© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

Para encontrar la recta de mejor ajuste, medimos la distancia vertical entre cada punto y la recta, a lo que llamamos **residuos**.

Representación Gráfica



Formulación Matemática

1. Cálculo del residuo (error):

$$e_{[i]} = y_{[i]} - \hat{y}_{[i]}$$

2. Valor observado:

$$y_{[i]} = \hat{y}_{[i]} + e_{[i]}$$

3. Modelo con parámetros explicativos:

$$y_{[i]} = b + w_0 x_{0[i]} + e_{[i]}$$

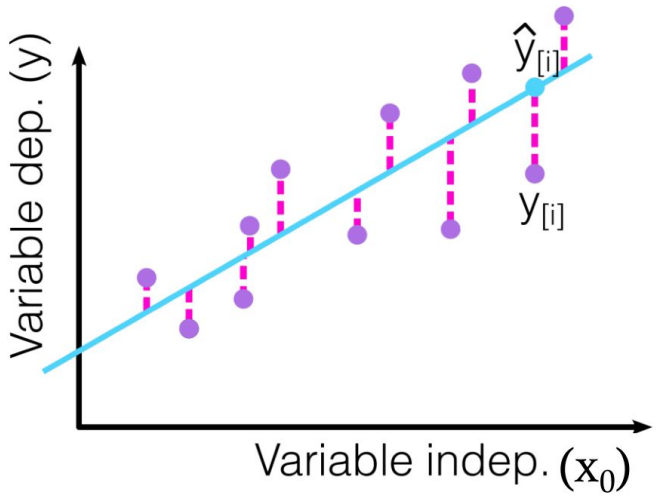
© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

Buscamos minimizar el valor de los residuos. Para lograrlo, lo hacemos minimizando la **suma de los cuadrados de los residuos**.

Representación Gráfica



Formulación Matemática

1. Suma de Cuadrados de los Residuos (S_{res}):

$$S_{res} = \sum_{i=0}^{N-1} \left(e_{[i]}\right)^2 = \sum_{i=0}^{N-1} \left(y_{[i]} - b - w_0 x_{0[i]}\right)^2$$

2. Criterio de Minimización:

$$\min(S_{res}) = \min\left(\sum_{i=0}^{N-1} \left(e_{[i]}\right)^2\right)$$

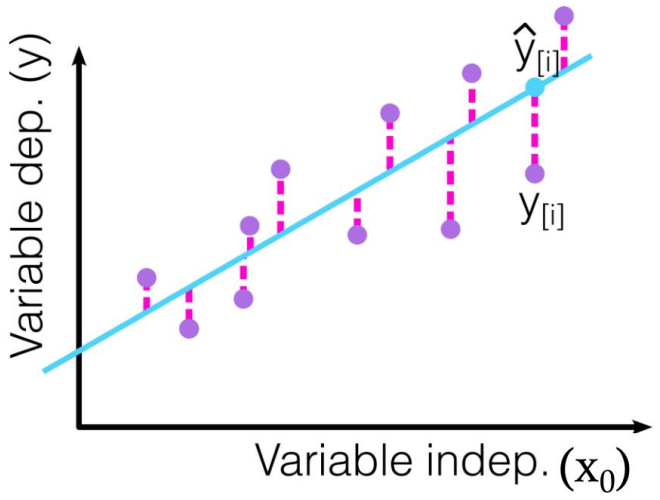
© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

Buscamos minimizar el valor de los residuos. Para lograrlo, lo hacemos minimizando la **suma de los cuadrados de los residuos**.

Representación Gráfica



Criterio de Optimización

Ajuste de coeficientes:

Para minimizar, solo podemos ajustar los coeficientes. Lo que hacemos es seguir el gradiente e igualar las derivadas parciales a cero.

Derivadas parciales (Gradiente nulo):

$$\frac{\partial S_{res}}{\partial b} = 0 \qquad \frac{\partial S_{res}}{\partial w_0} = 0$$

© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

En la regresión lineal, la función es **siempre convexa** (posee un solo mínimo global).

Formulación y Optimización

Gradiente nulo en su forma tradicional:

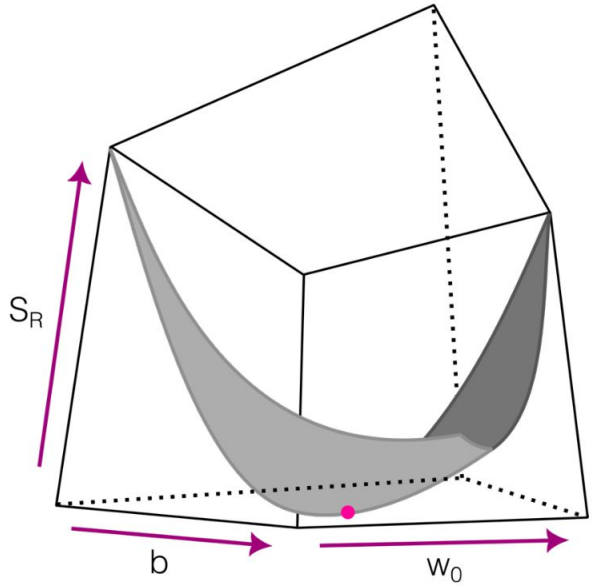
$$\frac{\partial S_{res}}{\partial b} = 0 \qquad \frac{\partial S_{res}}{\partial w_0} = 0$$

Ecuaciones Normales y Escalabilidad:

Al expresar las derivadas se obtiene un sistema de **ecuaciones normales**.

- **Problema:** Con muchos datos, resolver el sistema es muy difícil.
- **Solución:** ¡En esos casos se utiliza **gradiente descendiente**!

Superficie de Costo Convexa



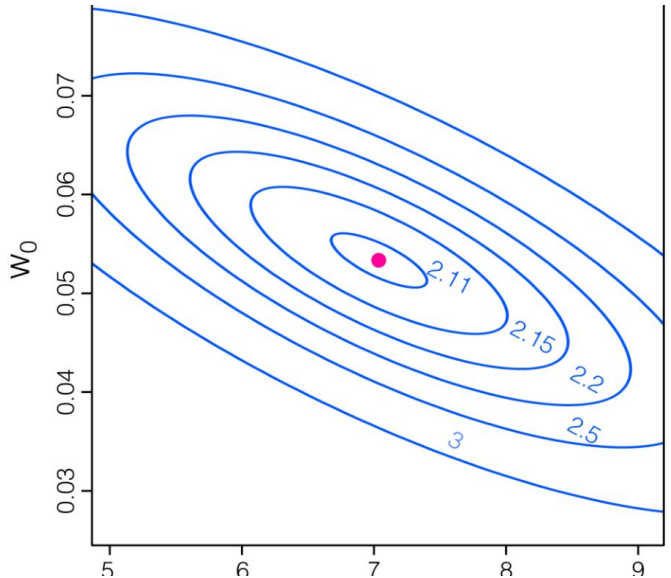
© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

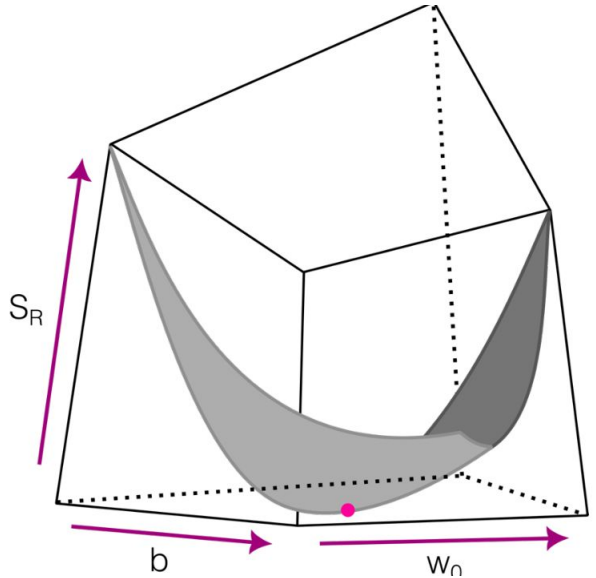
Regresión Lineal

En la regresión lineal, la función es **siempre convexa** (posee un solo mínimo global).

Curvas de Nivel (Vista 2D)



Superficie de Costo (Vista 3D)



© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

¿Cómo medimos qué tan bien se ajusta una regresión a nuestros datos? Analizando la varianza de la variable dependiente.

Varianza Total de la Variable Dependiente

Varianza total en los datos originales:

$$S_T = \sum_{i=0}^{N-1} \left(y_{[i]} - \bar{y}\right)^2$$

Descomposición en dos componentes:

Una parte atribuida al modelo y otra a los residuos.

$$S_T = S_{model} + S_{res}$$

Descomposición Suma de Cuadrados

$$S_T = \sum_{i=0}^{N-1} \left(\hat{y}_{[i]} - \bar{y}\right)^2 + \sum_{i=0}^{N-1} \left(e_{[i]}\right)^2$$

Explicada por el modelo

Mide la variabilidad capturada activamente por la función de regresión (S_{model}).

No explicada (Residuos)

Representa el error o diferencia no ajustada entre los datos y la predicción (S_{res}).

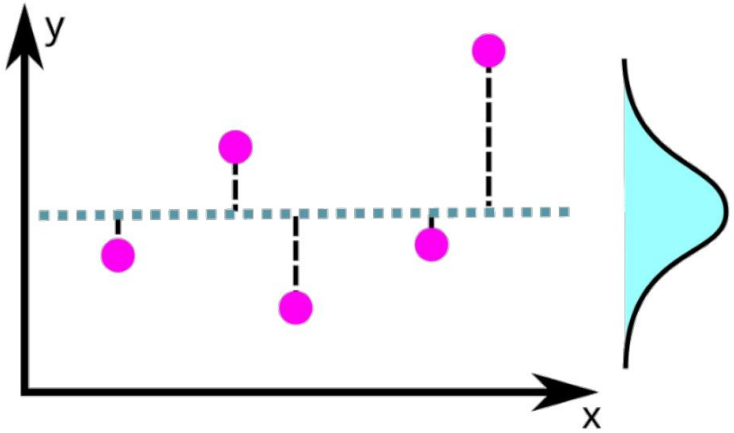
© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

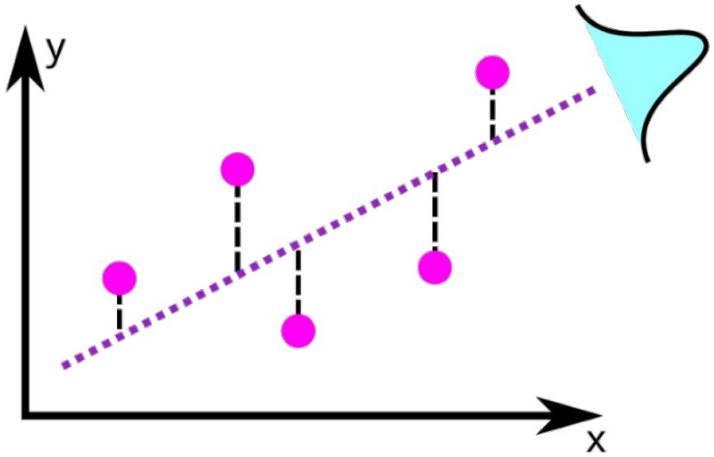
¿Cómo medimos qué tan bien se ajusta una regresión a nuestros datos? Analizando la varianza de la variable dependiente.

Varianza Total (S_T) - Modelo Base



$$S_T = \sum_{i=0}^{N-1} \left(y_{[i]} - \bar{y}\right)^2$$

Varianza Residual (S_{res}) - Modelo Ajustado



$$S_{res} = \sum_{i=0}^{N-1} \left(e_{[i]}\right)^2$$

© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

Como métricas para evaluar el modelo, podemos usar:

Desvío Estándar Residual

$$s_{res} = \sqrt{\frac{S_{res}}{N-d-1}} = \sqrt{\frac{1}{N-d-1}\sum_{i=0}^{N-1}\left(e_{[i]}\right)^2}$$

Donde: d representa la cantidad de features.

Coeficiente de Pearson (R^2)

$$R^2 = \frac{S_{model}}{S_T} = 1 - \frac{S_{res}}{S_T}$$

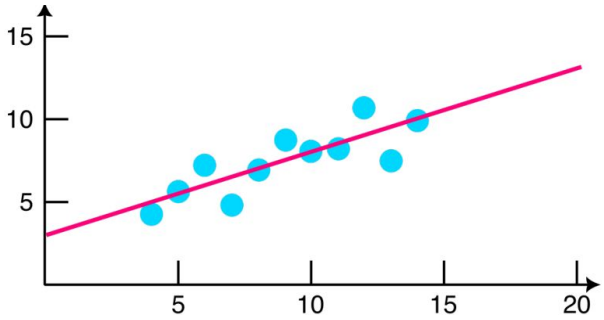
Representa la proporción de la varianza total explicada por el modelo de regresión.

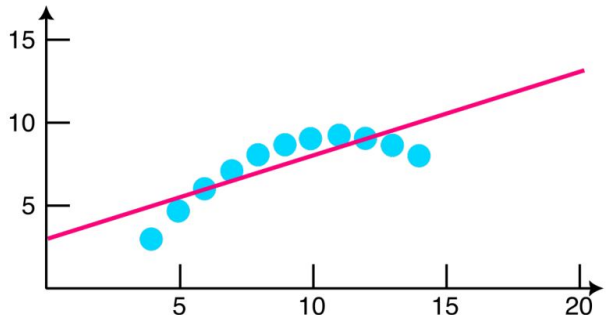
© gonzalezhalexis@gmail.com ©

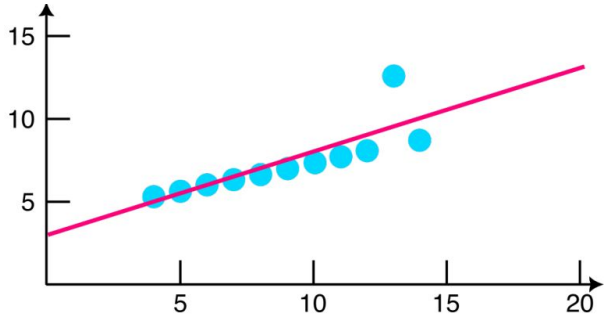
APRENDIZAJE ESTADÍSTICO

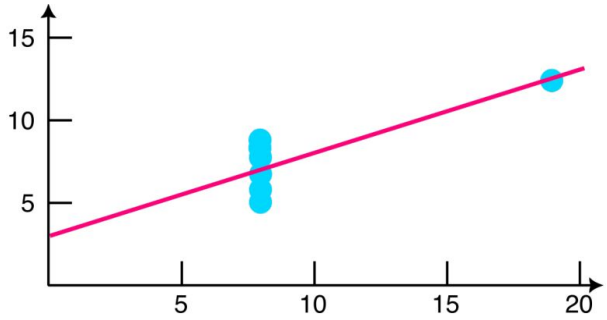
Regresión Lineal

Ajuste del Modelo: Mismos parámetros estadísticos en conjuntos con distribuciones totalmente distintas (Cuarteto de Anscombe).









© gonzalezhalexis@gmail.com ©

APRENDIZAJE ESTADÍSTICO

Regresión Lineal

Las suposiciones fundamentales para aplicar la regresión lineal son:

1Relación Lineal

Al aplicar el modelo, se busca validar la existencia de una relación lineal entre las variables.

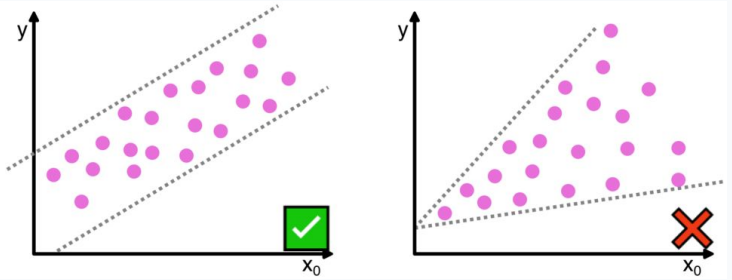
Features Independientes

Los features o variables de entrada de la regresión deben ser independientes entre sí.

Residuos N(0, σ^2)

Deben provenir de una distribución normal N(0, σ^2) y ser independientes entre sí (Homocedasticidad).

Evaluación de Homocedasticidad



© gonzalezhalexis@gmail.com ©

TRATAMIENTO DE VARIABLES

Normalización o Estandarización

En la regresión lineal, las variables de entrada interactúan directamente con sus coeficientes:

Ecuación del Modelo

$$\hat{y} = b + w_0 x_0 + w_1 x_1$$

Interpretación de Coeficientes

Los coeficientes reflejan la importancia relativa de cada entrada en la predicción. Sin embargo, esta comparación solo es válida cuando todas las variables están en la misma escala.

Impacto de Diferentes Escalas

Variable x_0
Rango: [1000, 3000]

Variable x_1
Rango: **[-1, 1]**

Consecuencia:

Los valores de w_0 y w_1 estarán en magnitudes completamente distintas y, por lo tanto, no serán comparables entre sí.

© gonzalezhalexis@gmail.com ©

TRATAMIENTO DE VARIABLES

Normalización o Estandarización

Escala [0, 1]

Una forma de normalizar es hacer que los valores estén aproximadamente entre 0 y 1, utilizando el máximo y el mínimo:

$$\tilde{x} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Cálculo sobre el Set de Entrenamiento

$\min(x)$

$\max(x)$

} Set de entrenamiento

Escala [-1, 1]

Si se necesita ajustar y centrar la normalización en un rango de -1 a 1:

$$\tilde{x} = 2\frac{x - \min(x)}{\max(x) - \min(x)} - 1$$

© gonzalezhalexis@gmail.com ©

TRATAMIENTO DE VARIABLES

Normalización o Estandarización

Estandarización (Z-Score)

Otra forma de escalar variables es aplicando la estandarización, la cual es menos sensible a los valores atípicos (outliers):

$$\tilde{x} = \frac{x - \text{mean}(x)}{\text{std}(x)}$$

Cálculo sobre el Set de Entrenamiento

Tanto la media como la desviación estándar deben obtenerse exclusivamente del conjunto de entrenamiento:

$$\left.\begin{matrix} \text{mean}(x) \\ \text{std}(x) \end{matrix}\right\} \text{Set de entrenamiento}$$

© gonzalezhalexis@gmail.com ©

TRATAMIENTO DE VARIABLES

Variables Dummies

¿Cómo codificar variables categóricas?

La regresión lineal requiere **variables numéricas** para realizar predicciones. Por ello, es necesario transformar el texto o categorías mediante codificación.

Variables Categóricas Ordinales

Tienen un orden natural implícito (ej. puntuaciones, niveles). Podemos asociarles números enteros directamente respetando dicha jerarquía.

Ejemplo: Asignación Númerica



© gonzalezhalexis@gmail.com ©

TRATAMIENTO DE VARIABLES

Variables Dummies

¿Por qué no usar números simples?

Si tenemos casos nominales no podemos asociarles números directamente, ya que, al hacerlo, estableceríamos un orden o jerarquía implícita no deseada.

Codificación: One-Hot Encoding

Para este tipo de variables existen diferentes codificaciones. Una de las más utilizadas es el **one-hot encoding**, que crea vectores binarios independientes para cada categoría.

Ejemplo: Vectorización Nomina



Ale = [1, 0, 0]
Honey = [0, 1, 0]
Stout = [0, 0, 1]

© gonzalezhalexis@gmail.com ©

TRATAMIENTO DE VARIABLES

Variables Dummies - Ejemplo

La Trampa de las Variables Dummies

El **one-hot encoding** nos genera un nuevo atributo por categoría, pero esto puede generar una trampa.

Si vemos el ejemplo, las tres variables que estamos usando están **100% correlacionadas entre sí**.

¿Cómo solucionarlo?

Para solucionar esto, **debemos eliminar siempre una columna** para romper la trampa.

Ejemplo: Matriz y Correlación

Peso	Altura	País	Argentina	Chile	Perú
80	180	Argentina	1	0	0
83	177	Chile	0	1	0
75	169	Chile	0	1	0
68	155	Argentina	1	0	0
95	199	Perú	0	0	1

Dependencia Lineal entre Atributos:

$$x_{peru} = 1 - x_{arg} - x_{chile}$$

$$\hat{y} = b + w_0 x_{peso} + w_1 x_{altura} + w_2 x_{arg} + w_3 x_{chile} + w_4 x_{peru}$$

$$\hat{y} = b + w_0 x_{peso} + w_1 x_{altura} + w_2 x_{arg} + w_3 x_{chile} + w_4 (1 - x_{arg} - x_{chile})$$

$$\hat{y} = (b + w_4) + w_0 x_{peso} + w_1 x_{altura} + (w_2 - w_4) x_{arg} + (w_3 - w_4) x_{chile}$$

© gonzalezhalexis@gmail.com ©

EVALUACIÓN Y MÉTRICAS

Métricas de Evaluación

Conjunto de Evaluación

El conjunto de datos de evaluación se utiliza para evaluar qué tan bien se entrenó el algoritmo con el conjunto de datos de entrenamiento.

Objetivo Principal

Garantizar que el modelo generalice de forma precisa antes de ser desplegado en producción con datos no vistos.

¿Pero cómo evaluamos?

- **Coeficiente de Pearson (R2)**

Mide la proporción de la varianza total explicada por el modelo de regresión.

Métricas Más Generales

Podemos usar métricas más generales, que midan el error en variables numéricas.

© gonzalezhalexis@gmail.com ©

EVALUACIÓN Y MÉTRICAS

Métricas de Evaluación

Error Absoluto Medio (MAE)

Es el cálculo del **valor absoluto del residuo** para cada punto de datos.

Luego, tomamos el promedio de todos estos residuos.

Interpretación

Representa la magnitud promedio de los errores en las predicciones, sin considerar su dirección.

Fórmula Matemática

$$MAE = \frac{1}{N}\sum_{i=0}^{N-1} |y_{[i]} - \hat{y}_{[i]}|$$

© gonzalezhalexis@gmail.com ©

EVALUACIÓN Y MÉTRICAS

Métricas de Evaluación

Error Cuadrático Medio (MSE)

El error cuadrático medio (MSE) es similar al MAE, pero ahora calculamos el **cuadrado de los residuos**.

Impacto de Outliers

Un detalle importante son los **residuos grandes (outliers)**. En esta métrica, su impacto es mayor que en el MAE.

Fórmula Matemática

$$MSE = \frac{1}{N}\sum_{i=0}^{N-1}\left(y_{[i]} - \hat{y}_{[i]}\right)^2$$

© gonzalezhalexis@gmail.com ©

EVALUACIÓN Y MÉTRICAS

Métricas de Evaluación

Raíz Cuadrada del MSE (RMSE)

Si al MSE le calculamos la **raíz cuadrada**, obtenemos una métrica llamada RMSE.

Ventaja Principal

Tiene la **misma unidad que la salida original**, a diferencia del MSE, lo que facilita su interpretación.

Fórmula Matemática

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=0}^{N-1}\left(y_{[i]} - \hat{y}_{[i]}\right)^2}$$

© gonzalezhalexis@gmail.com ©

EVALUACIÓN Y MÉTRICAS

Métricas de Evaluación

¿Incluir o Excluir Outliers?

Los valores atípicos son un tema de constante discusión. La respuesta dependerá fundamentalmente de:

- **El problema en particular:** naturaleza del dominio.
- **Los datos disponibles:** calidad y volumen.
- **Las consecuencias:** impacto de considerar o ignorar dichos valores.

Criterio de Selección de Métrica

Tenerlos en cuenta al comparar modelos

Conveniente usar **MSE**. Penaliza con mayor severidad los residuos grandes.

Reducir su importancia o impacto

Conveniente usar MAE. Asigna un peso proporcional lineal.

© gonzalezhalexis@gmail.com ©

EVALUACIÓN Y MÉTRICAS

Métricas de Evaluación

Error Absoluto Porcentual Medio (MAPE)

Es el cálculo del error MAE, pero escalado al valor verdadero, por lo que el resultado se expresa en porcentaje:

$$MAPE = \frac{100\%}{N} \sum_{i=0}^{N-1} \left| \frac{y_{[i]} - \hat{y}_{[i]}}{y_{[i]}} \right|$$

Limitaciones y Sesgo

No es una métrica ideal por su susceptibilidad a errores numéricos:

- Indefinida cuando **y[i] = 0**
- Sesgo cuando la predicción subestima

$$n = 1 \quad \hat{y} = 10 \quad y = 20$$
$$MAPE = 50\%$$

$$n = 1 \quad \hat{y} = 20 \quad y = 10$$
$$MAPE = 100\%$$

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Construcción de un Modelo

El Desafío de Selección

Al construir un modelo de regresión múltiple, determinar qué atributos incluir es fundamental.

¿Problema de Correlación?

Analizar la correlación es el primer paso, pero si dos variables están fuertemente correlacionadas, ¿cuál debemos descartar?

Por ello, se utilizan métodos sistemáticos para la selección óptima de variables.

Métodos de Construcción

Podemos mencionar 4 formas principales:

1. **Exhaustivo** (All Subsets)
2. **Eliminación hacia atrás** (Backward)
3. **Selección hacia adelante** (Forward)
4. **Eliminación bidireccional** (Stepwise)

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Construcción de un Modelo

Eliminación Hacia Atrás

Backward Elimination

Estrategia iterativa de selección de variables que evalúa la relevancia de cada atributo dentro del modelo de regresión.

Enfoque Top-Down:

Comienza desde la máxima complejidad hasta encontrar la estructura óptima del modelo.

Modelo Completo

Se comienza con un modelo completo que incluye todas las variables disponibles.

Eliminación Greedy

Se eliminan de forma secuencial las variables de entrada que menos aportan al modelo, una a la vez.

Criterio de Parada

El proceso continúa hasta que eliminar más variables no mejore significativamente el modelo.

Evaluación de Métricas

El descarte se realiza utilizando métricas específicas que miden la información aportada por cada atributo.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Construcción de un Modelo

Selección Hacia Adelante

Forward Selection

Estrategia iterativa de selección de variables que incrementa gradualmente la complejidad del modelo de regresión.

Enfoque Bottom-Up:

Comienza desde el modelo mínimo e incorpora atributos relevantes paso a paso.

Modelo Vacío

Comienza con un modelo que solo incluye la ordenada al origen.

$$\bar{y} = \frac{1}{N} \sum_{i=0}^{N-1} y_{[i]}$$

Adición Secuencial (Greedy)

Se agregan secuencialmente las variables de entrada que más aportan al modelo (usando el criterio de ajuste), una por vez.

Criterio de Parada

El proceso termina cuando agregar más variables no mejora significativamente el modelo.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Construcción de un Modelo

Eliminación Bidireccional

Stepwise Selection

Estrategia combinada de selección de variables que evalúa de forma dinámica la inclusión y exclusión en cada paso.

Enfoque Híbrido:

Es esencialmente la selección hacia adelante, pero con la posibilidad de eliminar variables en cada iteración si se observa correlación o pérdida de relevancia.

Paso Hacia Adelante (Forward Step)

Se ingresan secuencialmente las variables que más aportan al rendimiento del modelo en cada iteración.

Prueba de Eliminación (Backward Step)

Se evalúan las variables previamente incluidas y se remueven aquellas que hayan perdido significancia estadística.

Criterio de Convergencia

El proceso alternado finaliza cuando ninguna variable adicional entra ni ninguna de las actuales debe ser eliminada.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Construcción de un Modelo

¿Cómo sabemos el aporte de cada atributo?

Bondad de ajuste

Análisis estadístico para evaluar la significancia e impacto individual de cada variable independiente dentro del modelo de regresión.

Evaluación Cuantitativa:

Permite determinar con rigor si los cambios en una entrada generan cambios reales en la variable respuesta.

Prueba de Hipótesis

Se realiza una prueba de hipótesis para determinar si el coeficiente de una entrada en particular es igual a cero.

Evaluación del Valor p

Luego de la prueba, se evalúa el valor p para medir la probabilidad de que la relación observada se deba al azar.

Criterio de Significancia (< 0,05)

Un valor p bajo (< 0,05) rechaza la hipótesis nula, lo que sugiere que esta variable genera cambios significativos en la respuesta.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Construcción de un Modelo

¿Cómo sabemos el aporte de cada atributo?

Coeficiente de Pearson Ajustado

Métrica que evalúa la capacidad explicativa del modelo penalizando su complejidad técnica.

Penalización de Complejidad:

A diferencia del R^2 convencional, este coeficiente ajusta el valor según la cantidad de atributos incluidos, evitando un falso sobreajuste.

Fórmula Matemática

$$R^2_{adj} = 1 - (1 - R^2)\frac{N - 1}{N - d - 1}$$

Definición de Variables

N : Número total de observaciones.

d : Número de atributos (variables).

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Construcción de un Modelo

¿Cómo sabemos el aporte de cada atributo?

Criterio de Información de Akaike (AIC)

El AIC maneja un equilibrio entre la bondad de ajuste del modelo y la complejidad de este.

Equilibrio de Ajuste:

En otras palabras, el AIC aborda tanto el riesgo de sobreajuste como el riesgo de subajuste.

Fórmula Matemática

$$AIC = 2d - 2\ln(\hat{L})$$

Criterio de Selección

El valor de AIC debe ser **más bajo** para indicar un mejor modelo.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Construcción de un Modelo

¿Cómo sabemos el aporte de cada atributo?

Criterio de Información Bayesiano (BIC)

Se basa en el principio de la navaja de Occam, que establece que es preferible el modelo más simple que explique los datos.

Penalización de Complejidad:

A diferencia del AIC, el BIC penaliza más fuertemente al modelo por su complejidad.

Fórmula Matemática

$$BIC = d\ ln(N) - 2\ln(\hat{L})$$

Criterio de Selección

El valor de BIC debe ser **más bajo** para indicar un mejor modelo.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Ridge y Lasso

¿Cómo sabemos el aporte de cada atributo?

Métodos de Regularización

Permiten ajustar un modelo que contenga todos los atributos utilizando una técnica que restrinja o regularice las estimaciones de los coeficientes.

Reducción de Varianza:

Reducir las estimaciones de los coeficientes permite disminuir significativamente la varianza del modelo, mejorando su capacidad de generalización.

Regresión de Ridge

Penalización L2

Contrae los coeficientes de regresión hacia cero sin hacerlos exactamente cero. Mantiene todas las variables en el modelo, lo que resulta ideal cuando existen muchos atributos correlacionados.

Regresión de Lasso

Penalización L1

Fuerza algunos coeficientes de regresión a ser exactamente igual a cero. Realiza automáticamente selección de atributos, generando modelos más simples e interpretables.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Ridge

¿En qué se diferencia?

Minimización con Penalización

En la regresión lineal, vimos que se buscaban los coeficientes que minimizaban la suma de los residuos al cuadrado.

Estimación Modificada:

La regresión de Ridge es muy similar, pero con la diferencia de que los coeficientes se estiman minimizando una cantidad diferente.

Fórmula Matemática

$$\sum_{i=0}^{N-1} \left(y_{[i]} - b - \boldsymbol{W}^T \boldsymbol{X}_{[i]}\right)^2 + \alpha \sum_{j=0}^{d-1} w_j^2$$

Hiperparámetro de Ajuste

Control de Regularización

Donde **α** es un hiperparámetro de ajuste que determina la magnitud de la penalización impuesta a los coeficientes.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Ridge

Término de Penalización

Penalización por Encogimiento

En esta regresión, se buscan los coeficientes que minimizan Sres. Sin embargo, se añade el segundo término:

$$\alpha \sum_{j=0}^{d-1} w_j^2$$

Este término es pequeño cuando los coeficientes están cerca de cero, penalizando la complejidad del modelo.

Efecto del Hiperparámetro

Comportamiento cuando $\alpha \to \infty$

Nótese que la penalización no afecta la ordenada al origen *b*. Si α tiende a ∞, todos los coeficientes se vuelven cero, y la regresión queda de la siguiente forma:

$$\hat{y} = b = \frac{1}{N} \sum_{i=0}^{N-1} y_{[i]}$$

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Ridge

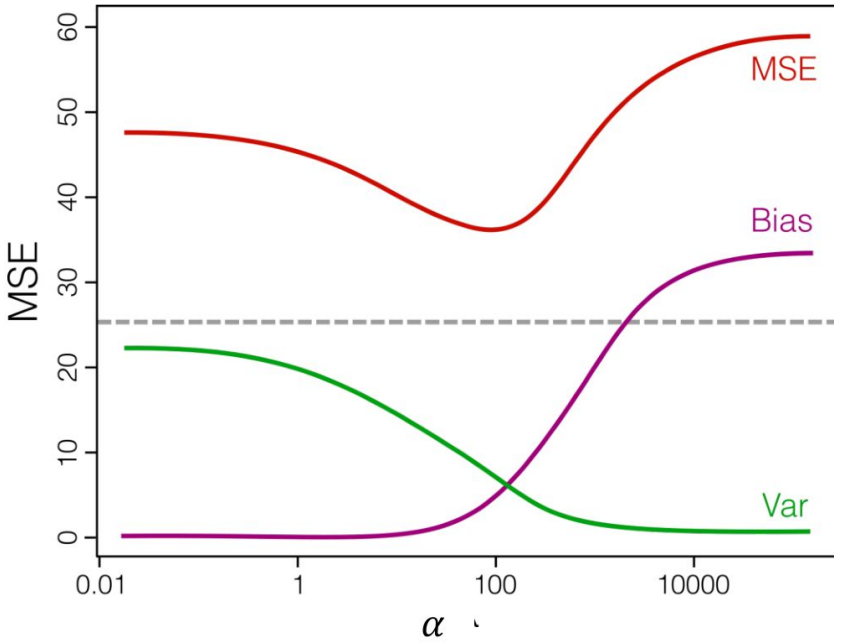
¿Para qué nos sirve?

Equilibrio Sesgo vs. Varianza

La ventaja de la regresión de Ridge sobre la regresión lineal de mínimos cuadrados radica en el equilibrio entre sesgo y varianza.

Al aumentar el parámetro α:

- La **flexibilidad** del ajuste disminuye.
- Se obtiene una **menor varianza**.
- Se incurre en un **mayor sesgo**.



© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Ridge

¿Para qué nos sirve?

Control de Varianza

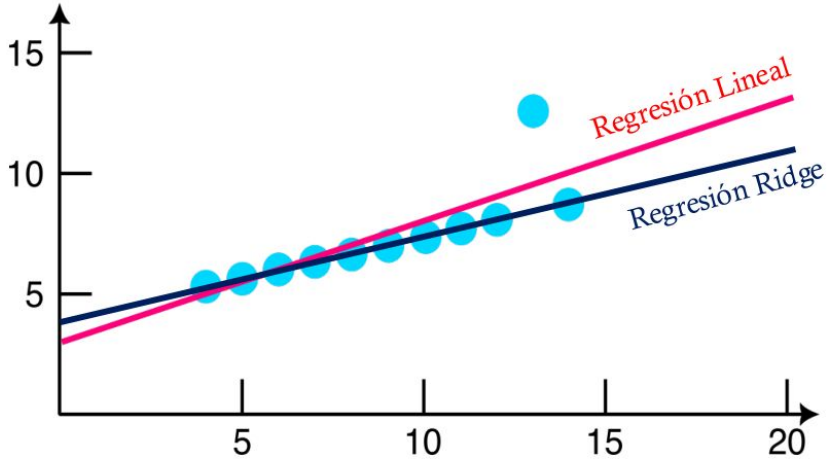
En general, cuando la verdadera relación es lineal, la regresión lineal tiende a tener **mucha varianza**.

Esto ocurre principalmente cuando:

- El número de observaciones es **cercano** al número de coeficientes.

Ajuste vs. Sensibilidad

Regresión Lineal vs. Regresión Ridge



© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Lasso

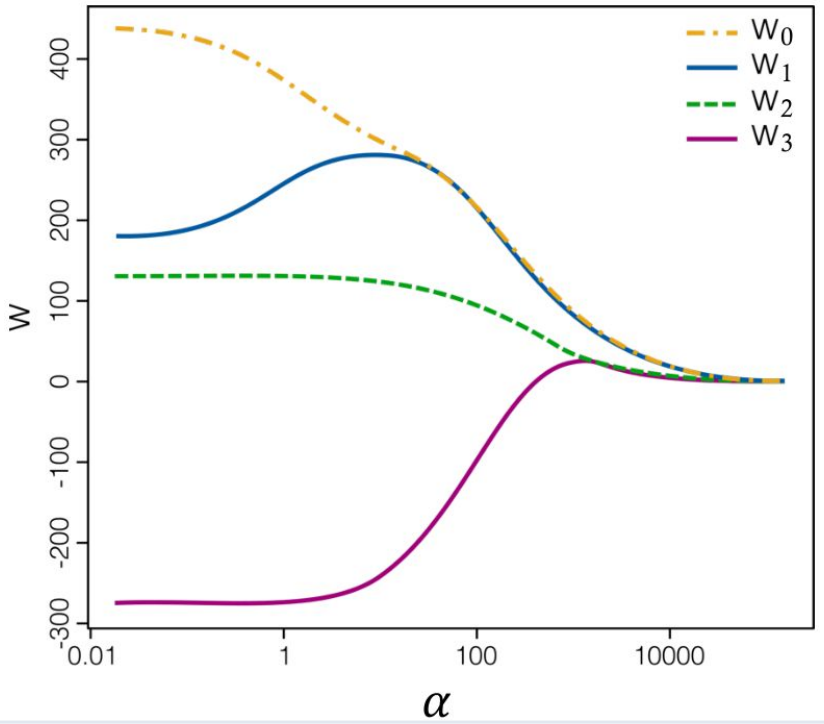
¿Por qué no Ridge?

Selección de Modelos

La regresión de Ridge, a priori, parece interesante para seleccionar modelos, ya que al ajustar α se observa si los coeficientes se acercan a cero.

El problema principal:

- Los coeficientes **se reducen hacia cero**, pero **nunca son exactamente cero** (a menos que α = ∞).
- Por lo tanto, **no podemos eliminar atributos** para simplificar el modelo.



© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Lasso

Solución a la Desventaja

Penalización L1 vs. L2

La regresión de Lasso cubre esta desventaja incorporando un término de penalización que permite reducir los coeficientes exactamente a cero.

Diferencia clave:

- **Lasso (L1):** Produce esparsidad (selección de variables).
- **Ridge (L2):** Reduce coeficientes sin eliminarlos.

Formulación Matemática

Función de Costo con Penalización L1



Componentes de la ecuación:

Error Cuadrático: Mide el ajuste del modelo a los datos observados.

Penalización α ∑|w□|: Aplica la norma L1 sobre los pesos w, forzando la esparsidad.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Lasso

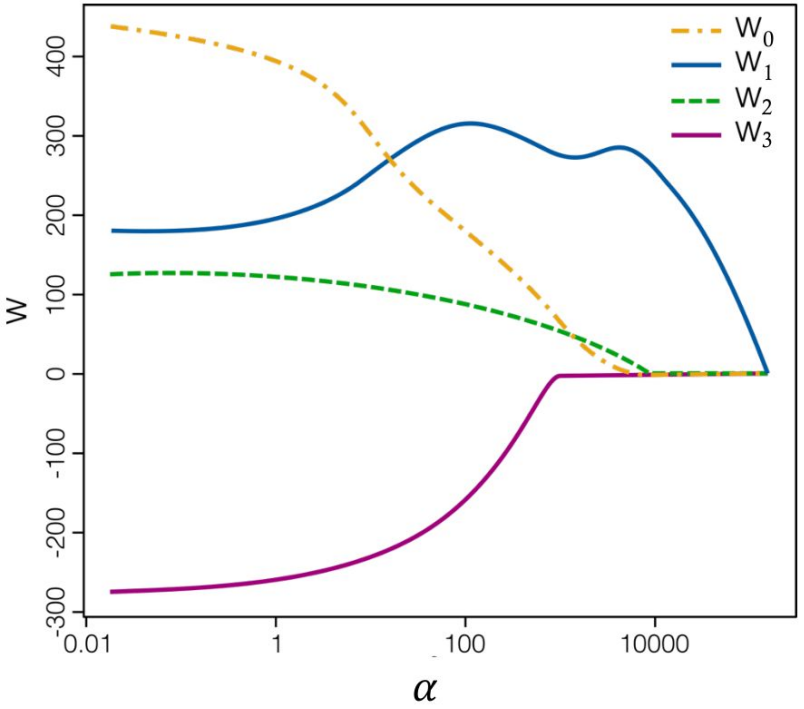
Selección de Atributos

Efecto del Parámetro α

A diferencia de la regresión Ridge, la penalización L1 en Lasso tiene una propiedad clave sobre los coeficientes.

Comportamiento principal:

- **Coeficientes a cero:** Conforme **α crece**, algunos coeficientes se convierten **exactamente en cero**.
- **Esparsidad:** Realiza una selección automática de variables descartando los atributos menos relevantes.



© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Lasso

¿Para qué nos sirve?

Para entender por qué esto ocurre, debemos reescribir las regresiones de una forma equivalente:

Regresión Lasso

Formulación con Restricción L1

$$min\left\{\sum_{i=0}^{N-1}\left(y_{[i]}-b-\boldsymbol{W}^T\boldsymbol{X}_{[i]}\right)^2\right\}$$

$$sujeto\ a\ \sum_{j=0}^{d-1}|w_j| \leq s$$

Regresión Ridge

Formulación con Restricción L2

$$min\left\{\sum_{i=0}^{N-1}\left(y_{[i]}-b-\boldsymbol{W}^T\boldsymbol{X}_{[i]}\right)^2\right\}$$

$$sujeto\ a\ \sum_{j=0}^{d-1} w_j^2 \leq s$$

© gonzalezhalexis@gmail.com ©

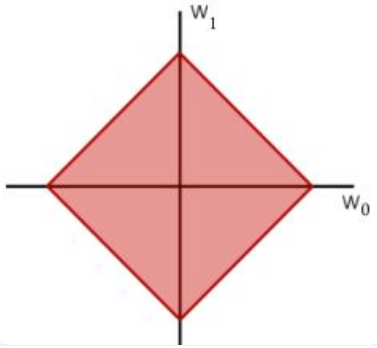
REGRESIÓN MÚLTIPLE

Regresión de Lasso

¿Para qué nos sirve? — Efecto de la penalización en 2 atributos (d = 2):

Regresión Lasso

Penalización L1: $|w_0| + |w_1| \leq s$

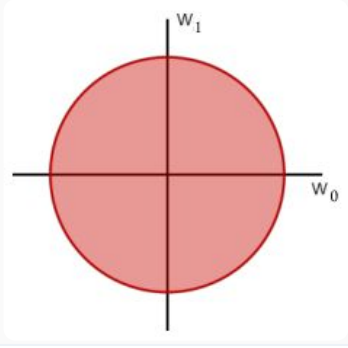


Geometría en Diamante (L1):

• Los vértices tocan los ejes, obligando a ciertos coeficientes a ser **exactamente cero** (Esparsidad).

Regresión Ridge

Penalización L2: $w_0^2 + w_1^2 \leq s$



Geometría Circular (L2):

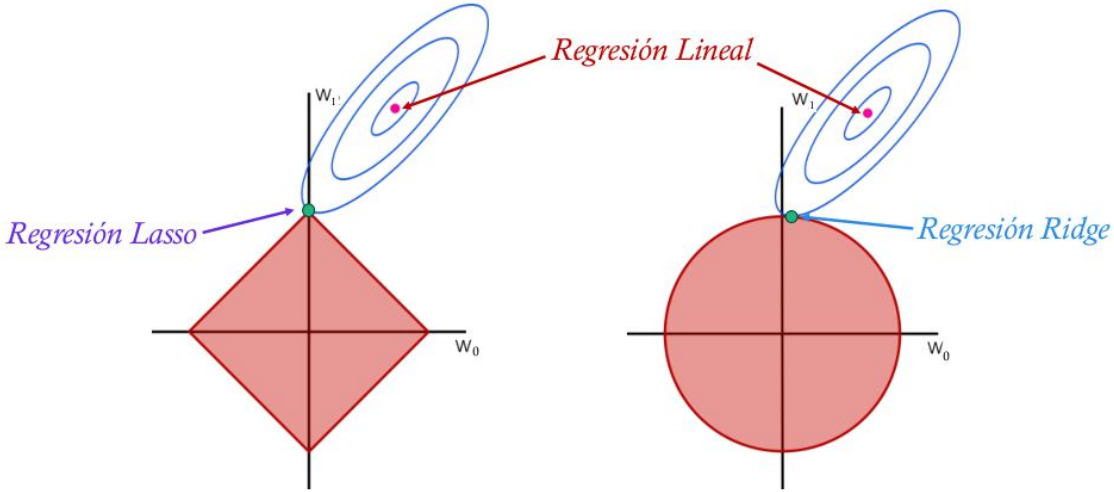
• Borde suave sin esquinas sobre los ejes; reduce la magnitud de los pesos **sin anularlos por completo**.

© gonzalezhalexis@gmail.com ©

REGRESIÓN MÚLTIPLE

Regresión de Lasso

¿Para qué nos sirve? — Efecto de la penalización en 2 atributos (d = 2):



Regresión Lasso (Penalización L1)

La restricción en diamante toca la elipse en los vértices sobre los ejes, forzando coeficientes a ser **exactamente cero** (esparsidad).

Regresión Ridge (Penalización L2)

La restricción circular suave contacta la elipse fuera de los ejes, reduciendo la magnitud de los pesos **sin anularlos**.

© gonzalezhalexis@gmail.com ©

Google Colab

Ejemplo en Python

10_regresion



© gonzalezhalexis@gmail.com ©

Actividad individual opcional

- Consigna:
-
- En este ejercicio deben predecir la tasa de fertilidad (Fertility) de 47 provincias suizas a partir del resto de sus atributos socioeconómicos (Agriculture, Examination, Education, Catholic, Infant.Mortality), entrenando y comparando dos modelos de regresión.
- Primero, deben completar la celda de regresión lineal múltiple: armar un pipeline que escale los atributos con StandardScaler y entrene un LinearRegression con todos ellos, obtener las predicciones sobre el set de testeo, y calcular e imprimir MAE, MSE y R^2.
- Después, deben completar la celda del modelo regularizado: elegir entre Ridge o Lasso (pista: tiene que poder hacer selección automática de variables, descartando coeficientes que no aportan), armar un pipeline con escalado y el modelo elegido, buscar automáticamente el mejor alpha con validación cruzada de 3 folds (usando LassoCV/RidgeCV y el array alphas ya dado), entrenar, predecir, calcular las mismas tres métricas, e imprimir los coeficientes identificando qué variables quedaron eliminadas (coeficiente = 0).
- Por último, deben completar la tabla comparativa con las métricas de ambos modelos y justificar por escrito cuál tuvo mejor desempeño general, considerando las tres métricas y la complejidad del modelo..



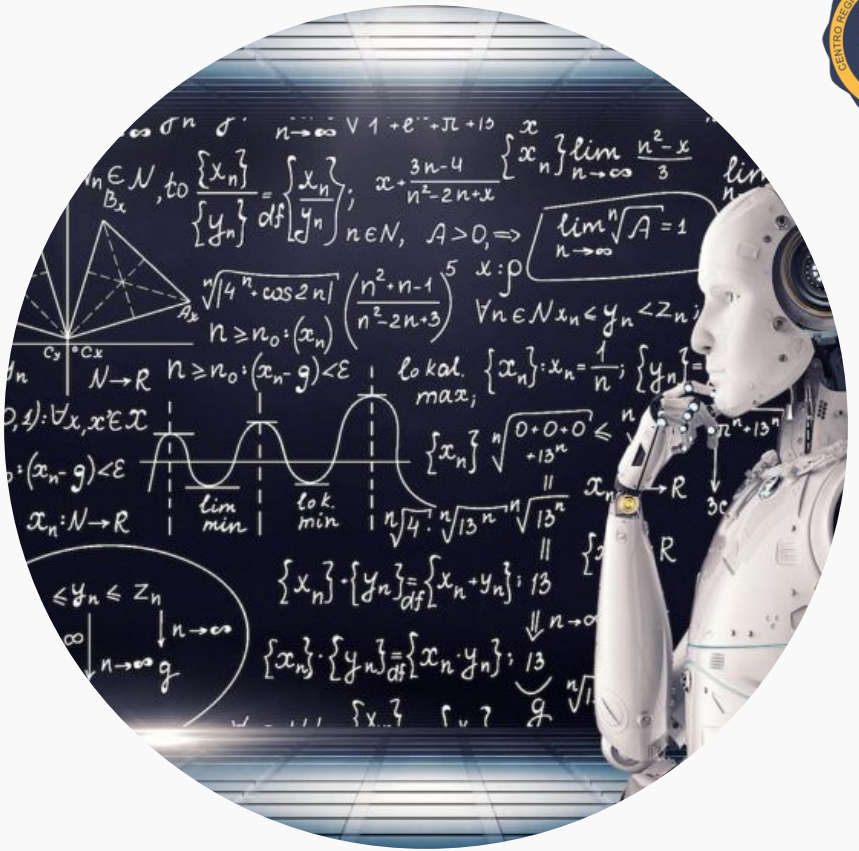


Entrega	Preguntas correctas	Puntos
No	-	0
Si	No cumple consigna	0
Si	Cumple consigna	1

© gonzalezhalexis@gmail.com ©

¡Gracias!

¿Consultas?



Ing. González H. Alexis

© gonzalezhalexis@gmail.com ©