Inteligencia Artificial

Clasificación

Ing. González H. Alexis



© gonzalezhalexis@gmail.com ©

Tabla de Contenidos

01

Active Recall

Repaso del tema anterior

02

Main Content

Clasificación
Regresión Logística
- Definición,
- Ajuste,
- Regresión logística multiclase

03

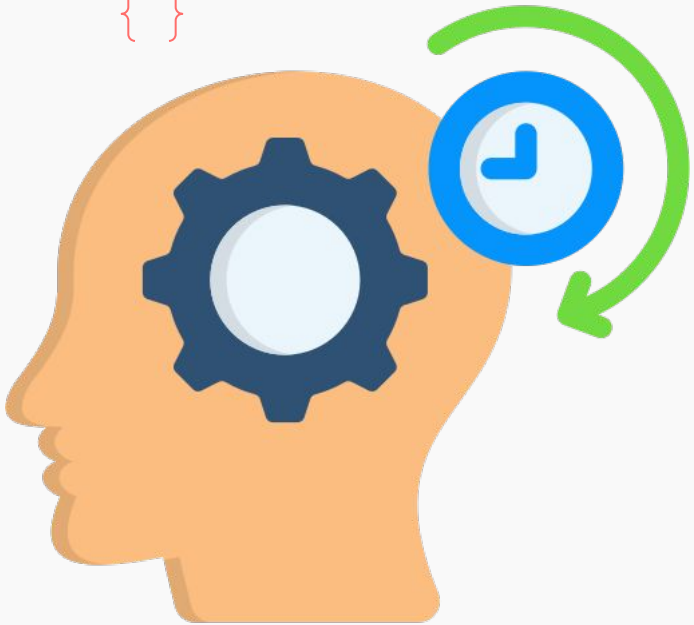
Live Coding Pair Programming

Ejercitación & Feedback

© gonzalezhalexis@gmail.com ©

01

Active Recall



© gonzalezhalexis@gmail.com ©

Problemas de Clasificación

APRENDIZAJE SUPERVISADO: CASOS DE USO Y CONCEPTO

Ejemplos Frecuentes

Es más común encontrar problemas de clasificación que de regresión:

1. Diagnóstico Médico

Asignación de un paciente a una de tres condiciones médicas según un conjunto de síntomas.

2. Detección de Fraude

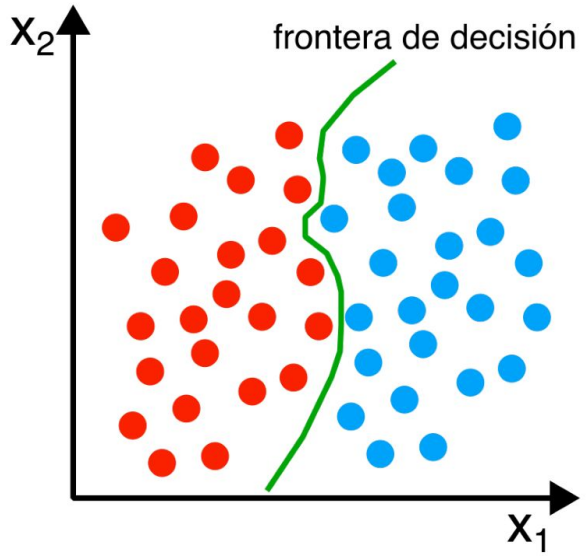
Determinación de transacciones bancarias fraudulentas según IP e historial transaccional.

3. Genómica y Salud

Identificación de mutaciones nocivas en secuencias de ADN asociadas a una enfermedad.

Frontera de Decisión

Separación visual entre clases



© gonzalezhalexis@gmail.com ©

Clasificación

LIMITACIONES DE LA REGRESIÓN LINEAL EN VARIABLES CATEGÓRICAS

Codificación Planteada

Mapeo numérico arbitrario para el modelo:

1 — ACV
Etiqueta asignada valor 1

2 — Sobredosis
Etiqueta asignada valor 2

3 — Ataques Epilépticos
Etiqueta asignada valor 3

Se intenta predecir la condición del paciente aplicando un modelo de regresión lineal estándar.

Problema del Enfoque

Supuestos implícitos erróneos

1. Implica un Orden Ficticio

Obliga al modelo a considerar que "Sobredosis" (2) está entre "ACV" (1) y "Ataques epilépticos" (3), sin existir una relación secuencial real.

2. Asume Distancias Iguales

Fuerza la condición de que la distancia clínica/matemática entre ACV y Sobredosis es idéntica a la distancia entre Sobredosis y Ataques epilépticos.

© gonzalezhalexis@gmail.com ©

Clasificación

LIMITACIONES DE LA REGRESIÓN LINEAL EN VARIABLES CATEGÓRICAS

Codificación Alternativa

Nuevo mapeo numérico para las variables:

1 — Ataques Epilépticos
Etiqueta asignada valor 1

2 — ACV
Etiqueta asignada valor 2

3 — Sobredosis
Etiqueta asignada valor 3

Esta reasignación genera una relación matemática totalmente diferente entre las observaciones.

Impacto del Cambio

Modelos generados y excepciones

1. Variación en Coeficientes

Cada codificación arbitraria produce modelos lineales distintos que conducen a coeficientes diferentes sobre las observaciones de prueba.

2. Excepción: Variables Ordinales

Si el target es una variable categórica ordinal, el orden tiene sentido. En este caso se encuentra en un área gris la elección entre modelos de clasificación y regresión.

© gonzalezhalexis@gmail.com ©

Clasificación

RESPUESTAS BOOLEANAS Y REGRESIÓN LINEAL

Contexto del Modelo

Clasificación con respuestas booleanas

Variable Binaria (0 ó 1)

Se analiza la presencia o ausencia de una condición diagnóstica:

- **ACV = 1:** Presenta la condición
- **ACV = 0:** No presenta la condición

En este escenario, se demuestra que adaptar un modelo de regresión lineal equivale a estimar la probabilidad condicional del evento dado las variables de entrada X.

Estimación Formada

Expresión de la probabilidad condicional

La probabilidad de tener la condición dado un conjunto de entradas **X** se expresa formalmente como:

$$P(ACV = 1|\boldsymbol{X}) = b + \boldsymbol{W}^{\boldsymbol{T}}\boldsymbol{X}$$

Interpretación de componentes:

- **b:** Intercepto o término de sesgo (bias).
- **WTX:** Producto escalar entre los pesos y las variables de entrada.

© gonzalezhalexis@gmail.com ©



02

Main Content

© gonzalezhalexis@gmail.com ©

Regresión Logística

MODELADO DE PROBABILIDAD Y CLASIFICACIÓN

Concepto General

Probabilidad de pertenencia a una clase

Lo que buscamos modelar en la regresión logística no es el label *y*, sino la probabilidad de que *y* pertenezca a una clase en particular:

$$P(y = k|\boldsymbol{X})$$

Clasificación Multiclase

En una clasificación multiclase, *k* puede tomar varios valores discretos:

- Valores numéricos: *k* = 0, 1, 2, …
- Etiquetas categóricas: "perro", "gato", "cebra".

Clasificación Binaria

Caso de dos clases exclusivas

En el escenario de clasificación binaria, la variable de respuesta solo puede asumir dos estados posibles (0 ó 1):

$$P(y = 0|\boldsymbol{X})$$
$$P(y = 1|\boldsymbol{X})$$

Interpretación de Probabilidades:

Se estiman las probabilidades condicionales asociadas a la presencia (1) o ausencia (0) del evento dado el vector de características **X**.

© gonzalezhalexis@gmail.com ©

Regresión Logística

MODELADO DE PROBABILIDAD Y CLASIFICACIÓN

Simplificación de Notación

Formulación matemática para dos clases

En el caso de dos clases:

$$P(y = 1|\boldsymbol{X}) = 1 - P(y = 0|\boldsymbol{X})$$

Por lo tanto, podemos simplificar la notación:

$$P(y = 1|\boldsymbol{X}) = p(\boldsymbol{X})$$

Consideraciones Clave

Propiedades fundamentales

Rango de Valores:

Las probabilidades son valores que van entre 0 y 1.

$$0 \leq P \leq 1$$

Caso Univariado:

Para simplificar aún más, consideremos el caso de un solo atributo: p(x)

$$p(x)$$

© gonzalezhalexis@gmail.com ©

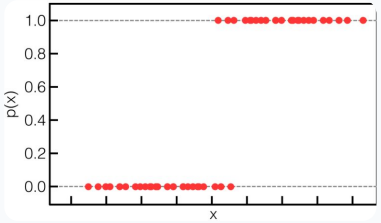
Regresión Logística

MODELADO DE PROBABILIDAD Y CLASIFICACIÓN

Problema de la Regresión Lineal

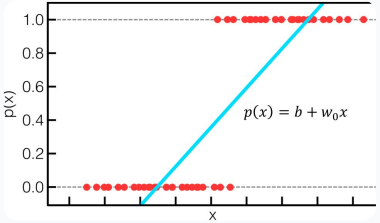
Predicciones fuera del rango [0, 1]

Al intentar predecir probabilidades con un ajuste lineal clásico, la función se extiende indefinidamente y puede producir valores incoherentes (menores a 0 o superiores a 1).



Datos Dispersos

Clases 0 y 1



Ajuste Lineal

Sobrepasa [0, 1]

Solución: Función Sigmoide

Mapeo acotado entre 0 y 1

Para evitar esto, podemos modelar la probabilidad utilizando una función que nos asegure que siempre tendremos valores entre 0 y 1.

En la regresión logística, esto se resuelve utilizando una función sigmoide:

$$p(x) = \frac{e^{b+w_0 x}}{1 + e^{b+w_0 x}} = \frac{1}{1 + e^{-(b+w_0 x)}}$$

Propiedad Fundamental:

Transforma cualquier valor real continuo de entrada en un valor acotado de probabilidad

$$0 \leq p(x) \leq 1$$

© gonzalezhalexis@gmail.com ©

Regresión Logística

MODELADO DE PROBABILIDAD Y CLASIFICACIÓN

Despeje Matemático

Transformación de la Ecuación Sigmoide

Si manipulamos la ecuación:

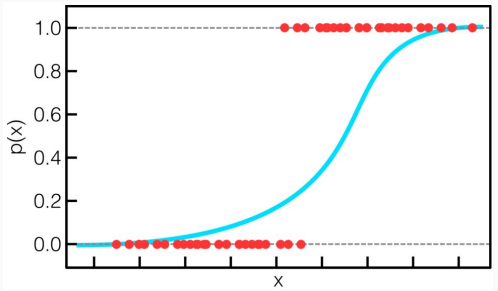
$$p(x) = \frac{e^{b+w_0 x}}{1+e^{b+w_0 x}}$$

Llegamos a:

$$\frac{p(x)}{1-p(x)} = e^{b+w_0 x}$$

Concepto de Chance (Odds)

Proporción de Probabilidades Complementarias



Este término es conocido como **chance** (o en inglés **odds**), la proporción entre dos probabilidades complementarias. Valores entre **0 e infinito**.

Ejemplo Ilustrativo:

Probabilidad de sábado = **1/7**
Chance (Odds) = **1/6** (1 a 6 de que sea sábado).

© gonzalezhalexis@gmail.com ©

Regresión Logística

MODELADO DE PROBABILIDAD Y CLASIFICACIÓN

Formulación Matemática

Deducción de la Función Logit

Si aplicamos el logaritmo de ambos lados:

$$logit(p) = ln\left(\frac{p(x)}{1-p(x)}\right) = b + w_0 x$$

Obtenemos la función logit:

Expresa el logaritmo neperiano de la proporción de probabilidades (chance u odds), vinculando la probabilidad de un evento con una combinación lineal de variables.

Interpretación y Uso

Propiedades Principales

Transformación de Variables

La función logit se utiliza para transformar variables de entrada en un rango que puede interpretarse directamente como probabilidades.

Relación Lineal

En la regresión logística, esta es una relación lineal respecto a los coeficientes del modelo, permitiendo estimar fácilmente los parámetros.

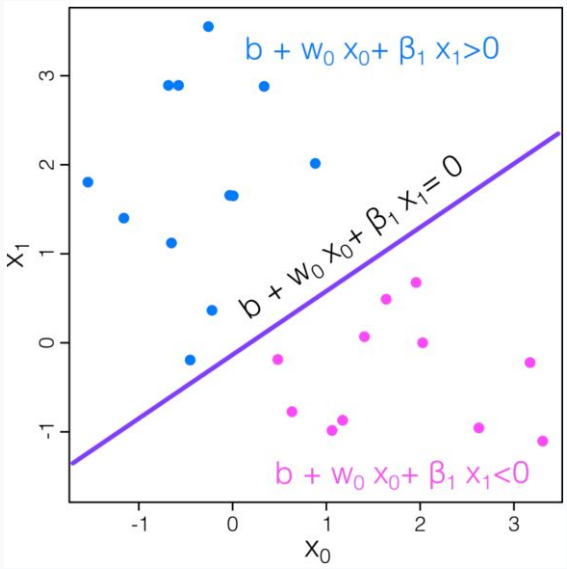
© gonzalezhalexis@gmail.com ©

Regresión Logística

AJUSTE DEL MODELO Y MÁXIMA VEROSIMILITUD

Clasificador Lineal

Frontera de Decisión



Ajuste de Parámetros

Estimación de Coeficientes

Entrenamiento del Modelo

Para encontrar los coeficientes **(b y w0)**, es decir, entrenar el modelo, lo hacemos mediante **máxima verosimilitud**.

Objetivo de Optimización

Tratamos de encontrar **b** y **w0** tales que las estimaciones sean:

- **Clase positiva:** lo más cercanas a 1.
- **Clase negativa:** lo más cercanas a 0.

© gonzalezhalexis@gmail.com ©

Regresión Logística

AJUSTE DEL MODELO Y FUNCIÓN DE VEROSIMILITUD

Función de Verosimilitud

Formulación Matemática

Matemáticamente, la función de verosimilitud es:

$$l(b, w_0) = \prod_{i=1}^{N} p(x_i)^{y_i} \ (1 - p(x_i))^{1-y_i}$$

Función de Log-Verosimilitud

Objetivo de Optimización

Similar a la regresión lineal, es mejor minimizar la función log-verosimilitud multiplicada por -1:

$$(b, w_0) = -\sum_{i=1}^{N} y_i \ln(p(x_i)) + (1 - y_i)\ln(1 - p(x_i))$$

© gonzalezhalexis@gmail.com ©

Regresión Logística

AJUSTE DEL MODELO Y GRADIENTE DESCENDENTE

Criterio de Optimización

Condición de Primer Orden

Para encontrar el mínimo, aplicamos el gradiente:

$$\frac{\partial J}{\partial b} = 0$$

$$\frac{\partial J}{\partial w_0} = 0$$

Métodos de Resolución

Solución Numérica e Iterativa

Ausencia de Solución Analítica

No es posible despejar directamente los parámetros de forma cerrada igualando las derivadas a cero.

Estrategias de Optimización

Para resolver este sistema se requieren:

- **Métodos Numéricos** aproximados.
- **Gradiente Descendente** para actualización iterativa.

© gonzalezhalexis@gmail.com ©

Regresión Logística Múltiple

EXTENSIÓN A MÚLTIPLES VARIABLES PREDICTORAS

Función Logit (Log-Odds)

Relación Lineal

Relación lineal entre las variables de entrada y el logit de la probabilidad:

$$logit(p) = ln\left(\frac{p(\boldsymbol{X})}{1-p(\boldsymbol{X})}\right) = b + \boldsymbol{W}^T\boldsymbol{X}$$

Probabilidad Estimada

Función Sigmoide Múltiple

Cálculo directo de la probabilidad posterior p(X) dada la combinación lineal:

$$p(\boldsymbol{X}) = \frac{e^{b+\boldsymbol{W}^T\boldsymbol{X}}}{1+e^{b+\boldsymbol{W}^T\boldsymbol{X}}}$$

© gonzalezhalexis@gmail.com ©

Regresión Logística Multiclase

EXTENSIÓN A MÚLTIPLES CLASES

Concepto General

De Clasificación Binaria a Multiclase

Los clasificadores binarios solo predicen 2 clases.

Para predecir 3 o más clases (ej: perro, gato, tero), se pueden crear regresiones logísticas individuales.



Problema de Probabilidades

Suma de Valores Independientes

Observación particular:

[0.73, 0.55, 0.20]

Valores obtenidos al evaluar las tres regresiones logísticas de forma independiente.

Suma Total Mayor a Uno

$0.73 + 0.55 + 0.20 = 1.48$

Esto va en contra del objetivo fundamental de mantener la probabilidad acotada en el rango de 0 a 1 para clases mutuamente excluyentes.

© gonzalezhalexis@gmail.com ©

Regresión Logística Multiclase

Normalización y Salida

Valores de Probabilidad y One-Hot Encoding

Si normalizamos los tres valores con respecto a la suma, recuperamos la propiedad deseada:

$$\left[\frac{0.73}{1.48}, \frac{0.55}{1.48}, \frac{0.2}{1.48}\right]$$

$$[0.49, 0.38, 0.13]$$

La clase más probable es **perro** (valor más alto).

Esta salida tiene forma de *one-hot encoding*:

$$[1, 0, 0]$$

Formulación Matemática

Regresión Logística Multiclase

Este proceso es lo que conocemos como regresión logística multiclase:

$$P(y = k|X) = \frac{e^{b_k + \boldsymbol{W}_k^T \boldsymbol{X}}}{\sum_k e^{b_{(k)} + \boldsymbol{W}_{(k)}^T \boldsymbol{X}}}$$

Se reduce a la fórmula tradicional para 2 clases realizando:

- $b = b_1 - b_0$
- $\mathbf{W} = \boldsymbol{W}_1 - \boldsymbol{W}_0$

© gonzalezhalexis@gmail.com ©

Regresión Logística Multiclase

ELECCIÓN DE LA CLASE DE REFERENCIA

Fundamento Teórico

Reducción de Parámetros

De hecho, no importa cuántas clases haya, siempre podemos elegir una clase y hacer que todos sus parámetros sean cero, sin perder generalidad.

Esto es posible porque la probabilidad de una clase está formada por el complemento de las otras.

Convención de Selección

Por convención, se elige generalmente la primera clase (k = 0) como referencia para fijar sus coeficientes en cero.

Formulación Matemática

Ecuaciones de Probabilidad

Primera Clase (k = 0):

$$P(y = 0|\boldsymbol{X}) = \frac{1}{1 + \sum_{k=1}^{K-1} e^{b_{(k)} + \boldsymbol{W}_{(k)}^T \boldsymbol{X}}}$$

Resto de las Clases (k > 0):

$$P(y = k|\boldsymbol{X}) = \frac{e^{b_k + \boldsymbol{W}_k^T \boldsymbol{X}}}{1 + \sum_{k=1}^{K-1} e^{b_{(k)} + \boldsymbol{W}_{(k)}^T \boldsymbol{X}}}$$

© gonzalezhalexis@gmail.com ©

Clasificador Bayesiano Ingenuo

TEOREMA DE BAYES

Fundamento Teórico

Definición y Aplicación

Este teorema es uno de los más importantes en probabilidad y genera profundas implicancias teóricas.

Describe la probabilidad de un evento basándose en el conocimiento previo de condiciones que pueden estar relacionadas con él.

Ejemplo Práctico:

Si el riesgo de salud aumenta con la edad, el teorema permite evaluar con mayor precisión el riesgo para un individuo de edad conocida, condicionando la probabilidad en lugar de asumir que representa a la población general.

Formulación Matemática

Ecuaciones del Teorema

$$P(H|E) = \frac{P(H)P(E|H)}{P(E)}$$

$$P(H|E) = \frac{P(H)P(E|H)}{P(H)P(E|H) + P(!H)P(E|!H)}$$

Probabilidad a Posteriori:

Este nuevo valor resultante es lo que se conoce como la probabilidad a posteriori: representa la creencia actualizada sobre la hipótesis luego de observar la evidencia.

© gonzalezhalexis@gmail.com ©

Clasificador Bayesiano Ingenuo

TEOREMA DE BAYES

Fundamento Teórico

Definición y Aplicación

Una de las aplicaciones de este teorema es el clasificador bayesiano ingenuo.

Este clasificador utiliza la probabilidad de observar atributos, dado un resultado, para estimar la probabilidad de observar un resultado y, dado un conjunto de atributos.

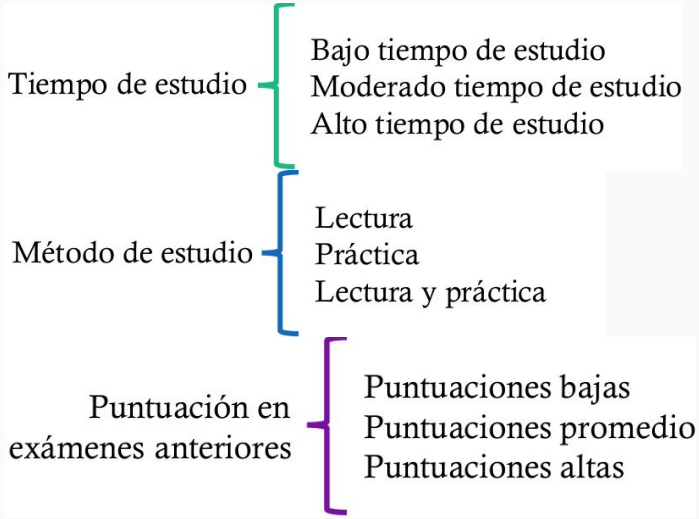
Ejemplo Práctico:

Para entender su funcionamiento, queremos construir un clasificador que prediga si un estudiante va a aprobar un examen.

Atributos del Modelo

Variables de Entrada

Predicción basada en los siguientes atributos:



© gonzalezhalexis@gmail.com ©

Clasificador Bayesiano Ingenuo

TEOREMA DE BAYES

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	Lectura y Práctica	Promedio	Aprobó
Alto	Lectura y Práctica	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	Lectura y Práctica	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	Lectura y Práctica	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Tiempo de estudio	Bajo	1	2
	Moderado	3	1
	Alto	2	1

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Método de estudio	Lectura	1	2
	Practica	2	1
	L y P	3	1

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Puntuación	Bajo	0	3
	Promedio	2	0
	Alto	4	1

© gonzalezhalexis@gmail.com ©

Clasificador Bayesiano Ingenuo

TEOREMA DE BAYES

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	Lectura y Práctica	Promedio	Aprobó
Alto	Lectura y Práctica	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	Lectura y Práctica	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	Lectura y Práctica	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

$$P(H|E) = \frac{P(H)P(E|H)}{P(E)}$$

$P(E)$

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Tiempo de estudio	Bajo	1	2
	Moderado	3	1
	Alto	2	1

$P(H)$

$P(E)$

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Método de estudio	Lectura	1	2
	Practica	2	1
	L y P	3	1

$P(E)$

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Puntuación	Bajo	0	3
	Promedio	2	0
	Alto	4	1

© gonzalezhalexis@gmail.com ©

Clasificador Bayesiano Ingenuo

TEOREMA DE BAYES

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Tiempo de estudio	Bajo	1	2	3
	Moderado	3	1	4
	Alto	2	1	3
		6	4	10

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Método de estudio	Lectura	1	2	3
	Practica	2	1	3
	L y P	3	1	4
		6	4	10

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Puntuación	Bajo	0	3	3
	Promedio	2	0	2
	Alto	4	1	5
		6	4	10

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Tiempo de estudio	Bajo	1/6	1/2	3/10
	Moderado	1/2	1/4	2/5
	Alto	1/3	1/4	3/10
		3/5	2/5	10

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Método de estudio	Lectura	1/6	1/2	3/10
	Practica	1/3	1/4	3/10
	L y P	1/2	1/4	2/5
		3/5	2/5	10

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Puntuación	Bajo	0	3/4	3/10
	Promedio	1/3	0	1/5
	Alto	2/3	1/4	1/2
		3/5	2/5	10

© gonzalezhalexis@gmail.com ©

Clasificador Bayesiano Ingenuo

TEOREMA DE BAYES

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Tiempo de estudio	Bajo	1/6	1/2	3/10
	Moderado	1/2	1/4	2/5
	Alto	1/3	1/4	3/10
		3/5	2/5	10

$$P(H) = P(Aprobo) = 3/5 = 0.6$$

$$P(!H) = P(Desaprobo) = 2/5 = 0.4$$

$$P(E) = P(Bajo\ tiempo\ de\ estudio) = 3/10 = 0.3$$

$$P(E|H) = P(Bajo|Aprobo) = 1/6 = 0.17$$

$$P(E|!H) = P(Bajo|Desaprobo) = 1/2 = 0.5$$

Apliquemos el teorema de Bayes:

$$P(H|E) = P(Aprobo|Bajo) = \frac{P(E|H)P(H)}{P(E)} = \frac{P(Bajo|Aprobo)P(Aprobo)}{P(Bajo\ tiempo\ de\ estudio)} = \frac{0.17 * 0.6}{0.3} = 0.34$$

$$P(!H|E) = P(Desaprobo|Bajo) = \frac{P(E|!H)P(!H)}{P(E)} = \frac{P(Bajo|Desaprobo)P(Desaprobo)}{P(Bajo\ tiempo\ de\ estudio)} = \frac{0.5 * 0.4}{0.3} = 0.67$$

© gonzalezhalexis@gmail.com ©

TEOREMA DE BAYES

Clasificador Bayesiano Ingenuo

Se asume que los tres atributos son independientes entre sí:

FÓRMULA Y CÁLCULO DE PROBABILIDAD

$P(E)$ equivale a *Estudio = Alto*, *Método = L y P*, *Puntuación = Alta*

$$P(H) = P(Aprueba)$$

$$P(H|E) = \frac{\overbrace{P(Alto|Aprueba)P(LyP|Aprueba)P(Alta|Aprueba)}^{P(E|H)}P(Aprueba)}{\underbrace{P(Alto)P(LyP)P(Alto)}_{P(E)}}$$

$$P(H|E) = \frac{0.333 * 0.5 * 0.667 * 0.6}{0.3 * 0.4 * 0.5} = 1.11$$

© gonzalezhalexis@gmail.com ©

TEOREMA DE BAYES

Clasificador Bayesiano Ingenuo

Veamos la hipótesis de que el alumno desaprueba:

FÓRMULA Y CÁLCULO DE PROBABILIDAD

$P(E)$ equivale a $Estudio = Alto$, $Método = L\ y\ P$, $Puntuación = Alta$

$$P(H) = P(Desaprueba)$$

$$P(H|E) = \frac{P(Alto|Aprueba)P(LyP|Aprueba)P(Alta|Aprueba)P(Aprueba)}{P(Alto)P(LyP)P(Alto)}$$

$$P(H|E) = \frac{0.25 * 0.25 * 0.25 * 0.4}{0.3 * 0.4 * 0.5} = 0.10$$

© gonzalezhalexis@gmail.com ©

TEOREMA DE BAYES

Clasificador Bayesiano Ingenuo

PROCESO DE NORMALIZACIÓN

Normalizamos:

$$Suma = P(H|E) + P(!H|E) = 1.11 + 0.10 = 1.21$$

$$P(H|E) = \frac{1.11}{1.21} = 0.92$$

$$P(!H|E) = \frac{0.1}{1.21} = 0.08$$

Interpretación Final:

Dado que, si un alumno le dedica muchas horas, estudia practicando y leyendo, y tiene buenas notas, es muy probable que apruebe el examen.

FUNDAMENTO TEÓRICO

Independencia de Características

En el contexto del clasificador Naive Bayes, las probabilidades condicionales pueden sumar más de uno debido a la independencia asumida entre las características, lo que puede resultar en una sobreestimación.

¿Por qué se requiere normalizar?

Aunque una probabilidad no puede ser mayor que uno, en este contexto, este valor no invalida el resultado. Sin embargo, para interpretarlas como una distribución de probabilidad válida, se requiere normalizar.

© gonzalezhalexis@gmail.com ©

TEOREMA DE BAYES

Clasificador Bayesiano Ingenuo

SIMPLIFICACIÓN DEL CÁLCULO

El denominador es constante, solo se calcula el numerador:

- $P(H|E) = 0.333 * 0.5 * 0.667 * 0.6 = 0.06663$
- $P(!H|E) = 0.25 * 0.25 * 0.25 * 0.4 = 0.00625$

PROBLEMA DE FRECUENCIA CERO Y SOLUCIÓN

Falta de datos en alguna combinación:

Si un atributo tiene frecuencia 0, anula toda la probabilidad:

```
P(H|A) = 0.333 * 0.5 * 0 * 0.6 = 0
```

Solución: Suavizado de Laplace (+1)

Mitigamos este problema sumando un valor (generalmente +1) a cada recuento en las tablas de frecuencia, garantizando que ninguna probabilidad sea nula.

TABLAS DE FRECUENCIA CON SUAVIZADO (+1)

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Tiempo de estudio	Bajo	1+1=2	2+1=3
	Moderado	3+1=4	1+1=2
	Alto	2+1=3	1+1=2

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Método de estudio	Lectura	1+1=2	2+1=3
	Practica	2+1=3	1+1=2
	L y P	3+1=4	1+1=2

Tabla de frecuencia		Resultado	
		Aprobó	Desaprobó
Puntuación	Bajo	0+1=1	3+1=4
	Promedio	2+1=3	0+1=1
	Alto	4+1=5	1+1=2

© gonzalezhalexis@gmail.com ©

TEOREMA DE BAYES

Clasificador Bayesiano Ingenuo

TABLAS DE FRECUENCIA

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Tiempo de estudio	Bajo	2/9	3/7	5/16
	Moderado	4/9	2/7	6/16
	Alto	3/9	2/7	5/16
		9/16	7/16	16

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Método de estudio	Lectura	2/9	3/7	5/16
	Practica	3/9	2/7	5/16
	L y P	4/9	2/7	6/16
		9/16	7/16	16

Tabla de frecuencia		Resultado		
		Aprobó	Desaprobó	
Puntuación	Bajo	1/9	4/7	5/16
	Promedio	3/9	1/7	4/16
	Alto	5/9	2/7	6/16
		9/16	7/16	16

CÁLCULO DE PROBABILIDAD CON SUAVIZADO

Predicción para alumno con: **Tiempo alto, práctica, lecturas y puntuación baja**:

- $P(H|E) = 0.333 * 0.444 * 0.111 * 0.5625 = 0.0092$
- $P(!H|E) = 0.286 * 0.286 * 0.286 * 0.4375 = 0.0102$

Este número adicional es un hiperparámetro llamado α (alfa).

TRATAMIENTO DE VARIABLES NUMÉRICAS

El clasificador funciona nativamente con variables categóricas. Para variables numéricas existen dos enfoques:

- **Discretización:** Agrupar los valores continuos en contenedores o rangos.
- **Distribución de Probabilidad:** Asumir una distribución (ej. Gaussiana) para calcular $P(x_i|y)$

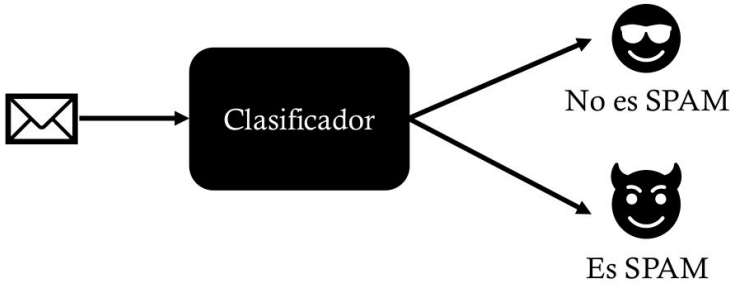
© gonzalezhalexis@gmail.com ©

MÉTRICAS DE CLASIFICACIÓN

Evaluación de Clasificadores y Tasa de Aciertos

PROBLEMA DE CLASIFICACIÓN DE SPAM

Supongamos que tenemos un modelo encargado de identificar si un correo es SPAM o no:



¿Cómo medimos la calidad de este clasificador? ¿Cómo sabemos si funciona bien?

DESBALANCE DE DATOS Y LA TASA DE ACIERTOS

Uno podría pensar intuitivamente en la tasa de aciertos.

Pero los correos SPAM son mucho menos frecuentes que los no SPAM, supongamos que tenemos una relación 1 a 1000.

Modelo iluso (clasifica todo como no SPAM):

Tasa de Aciertos: 99.9%

Un modelo inútil obtiene una excelente métrica por el desbalance.

Entonces, ¿seguimos considerando la tasa de aciertos como una buena métrica?

© gonzalezhalexis@gmail.com ©

MÉTRICAS DE CLASIFICACIÓN

Matriz de Confusión

ESTRUCTURA DE LA MATRIZ

Predicción \ Valor Real (Clase)	Positivo (1)	Negativo (0)
Positivo (1)	**TP** Verdadero Positivo	**FP** Falso Positivo **(Error Tipo I)**
Negativo (0)	**FN** Falso Negativo **(Error Tipo II)**	**TN** Verdadero Negativo

¿Qué es la matriz de confusión? Es una herramienta que permite visualizar el desempeño de un algoritmo de clasificación comparando los valores reales con las predicciones del modelo.

DESGLOSE DE COMPONENTES

Verdadero Positivo (TP)
Observaciones clasificadas correctamente como **1** (Positivo) y que realmente eran **1**.

Verdadero Negativo (TN)
Observaciones clasificadas correctamente como **0** (Negativo) y que realmente eran **0**.

Falso Positivo (FP) — Error Tipo I
Observaciones clasificadas como **1** pero que realmente eran **0**.

Falso Negativo (FN) — Error Tipo II
Observaciones clasificadas como **0** pero que realmente eran **1**.

© gonzalezhalexis@gmail.com ©

MÉTRICAS DE CLASIFICACIÓN

Sensibilidad, Especificidad y Exactitud

MÉTRICAS FUNDAMENTALES

Sensibilidad (Tasa de Verdaderos Positivos - TPR)

Capacidad del clasificador para detectar todos los casos positivos en los datos.

$$TPR = \frac{TP}{TP + FN}$$

Especificidad (Tasa de Verdaderos Negativos - TNR)

Capacidad del clasificador para identificar correctamente los casos negativos.

$$TNR = \frac{TN}{TN + FP}$$

EJEMPLO: CLASIFICADOR NO-SPAM (DESBALANCE)

Para un modelo que clasifica **todo como "NO SPAM"**:
Sensibilidad = 0 | Especificidad = 1

$$Exactitud = \frac{TP + TN}{P + N} = 0.999$$

Ante un **desbalance de clases**, se debe utilizar la **exactitud balanceada**:

$$Exactitud\ balanceada = \frac{TPR + TNR}{2} = 0.5$$

💡 **Conclusión Clave**

Mientras que la exactitud convencional parece casi perfecta (0.999), la exactitud balanceada de **0.5 nos indica que el clasificador simplemente está adivinando.**

© gonzalezhalexis@gmail.com ©

MÉTRICAS DE CLASIFICACIÓN

Precisión y Recuperación

DEFINICIONES Y FÓRMULAS

Precisión

Proporción de casos positivos identificados correctamente respecto a todos los que el clasificador etiquetó como positivos.

$$Precision = \frac{TP}{TP + FP}$$

Recuperación (Recall)

Proporción de casos positivos identificados correctamente con respecto a todos los casos positivos reales.

$$Recall = \frac{TP}{TP + FN}$$

EJEMPLOS Y APLICACIONES

Importancia según el escenario de clasificación:

Precisión — Clasificador de SPAM

Es prioritaria cuando el clasificador determina que un correo es SPAM, garantizando alta seguridad para evitar que el usuario pierda correos electrónicos importantes.

Recuperación — Detección de Cáncer

Es fundamental capturar la mayor cantidad posible de casos reales para asegurar un diagnóstico y tratamiento oportunos, aun cuando esto genere algunos falsos positivos.

© gonzalezhalexis@gmail.com ©

MÉTRICAS DE CLASIFICACIÓN

Precisión y Recuperación

BALANCE ARMÓNICO: PUNTAJE F1

Útil cuando se busca un equilibrio justo entre ambas métricas.

$$F_1 = 2\,\frac{precision \cdot recall}{precision + recall}$$

PONDERACIÓN DE MÉTRICAS: PUNTAJE Fβ

Permite dar mayor importancia a una métrica sobre la otra según el caso de uso.

$$F_\beta = (1+\beta^2)\,\frac{precision \cdot recall}{\beta^2\,precision + recall}$$

CRITERIO DE SELECCIÓN DE β

0 < β < 1 — Mayor peso a la Precisión

Se prioriza cuando el costo de los falsos positivos es muy alto (preferimos minimizarlos).

β > 1 — Mayor peso a la Recuperación

Se prioriza cuando omitir casos positivos es grave (preferimos minimizar los falsos negativos).

© gonzalezhalexis@gmail.com ©

MÉTRICAS DE CLASIFICACIÓN

Curva ROC (Receiver Operating Characteristic)

CONCEPTO DE UMBRAL DE DECISIÓN

Regresión Logística y Probabilidad

Para las métricas vistas, asumíamos que el clasificador devuelve salida 1 (clase positiva) o 0 (negativa).

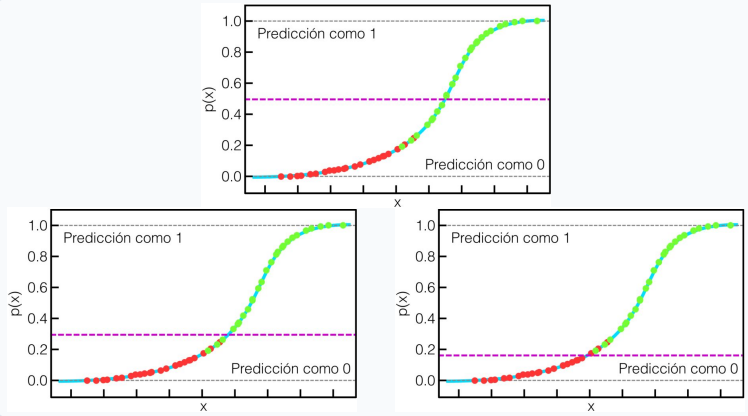
En regresión logística obtenemos una probabilidad de pertenencia a la clase positiva.

Intuitivamente, si la probabilidad es **> 0.5** se clasifica como positiva; si es **0.5**, como negativa.

¿Por qué el umbral de 0.5?

Nos basamos en la idea de que el modelo nos da un valor de probabilidad. Sin embargo, nada impide definir el umbral en otros valores, especialmente cuando las clases están desbalanceadas.

EVALUACIÓN DE UMBRALES (0 A 1)



Análisis de la Curva ROC

Permite ver, para cada valor de umbral de 0 a 1, los dos tipos de errores midiendo sensibilidad y especificidad.

Eje X (Abscisas): Tasa de Falsos Positivos (1 - Especificidad)

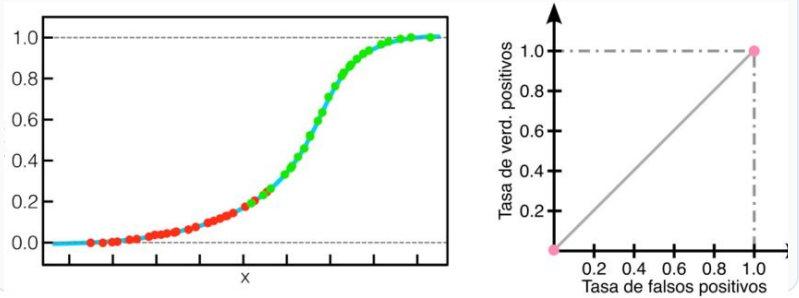
Eje Y (Ordenadas): Tasa de Verdaderos Positivos (Sensibilidad)

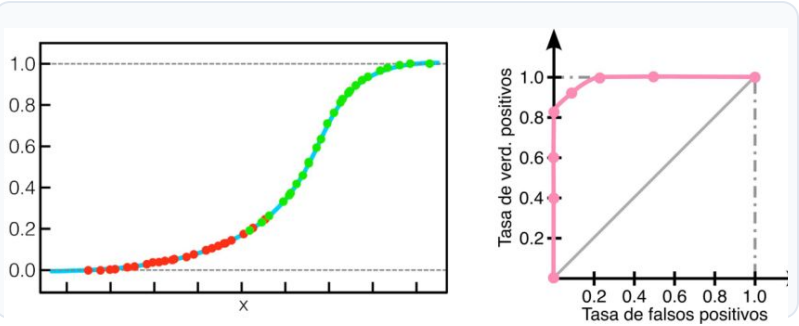
© gonzalezhalexis@gmail.com ©

MÉTRICAS DE CLASIFICACIÓN

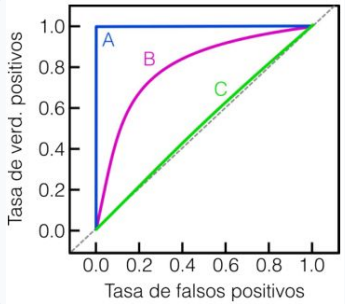
Curva ROC (Receiver Operating Characteristic)

CONSTRUCCIÓN DE LA CURVA ROC





EVALUACIÓN Y ÁREA BAJO LA CURVA (AUC)



- **A:** La curva de un clasificador perfecto.
- **B:** La curva de un clasificador estándar.
- **C:** La curva de un clasificador que adivina (el peor caso)

La curva ROC permite encontrar el valor de umbral que dé el mejor resultado

Además, permite comparar clasificadores sin preocuparnos por el valor del umbral elegido.

Área Bajo la Curva (AUC)

Si queremos resumir esta curva en una métrica, podemos calcular el área bajo la curva (AUC):

- **Modelo A:** AUC = 1 (Clasificador perfecto)
- **Modelo B:** 0.5 < AUC < 1 (Clasificador estándar)
- **Modelo C:** AUC = 0.5 (Adivina / Peor caso)

© gonzalezhalexis@gmail.com ©

Google Colab

Ejemplo en Python

11_clasificacion



© gonzalezhalexis@gmail.com ©

Actividad individual opcional





Detector de SPAM

En este ejercicio deben detectar SPAM en un dataset de 4601 correos (54 atributos word_freq_XXXX con la frecuencia de cada palabra), comparando dos modelos:

(1) una regresión logística con un Pipeline que incluya escalado de atributos, y

(2) un modelo de Bayes ingenuo, eligiendo la implementación de scikit-learn más apropiada para datos de frecuencia de palabras, sin normalización.

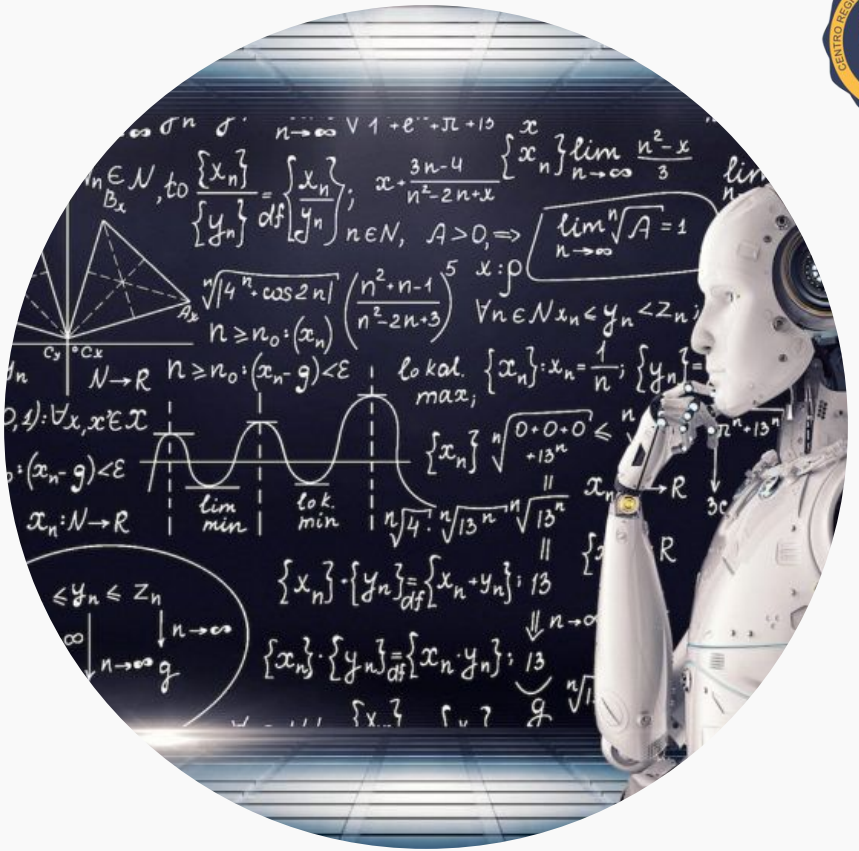
Para ambos hay que calcular matriz de confusión, precisión, recall y AUC sobre el set de testeo, y responder qué tipo de error (falso positivo o falso negativo) comete más cada modelo y cuál de los dos es más grave para este problema.

Entrega	Preguntas correctas	Puntos
No	-	0
Si	No cumple consigna	0
Si	Cumple consigna	1

© gonzalezhalexis@gmail.com ©

¡Gracias!

¿Consultas?



Ing. González H. Alexis

© gonzalezhalexis@gmail.com ©